Machine Translated by Google

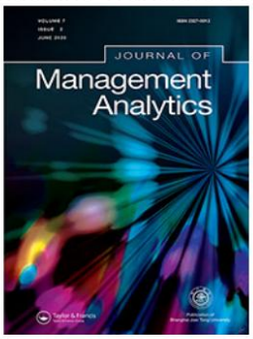

Taylor & Francis
Taylor & Francis Group

Jornal de Análise de Gestão

ISSN: 2327-0012 (Impresso) 2327-0039 (Online) Página inicial da revista: https://www.tandfonline.com/loi/tjma20

Processamento de linguagem natural (PNL) na pesquisa gerencial: uma revisão da literatura

Yue Kang, Zhao Cai, Chee-Wee Tan, Qian Huang e Hefu Liu

Para citar este artigo: Yue Kang, Zhao Cai, Chee-Wee Tan, Qian Huang e Hefu Liu (2020) Processamento de linguagem natural (PNL) na pesquisa de gestão: uma revisão de literatura, Journal of Management Analytics, 7:2, 139-172, DOI: 10.1080/23270012.2020.1756939

Para vincular a este artigo: https://doi.org/10.1080/23270012.2020.1756939

Publicado on-line: 04 de maio de 2020.

Envie seu artigo para esta revista

Visualizações de artigos: 5755

Ver artigos relacionados

Ver dados do Crossmark

Citando artigos: 62 Ver artigos que citaram

Os Termos e Condições completos de acesso e uso podem ser encontrados em https://www.tandfonline.com/action/journalInformation?journalCode=tjma20

Machine Translated by Google

Jornal de Análise de Gestão, 2020 Vol. 7, nº 2,
139–172, https://doi.org/10.1080/23270012.2020.1756939

ANÁLISE

Processamento de linguagem natural (PNL) na pesquisa gerencial: uma revisão da literatura

Yue Kanga , Zhao Cai b*, Chee-Wee Tan c, Qian Huanga e Hefu Liu a

[a]Escola de Administração, Universidade de Ciência e Tecnologia da China, Hefei, República Popular da China; [b]Escola de Negócios da Universidade de Nottingham China, Universidade de Nottingham Ningbo China, Ningbo, República Popular da China; [c]Departamento de Digitalização, Copenhagen Business Escola, Copenhague, Dinamarca

(Recebido em 14 de março de 2020; revisado em 13 de abril de 2020; aceito em 14 de abril de 2020)

O processamento de linguagem natural (PNL) está ganhando impulso na pesquisa gerencial por sua capacidade de analisar e compreender automaticamente a linguagem humana. No entanto, apesar da sua extensa aplicação na investigação em gestão, não existe uma revisão abrangente da literatura existente sobre tais aplicações, nem há um passo a passo detalhado sobre como pode ser empregue como uma técnica analítica. Para esse fim, revisamos artigos na lista dos 24 principais periódicos de negócios da UT Dallas que empregam a PNL como técnica analítica focal para elucidar como os dados textuais podem ser aproveitados para o avanço das teorias de gestão em múltiplas disciplinas. Descrevemos os kits de ferramentas disponíveis e as etapas processuais para empregar a PNL como técnica analítica, bem como suas vantagens e desvantagens. Ao fazê-lo, destacamos os desafios gerenciais e tecnológicos associados à aplicação da PNL na pesquisa gerencial, a fim de orientar futuras investigações.

Palavras-chave: processamento de linguagem natural; revisão da literatura; análise de sentimentos; aprendizado de máquina

1. Introdução

A digitalização dotou os investigadores de oportunidades sem precedentes para colher uma riqueza de dados textuais para investigar fenómenos contemporâneos. O Processamento de Linguagem Natural (PNL), uma técnica analítica assistida por computador que visa analisar e compreender automaticamente a linguagem humana (Manning, Manning, & Schütze, 1999), permite que os estudiosos extraiam facilmente insights benéficos contidos em conjuntos de dados textuais, evitando ao mesmo tempo um trabalho computacional pesado. (Collobert et al., 2011; Verde, 2012). Nos últimos anos, a PNL experimentou avanços significativos com o surgimento da Inteligência Artificial (IA) (Barr & Feigenbaum, 2014; Hirsch-berg & Manning, 2015; Lu, 2019). Os avanços na tradução automática (Och, 2003), na correspondência de padrões (Califf & Mooney, 2003), na análise de sentimentos (Liu, 2012) e no reconhecimento de fala (Weber, 2002) não só trouxeram mudanças radicais na vida diária das pessoas, mas também também revolucionaram as práticas empresariais. Por exemplo, a Agência Norueguesa de Notícias1 (NTB) documentou que jornalistas robóticos podem produzir um artigo noticioso dentro de 30 segundos após a conclusão de um evento. Da mes

*Autor correspondente. E-mail: zhao.cai@nottingham.edu.cn

© 2020 Antai College of Economics and Management, Universidade Jiao Tong de Xangai

Machine Translated by Google

deu origem a dispositivos inteligentes (Siri, Cortana), tradução simultânea (STACL2 do Baidu), reconhecimento de voz para texto (iflyrec3 da iFLYTEK), previsões de mercado baseadas em sentimentos (por exemplo, notícias financeiras e Twitter)4 , bem como guias de compras inteligentes e atendentes robóticos de atendimento ao cliente (Alibaba5), que juntos remodelaram o cenário empresarial. Para obter uma apreciação aprofundada do comportamento do consumidor (Chi-Hsien & Nagasawa, 2019; Hou, Zhao, Zhao, & Zhang, 2016), governança corporativa (Chanda & Goyal, 2019; Law & Chung, 2020) e dinâmica de mercado (Verma, Malhotra, & Singh, 2020), os estudiosos recorreram à PNL como um meio de obter insights de conjuntos de dados textuais em relatórios anuais e comunicados de imprensa publicados por empresas, análises online e postagens em mídias sociais geradas por consumidores, bem como documentos legislativos e políticos promulgados pelos governos (Bansal, Sharma, & Singh, 2019). Aproveitando a PNL, os pesquisadores podem capturar conceitos de forma objetiva e precisa, eliminando assim o trabalho tedioso associado à codificação textual manual.

Até o momento, o vasto desenvolvimento da PNL contribuiu substancialmente para avanços nas teorias de gestão. No final de 2019, havia 72 artigos publicados na lista de 24 principais periódicos de negócios da UT Dallas (lista UTD) que se baseiam na PNL como técnica analítica focal. No entanto, apesar do número crescente de estudos centrados na PNL, não existe uma revisão abrangente da literatura existente sobre como ela tem sido aplicada à pesquisa de gestão, nem há um passo a passo detalhado sobre como ela pode ser empregada como uma técnica analítica. Portanto, argumentamos que uma revisão sistemática da literatura existente está muito atrasada para elucidar como a PNL tem sido aplicada à pesquisa de gestão em todas as disciplinas e fornecer aos estudiosos abordagens plausíveis e inovadoras para aplicar esta técnica analítica para o enriquecimento das teorias de gestão. . Na mesma linha, afirmamos que é essencial desenvolver um tutorial passo a passo que ilumine como a PNL pode ser empregada na análise de dados para torná-la mais acessível aos estudiosos que lidam com dados textuais. Para este fim, este estudo aborda as lacunas de conhecimento acima mencionadas, conduzindo uma revisão da literatura existente sobre PNL para traçar um roteiro sobre como a técnica analítica pode ser aplicada para informar a pesquisa de gestão. O escopo de nossa revisão de literatura abrange a lista UTD das 24 principais revistas de negócios porque os artigos publicados nessas revistas geralmente possuem uma base teórica sólida, design empírico rigoroso, procedimentos analíticos meticulosos e conjuntos de dados ricos. Ao restringir o escopo de nossa revisão de literatura a esta lista, aderimos ao princípio defendido por Ricks, Toyne e Martinez (1990) de que a literatura revisada deve ser a “literatura recente sobre as questões básicas para que o leitor possa ser levado atualizado e orientado para o que pode ser lido para obter a profundidade de compreensão desejada” (p. 220).

Diante disso, pretendemos contribuir para a aplicação da PNL na pesquisa em gestão em três frentes. Primeiro, tentamos ilustrar como os dados textuais podem ser aproveitados para a investigação de gestão em múltiplas disciplinas, concentrando-nos especificamente em onde os conjuntos de dados textuais podem ser adquiridos e como podem ser aproveitados para resolver problemas de gestão contínuos. Em segundo lugar, esforçamo-nos por oferecer um guia metódico para os académicos que pretendem empregar a PNL no seu trabalho analítico, descrevendo os passos processuais e os kits de ferramentas disponíveis, bem como as suas vantagens e desvantagens. Finalmente, procuramos expor os desafios gerenciais e tecnológicos enfrentados pelos estudiosos na aplicação da PNL, que por sua vez apontam para oportunidades para mais inovação sobre como os dados textuais podem ser engenhosamente aplicados para avançar nas teorias de gestão.

Machine Translated by Google

O manuscrito restante está estruturado da seguinte forma. Primeiro oferecemos uma visão geral da PNL, incluindo sua história. Em seguida, descrevemos as etapas metodológicas tomadas na condução de nossa revisão da literatura existente sobre a aplicação da PNL em artigos publicados na Lista UTD das 24 principais revistas de negócios. Em seguida, elaboramos como a PNL tem sido aplicada na pesquisa de gestão em uma variedade de disciplinas, destacando considerações específicas da disciplina no que diz respeito à sua aplicação e derivando oportunidades para pesquisas futuras através de comparações interdisciplinares. A seguir, apresentamos um tutorial passo a passo de procedimentos básicos de processamento para PNL e algoritmos Concluímos identificando desafios potenciais e direções futuras para o desenvolvimento da PNL, tanto do ponto de vista gerencial quanto tecnológico.

2. Processamento de linguagem natural: uma visão geral

A PNL constitui um interesse central no campo da inteligência artificial e da ciência da computação. Os estudos de PNL compreendem teorias e métodos que permitem a comunicação eficaz entre humanos e computadores em linguagem natural. Como campo de estudo científico, a PNL assimila a ciência da computação, a linguística e a matemática com o objetivo principal de traduzir a linguagem humana (ou natural) em comandos que podem ser executados por computadores. A PNL consiste em duas direções de pesquisa: Compreensão da Linguagem Natural (NLU) e Geração de Linguagem Natural (NLG). A principal missão da NLU é compreender a linguagem natural (linguagem humana) (Schank, 1972) , decifrando documentos e extraindo informações valiosas para tarefas posteriores. Em contraste, NLG é a produção de texto em línguas naturais que são compreensíveis por humanos com base no fornecimento de dados estruturados, texto, gráficos, áudio e vídeo (McDonald, 2010) . O NLG pode ainda ser dividido em três categorias: texto para texto (Genest & Lapalme, 2011), como tradução e resumo; texto para outro, como imagens geradas por texto (Xu et al., 2018); e other para texto (other-to-Text), como texto gerado por vídeo (Rohrbach et al., 2013).

Até agora, o desenvolvimento da PNL passou por quatro períodos: o período de germinação antes de 1956, o período de rápido desenvolvimento de 1957 a 1970, o período de desenvolvimento de baixa velocidade de 1971 a 1993 e o período de recuperação de 1994 até o presente.

O período de germinação abrange o início da pesquisa em PNL. Alan Turing propôs pela primeira vez o conceito de 'Máquina de Turing' em 1936. A 'Máquina de Turing', como origem teórica do computador moderno, motivou o nascimento do computador eletrônico em 1946, fornecendo uma base material para a tradução automática e, posteriormente , PNL. Dadas as necessidades da tradução automática, foram realizadas pesquisas fundamentais em PNL durante este período. Em 1948, Shannon aplicou o modelo probabilístico de processos discretos de Markov à automação da linguagem de descrição. Ele então aplicou o conceito de entropia na termodinâmica ao algoritmo probabilístico de processamento de linguagem para medir a quantidade de informação contida na linguagem humana. No início da década de 1950, Kleene investigou autômatos finitos e expressões regulares e, em 1956, Chomsky propôs uma gramática livre de contexto e aplicou-a à PNL. Tal trabalho levou diretamente à geração de duas técnicas de PNL baseadas em regras e probabilidade. Esses dois métodos geraram décadas de disputas sobre métodos baseados em regras e métodos probabilísticos na PNL. O nascimento da inteligência artificial em 1956 abriu ainda mais um novo capítulo na PNL, à medida que a IA gradualmente se combinou com outras tecnologias de PNL ao longo das décadas seguintes para enriquecer os meios técnicos de NLU e NLG, ampliando assim a aplicação social da PNL.

Machine Translated by Google

O primeiro grande desenvolvimento da PNL ocorreu de 1957 a 1970, quando a PNL foi rapidamente integrada ao campo da inteligência artificial. Durante este período, a pesquisa sobre métodos baseados em regras e métodos probabilísticos fez grandes progressos. De meados da década de 1950 a meados da década de 1960, estudiosos simbolistas como Chomsky começaram o estudo da teoria da linguagem formal e da sintaxe generativa. Ao mesmo tempo, estudiosos com foco em métodos probabilísticos adotaram o método Bayesiano baseado em métodos de pesquisa estatística e também fizeram grandes progressos durante este período. Contudo, no campo da inteligência artificial, a maioria dos estudiosos só prestou atenção ao estudo do raciocínio e da lógica.

Muito poucos estudiosos de estatística e eletrônica estudaram métodos estatísticos baseados em probabilidade e redes neurais. Realizações importantes na pesquisa durante este período incluíram o bem-sucedido Projeto de Transformações e Análise do Discurso (TDAP) desenvolvido pela Universidade da Pensilvânia em 1959 e o estabelecimento do Brown American English Corpus. Em 1967, o psicólogo americano Neisser propôs o conceito de psicologia cognitiva, ligando diretamente a PNL à cognição humana.

O segundo grande desenvolvimento da PNL começou em 1971 e terminou em 1993. Naquela época, era evidente que as aplicações baseadas em PNL não poderiam ser resolvidas em um curto espaço de tempo e novos problemas relativos ao uso da abordagem estatística e ao estabelecimento de corpus foram surgindo. emergindo constantemente. Como resultado, muitas pessoas perderam a confiança no estudo da PNL. A década de 1970 marca, portanto, um ponto baixo no estudo da PNL.

Apesar disso, os investigadores dos países desenvolvidos continuaram a sua investigação e, na década de 1970, desenvolveram com sucesso métodos estatísticos baseados no Modelo Oculto de Markov (HMM) que beneficiaram enormemente o campo do reconhecimento de voz. Além disso, o desenvolvimento da análise do discurso no início da década de 1980 também fez progressos significativos no diálogo homem-máquina. Poucos anos depois, à medida que os pesquisadores da PNL refletiam sobre pesquisas anteriores, os modelos de estados finitos e os métodos estatísticos também começaram a reviver.

Após meados da década de 1990, dois eventos promoveram fundamentalmente a recuperação e o desenvolvimento da pesquisa em PNL. O primeiro foi o rápido aumento da velocidade e do armazenamento nos computadores, que melhorou a base material da PNL e tornou possível o desenvolvimento comercial do processamento da fala e da linguagem. O segundo evento foi a comercialização da Internet em 1994. No geral, o desenvolvimento da tecnologia de rede durante este período tornou mais proeminente a procura por recuperação e extracção de informação baseada em linguagem natural. Em 2001, Yoshua Bengio propôs o primeiro modelo de linguagem neural, a rede neural feed-forward.

Em 2008, Ronan Collobert foi o primeiro a aplicar multitarefa à rede neural da PNL. Em 2013, Tomas Mikolov desenvolveu o Word2Vec, um método estatístico que pode aprender com eficácia a incorporação independente de palavras a partir de um corpus de texto baseado em redes neurais do Google. Em 2014, Ilya Sutskever propôs o modelo de aprendizagem sequência a sequência, uma estrutura geral para mapear uma sequência para outra sequência usando uma rede neural. Com base nesses modelos estatísticos, as pessoas fazem com que as máquinas compreendam e produzam melhor a linguagem humana.

Recentemente, além da pesquisa focada na melhoria de algoritmos existentes ou na proposição de novos métodos para NLU e NLG no campo da ciência da computação, estudiosos de outras áreas começaram a perceber o valor da PNL e a aplicá-la à pesquisa. Por exemplo, muitos estudiosos da gestão propuseram novos métodos e algoritmos aprimorados de acordo com diferentes cenários de gestão. No campo da classificação, por exemplo, a estrutura de Desidentificação e Anonimização para Compartilhamento de Textos Médicos (DAST) foi proposta como um meio de agrupar registros de textos médicos (Li & Qin, 2017). Xu, Liao, Lau e Zhao (2014) tentaram superar a dificuldade de

Machine Translated by Google

alcançar anotação precisa em uma massa de dados rotulados manualmente, introduzindo um novo método de aprendizagem ativa para classificadores de grande margem. Gabel, Guhl e Klapper (2019) combinaram um modelo de linguagem de rede neural e redução de dimensionalidade para propor uma nova abordagem para analisar a estrutura do mercado. Da mesma forma, TY Lee e Bradlow (2011) concentrou-se na análise da estrutura de mercado e apresentou um método para identificar atributos do produto e a posição relativa de uma marca com base na experiência do cliente online. avaliações. Das e Chen (2007) desenvolveram uma metodologia para extrair informações de pequenos investidores sentimento de painéis de mensagens de ações. Em termos de análise de sentimento Fang Dutta e Datta (2014) propuseram uma abordagem híbrida que utiliza análise de sentimento para resolver o alto custo de aquisição de dados rotulados. Para melhorar a modelagem de tópicos, Toubia, Iyengar, Bunnell e Lemaire (2018) propuseram alocação latente guiada de Dirichlet (LDA) para extrair características de produtos de entretenimento. Bao e Datta (2014) também modelagem de tópicos aprimorada, levando em consideração a estrutura das frases e desenvolvendo um modelo LDA enviado para medir tipos de risco de registros 10-K. Ansari, Li e Zhang (2018) desenvolveu um novo tópico supervisionado, heterogêneo e guiado por covariáveis modelo para caracterizar sucintamente os produtos em termos de tópicos latentes e especificar as preferências do consumidor por meio de tópicos. J. Liu e Toubia (2018) levaram em consideração a semântica relação entre dois tipos diferentes de documentos e, consequentemente, propôs uma alocação de Dirichlet latente hierarquicamente dupla (HDLDA). Fundamentado no Correlacionado Topic Model (CTM), Trusov, Ma e Jamal (2016) incorporaram intensidade de visitação, heterogeneidade e dinâmica para propor uma abordagem que revele usuários individuais perfis de dados de navegação online. Bansal et al. (2019) propuseram um novo processo Hierárquico Analítico Fuzzy (FAHP) baseado na estrutura da frase, frequência do termo, palavra temática e proximidade da frase para avaliar sentenças na produção de um resumo eficiente e eficaz do julgamento legal. Para anotar informações médicas eletrônicas registros (EMR) com precisão e eficácia, Xu et al. (2016) sugeriram um método de anotação indireta. Este método divide os termos médicos em palavras e aplica o sentido da frase desambiguação (PSD) para 'termos compostos', a fim de refinar palavras candidatas para anotação. Tomados em conjunto, esses estudos indicam que a PNL tem sido cada vez mais aplicado a uma variedade de tópicos em pesquisa de gestão. Nosso artigo examina, portanto, aplicação da PNL em diferentes disciplinas para descobrir como ela tem sido usada e identificar oportunidades de pesquisa baseadas na comparação interdisciplinar.

3. Metodologia de revisão de literatura

Para obter uma análise abrangente da literatura proeminente em gestão (Webster & Watson, 2002), pesquisamos artigos em 24 importantes revistas de negócios identificadas pela Universidade do Texas em Dallas: Academy of Management Journal, Academy of Management Review, Administrative Science Quarterly, Management Science, Strategic Management Journal, Journal of International Business Studies, Journal of Finanças, Journal of Financial Economics, Revisão de Estudos Financeiros, Journal of Contabilidade e Economia, Journal of Accounting Research, Accounting Review, Manufacture and Service Operations Management, Operations Research, Journal of Operations Management, Production and Operations Management, Journal of Consumer Pesquisa, Jornal de Marketing, Ciência de Marketing, Jornal de Pesquisa de Marketing, Ciência da Organização, MIS Quarterly, Journal on Computing e Information Pesquisa de Sistemas. As palavras-chave “processamento de linguagem natural” foram utilizadas na busca um total de 123 artigos.

Machine Translated by Google

Localizamos sentenças que mencionavam PNL para determinar se os artigos eram diretamente relacionado a esta técnica. Como resultado, 50 artigos foram excluídos porque alguns artigos propuseram a aplicação da PNL em pesquisas futuras, alguns descartaram essa técnica devido a desvantagens declaradas e alguns apenas mencionaram a PNL na biografia do autor. 73 artigos foram selecionados como conjunto de artigos para análise posterior. Gerenciamento Science teve o maior número de artigos (16), Marketing Science teve o segundo (12), e o Journal of Marketing Research and Information Systems Research teve o terceiro (8) (Figura 1).

Depois de identificar os artigos que abordavam substancialmente a PNL, identificamos então distribuição dos artigos. Conforme ilustrado na Figura 2, a distribuição geral mostra que os últimos dois anos testemunharam um rápido crescimento nas aplicações da PNL à pesquisa em gestão. Além disso, de acordo com a Figura 3, o crescimento das pesquisas sobre o

Figura 1. Número de artigos da UTD24.

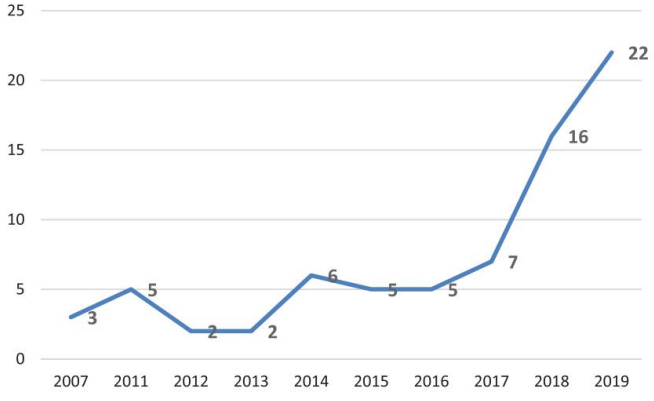

Figura 2. Distribuição dos artigos entre 2007 e 2019.

Machine Translated by Google

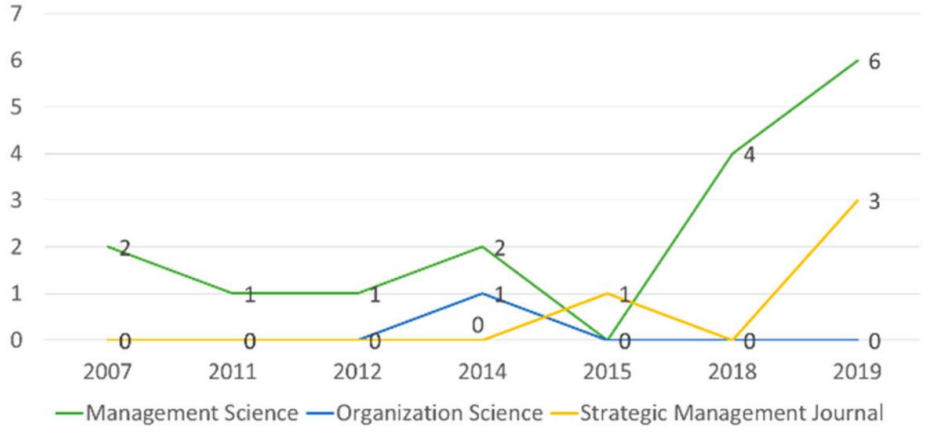

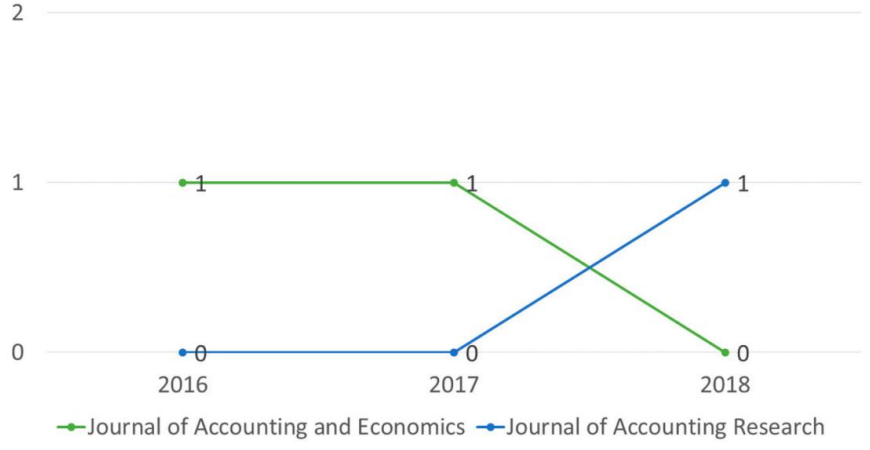

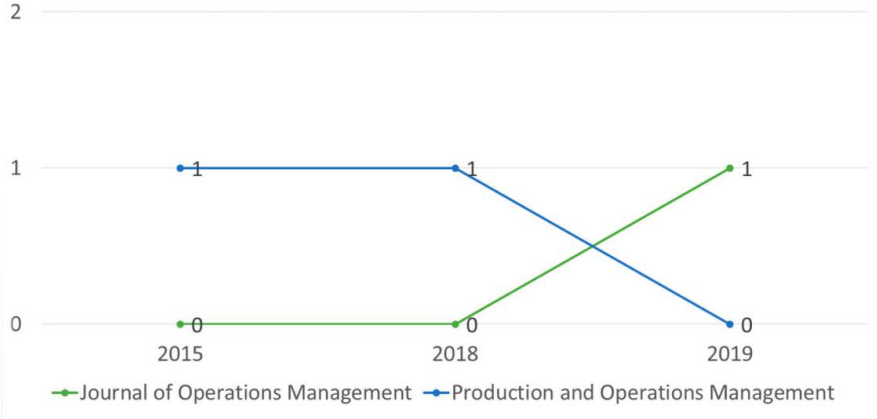

Figura 3. Distribuição dos artigos entre UTD24 entre 2007 e 2019.

Machine Translated by Google

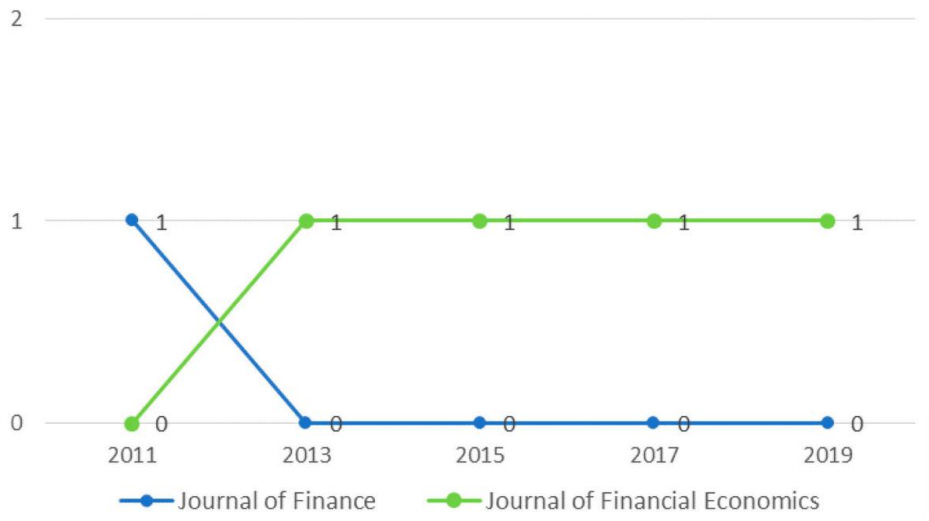

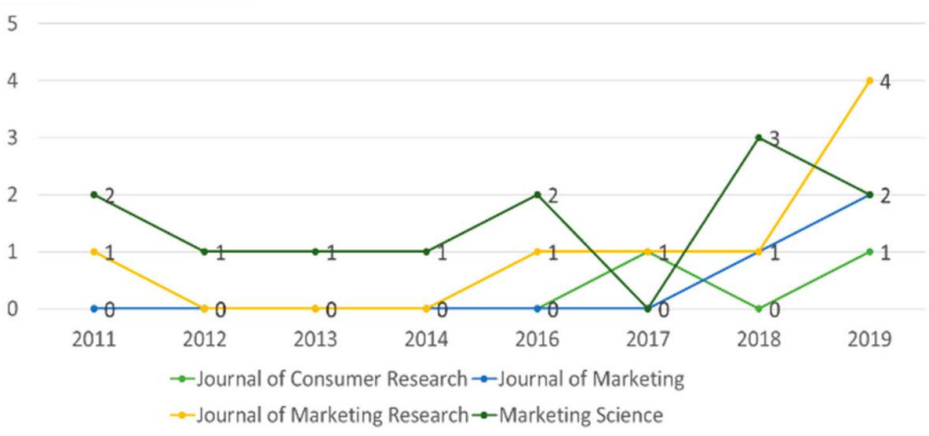

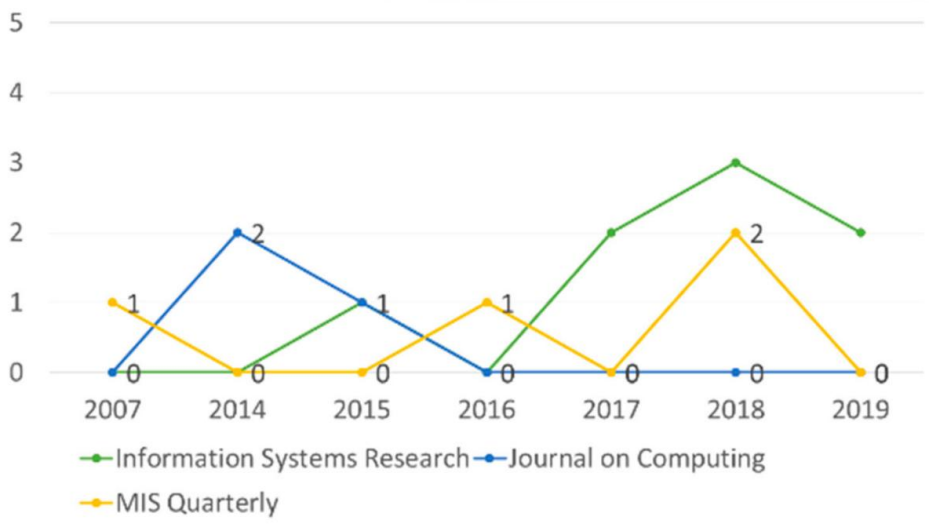

Figura 3. Continuação

Machine Translated by Google

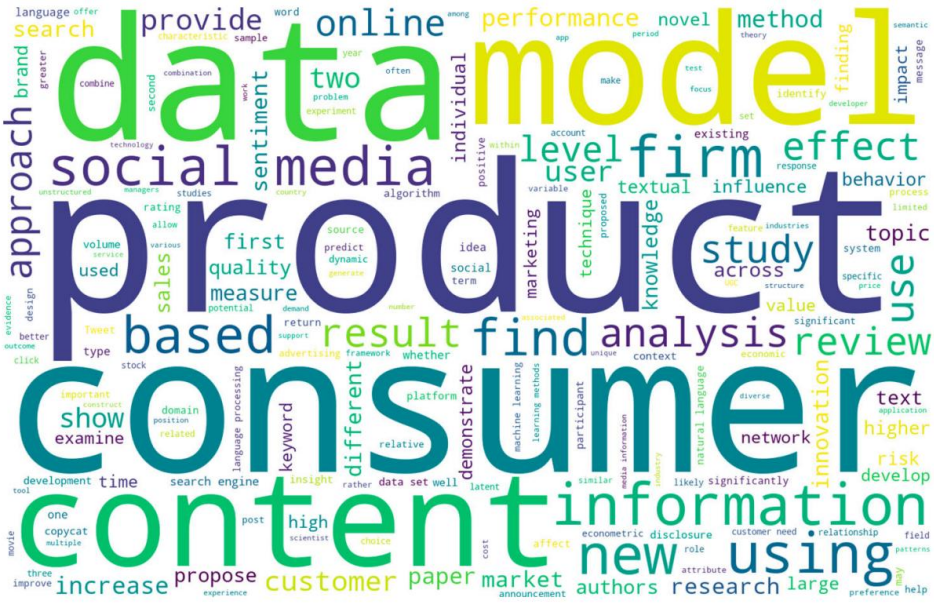

Figura 4. Word Cloud de aplicativos de PNL em gerenciamento.

a aplicação da PNL em diferentes disciplinas de gestão está se acelerando, especialmente em marketing, ciência de gestão e tópicos de gestão estratégica.

Para entender melhor o tema desses artigos, foi utilizada uma nuvem de palavras para analisar seus resumos. Implementamos um projeto Python para minerar textos e sintetizar o conteúdo de cada um dos 72 artigos. Conforme mostrado na Figura 4, palavras comuns relacionadas à PNL foram agrupadas e construídas como uma nuvem de palavras, a partir da qual foi ilustrada uma imagem holística da principal aplicação da PNL na gestão. Com base nos resultados da mineração de texto e nos artigos selecionados, descobrimos que a PNL tem sido aplicada a diversas áreas de interesse dentro do campo de pesquisa em gestão e destacamos neste estudo as áreas de pesquisa do consumidor, gestão de produtos, mídias sociais e gestão da informação.

4. Processamento de linguagem natural na gestão

Como os dados textuais são gerados de forma onipresente com as operações de negócios, a pesquisa em PNL em diferentes disciplinas de gestão concentra-se em uma variedade de tópicos de pesquisa e métodos analíticos. Especificamente, estudos nas áreas de sistemas de informação e marketing tendem a utilizar a PNL para capturar as opiniões e comportamentos dos clientes. Outras disciplinas, como contabilidade, finanças e gestão de operações, tendem a concentrar-se na extração de informações diferenciadas dos registros das empresas, como relatórios anuais e dados de patentes. Para métodos analíticos, estudiosos de sistemas de informação, marketing e gestão de operações adotaram algoritmos de aprendizagem profunda que levam em conta o contexto das palavras, o que significa que os computadores podem expressar palavras de acordo com seu valor semântico para “entender” o texto com mais precisão. Em outros campos, os métodos tradicionais de PNL, como o cálculo da frequência das palavras, continuam sendo os principais em termos de métodos analíticos. Essas diferenças tornam necessário determinar os temas de pesquisa de

Machine Translated by Google

métodos analíticos para identificar oportunidades de pesquisa com base em comparações entre disciplinas. Como tal, esta seção analisa essas diferenças para lançar luz sobre o progresso atual da pesquisa em PNL e as oportunidades de pesquisa no campo da gestão.

4.1. Processamento de linguagem natural em contabilidade

4.1.1. Os estudiosos de

contabilidade de aplicação exploram principalmente diferentes fatores que afetam o desempenho da empresa, como o valor da empresa. Com o rápido desenvolvimento da Internet e das redes sociais, os clientes utilizam plataformas online para expressar as suas opiniões sobre empresas ou marcas (por exemplo, Twitter). Estas informações e os sentimentos que as acompanham podem afetar o comportamento de compra de outros clientes (Tang, 2018) e o comportamento de investimento dos investidores (Nguyen, Calantone, & Krishnan, 2019), o que pode influenciar o valor de uma empresa. Nesse processo, tipos de investidores e remetentes ou comentaristas de tweets apresentam mecanismos de influência diferenciados.
Por exemplo, investidores institucionais dedicados e quase-índices aumentam as suas participações acionárias em resposta a aumentos no sentimento positivo no tweet, mas os investidores transitórios diminuem as suas participações acionárias em resposta a aumentos no sentimento negativo. Além disso, os registros publicados pelas próprias empresas, como os registros 10-K, contêm informações sobre as atividades comerciais das empresas (Frankel, Jennings, & Lee, 2016), o que impacta a reação do mercado e pode, assim, prever o desempenho futuro das empresas. Os analistas que desempenham funções de intermediários de informações confirmaram e esclareceram os registros da empresa (por exemplo, teleconferências), levando os investidores a atribuir maior valor às novas informações nos relatórios dos analistas, quando os gestores enfrentam maiores incentivos para reter informações relevantes para o valor (Huang, Lehavy, Zang e Zheng, 2018).

4.1.2. Algoritmos de

classificação de abordagem, modelagem de tópicos e análise de sentimento são os métodos mais comumente usados em pesquisa contábil. Na classificação de textos, os métodos de aprendizagem supervisionada (por exemplo, SVR) permitem aos pesquisadores explorar a relação latente entre os registros por meio de exames de como palavras e frases específicas na Discussão e Análise Gerencial (MD&A) explicam os níveis de acumulação (Frankel et al., 2016) . Na modelagem de tópicos, LDA, ou classificação de textos em um número específico de tópicos, é o método de aprendizagem aplicado com mais frequência. Os pesquisadores de contabilidade definem o número do tópico com base nos padrões da PNL, como pontuação de perplexidade (Huang et al., 2018) ou interpretação gerencial dos registros, ou seja, contratar vários indivíduos com experiência em contabilidade ou financeira e agrupar manualmente os tópicos de LDA em categorias amplas (Dyer, Lang e Stice-Lawrence, 2017). A interpretação dos resultados do LDA verificou mudanças temáticas ao longo do tempo (Dyer et al., 2017), algumas das quais serviram para expandir e revisar certos conceitos. Por exemplo, para capturar as funções de descoberta e interpretação dos relatórios dos analistas, Huang et al. (2018) operacionalizaram o papel de descoberta como casos em que os analistas discutiram tópicos que receberam pouca ou nenhuma menção pelos gestores durante teleconferências e o papel de interpretação como casos em que os analistas discutiram tópicos de teleconferência em seus relatórios imediatos. Para a análise de sentimentos, a aplicação mais comum é examinar as atitudes e emoções dos clientes em relação a uma marca ou ao mercado, bem como a partilha desses sentimentos em plataformas de redes sociais (Tang, 2018). Além disso, os pesquisadores classificaram ainda mais as emoções com base no léxico sentimental ou em algoritmos para investigar os diferentes mecanismos de cada emoção. Para

Machine Translated by Google

por exemplo, Nguyen et al. (2019) capturaram oito tipos de emoções – alegria, confiança, surpresa, antecipação, tristeza, medo, repulsa e raiva – e identificaram as suas influências nas decisões de investimento e no valor da empresa dos investidores institucionais. Além disso, a plataforma de análise de mídia social Infegy Atlas e o Word-Emotion Association Lexicon do National Research Council Canada (NRC) são relativamente mais adequados para pesquisas contábeis, dado o significado específico dos nomes próprios em contextos contábeis.

Em conclusão, os estudiosos da contabilidade concentraram-se principalmente na função explicativa das características textuais dos relatórios anuais, anúncios e opiniões dos clientes publicados nas redes sociais, atendendo a tópicos, tom e sentimento. Os algoritmos mais frequentes aplicados por esses estudiosos incluem LDA e métodos de análise de sentimento.

4.2. Processamento de linguagem natural em finanças 4.2.1.

Aplicação Pesquisadores em finanças geralmente discutiram o efeito de previsão dos recursos linguísticos de notícias e anúncios em termos de tom, sentimento, frequência e caráter incomum (entropia) do fluxo de palavras na reação do mercado e nas vendas corporativas ou causalidade oposta (Calomiris & Mamaysky , 2019; Froot, Kang, Ozik e Sadka, 2017; Hender-shott, Livdan e Schürhoff, 2015). Além disso, investigaram as diferenças deste efeito de previsão a nível nacional através da divisão entre mercados desenvolvidos e emergentes (Calomiris & Mamaysky, 2019).

4.2.2. Abordagem

Algumas plataformas ou bancos de dados oferecem notícias divulgadas e ferramentas analíticas para auxiliar a análise dos pesquisadores de financiamento, como Thomson Reuters News Analytics (TRNA), o arquivo Thomson Reuters Machine Readable News e Reuters Data Feed (RDF). O RDF oferece um algoritmo da Reuters que identifica o grau de positividade, neutralidade e negatividade das palavras usadas em artigos pelas empresas para determinar o tom. No entanto, embora existam ferramentas emergentes que auxiliam na análise de sentimentos, muitos investigadores financeiros afirmam que um grande desafio na investigação em gestão é que a lista de palavras desenvolvida para a psicologia e a sociologia é inadequada para tal contexto. Em um esforço para alterar isso, T. Loughran e Mcdonald (2011) usaram a lista de palavras Harvard-IV-4 TagNeg (H4N) para reclassificar uma seleção de palavras negativas e desenvolver seis novas listas de palavras que refletem melhor o tom dos textos financeiros.

Concluindo, os tópicos de pesquisa na área financeira tendem a ser mais focados do que os de contabilidade, e os bancos de dados e plataformas existentes têm auxiliado os estudiosos na aplicação da PNL ao cálculo de construtos relacionados.

4.3. Processamento de linguagem natural em sistemas de informação 4.3.1.

Aplicação Dentro da disciplina de sistemas de informação, os temas mais investigados em relação à aplicação da PNL são a pesquisa organizacional e o comportamento do consumidor. Os estudos sobre organização abrangeram questões relativas ao investimento em P&D, inovação e muito mais. Demonstrou-se que novas ameaças de entrada na indústria de tecnologia da informação em rápida mudança têm impactos significativos na tomada de decisões das empresas, como no caso do investimento em P&D e nas características da indústria que diferenciam o mecanismo

Machine Translated by Google

(Pan, Huang e Gopal, 2019). Além disso, os investigadores provaram que as capacidades de análise de dados contribuíram para a inovação das empresas, uma descoberta que foi classificada como melhoria de processos e melhoria de novas tecnologias, ou inovação centralizada e inovação descentralizada (Wu, Hitt, & Lou, 2019; Wu, Lou e Hitt, 2019). Nas comunidades online, a comunicação interpessoal reflete a personalidade de um usuário e como ela pode influenciar a identificação de outros membros e como as semelhanças entre dois usuários podem acentuar o comportamento de compra (Adamopoulos, Ghose, & Todri, 2018; Hong & Pavlou, 2017) . As interações interpessoais entre os membros da comunidade permitem-lhes partilhar conhecimentos e estimular ideias inovadoras (Hwang, Singh, & Argote, 2019). Tais interações exigem primeiro a busca por informações específicas. Por exemplo, as preferências e os hábitos de pesquisa dos consumidores podem ser determinados através de palavras-chave, o que demonstra como a seleção e o design do motor de pesquisa são cruciais nas compras subsequentes e no comportamento de pesquisa dos consumidores e cruciais para a compreensão do desempenho da pesquisa (por exemplo, taxa de cliques) e da publicidade. desempenho (por exemplo, posição do anúncio)
(Ghose, Ipeirotis, & Li, 2019; Gong, Abhisek, & Li, 2018).

4.3.2. Abordagem

Os estudiosos de sistemas de informação aplicaram principalmente cinco categorias de PNL: métodos de pré-processamento de texto, representação de texto, classificação, modelagem de tópicos e aprendizagem profunda. No método de pré-processamento, classes gramaticais são aplicadas à identificação de substantivos, verbos ou adjetivos e a frequência da palavra resultante é usada para análise posterior. Os pesquisadores escolhem diferentes classes gramaticais de acordo com seus contextos de pesquisa, por exemplo, frases de avaliação (adjetivos e advérbios) para medir as características do serviço (Ghose, Ipeirotis, & Li, 2012) . Este método é frequentemente combinado com algoritmos de agrupamento ou classificação e codificação manual para extração de informações e melhoria da precisão.

Na representação de texto, a frequência de documento inversa de frequência de termo (TF-IDF) é o método mais comum para obter vetores de palavras e é frequentemente combinada com similaridade de cosseno para medir construções. Por exemplo, para determinar se as competências de um prestador de serviços correspondem aos requisitos do projeto, Hong e Pavlou (2017) aplicaram o TF-IDF para analisar perfis de utilizadores e descrições de projetos numa plataforma de outsourcing online. Eles então calcularam a similaridade de cosseno entre os dois documentos (perfil do provedor de serviços e descrição do projeto) para cada par projeto-provedor de serviços. Para capturar o grau de ameaça de novas entradas para um operador estabelecido, Pan et al. (2019) calcularam a pontuação de similaridade de cosseno entre as descrições de negócios das empresas usando o vetor de palavras ponderadas TF-IDF. Wang, Li e Singh (2018) detectaram semelhança funcional com base em descrições de aplicativos e avaliações de consumidores de cada aplicativo na App Store do iOS usando saco de palavras, TF-IDF e decomposição de valor singular (SVD), um algoritmo para resolver o problema da dispersão de dados em dados de alta dimensão. Bag-of-words é outro método frequentemente usado para medir características de palavras em documentos. Em termos de medição da inovação e dado o facto de que novas ideias podem ser detectadas através da mudança de vocabulário, Wu, Hitt, et al. (2019) aplicaram bag-of-words à identificação de termos de patentes em resumos de patentes coletados do NBER Patent Citation Data File. Os autores calcularam então a idade de cada palavra com base em quando ela apareceu pela primeira vez em domínios tecnológicos semelhantes para obter a “pontuação de novidade”.

Existem dois métodos principais para classificar textos: aprendizagem supervisionada e aprendizagem não supervisionada. Ghose et al. (2012) usaram um método de aprendizagem supervisionada para medir duas características do texto: legibilidade (por exemplo, complexidade textual, sílabas, ortografia

Machine Translated by Google

erros) e subjetividade – que provavelmente afetariam os esforços intelectuais dos consumidores na internalização do conteúdo das avaliações. Eles treinaram um classificador de modelo de linguagem dinâmica de 4 gramas fornecido pelo kit de ferramentas LingPipe para derivar a probabilidade de subjetividade nas avaliações dos clientes. Da mesma forma, Wang et al. (2018) agruparam o vetor de palavras de cada aplicativo com base no TF-IDF usando o algoritmo de agrupamento de Markov para identificar o original de aplicativos imitadores.

Além disso, é consenso geral que o LDA é adequado para estudos de sistemas de informação e, como tal, é comumente utilizado. Por exemplo, Adamopoulos et al. (2018) aplicaram vários métodos diferentes de PNL à análise de tweets, a fim de capturar tanto as personalidades dos consumidores (ou seja, semelhanças entre remetente e destinatário de mensagens boca a boca) quanto as características dos tweets. Alguns investigadores tentaram construir redes de informação dos indivíduos em plataformas de crowdsourcing baseadas na comunicação dos indivíduos (Hwang et al., 2019). Ghose et al. (2019) também calcularam a "Entropia do Tópico" com base no LDA para medir a complexidade do tópico textual.

Para quantificar a ambiguidade das palavras-chave, Gong et al. (2018) aplicaram LDA a um corpus construído usando resultados de pesquisa específicos de palavras-chave e posteriormente calcularam a entropia da distribuição de tópicos para cada palavra-chave.

A análise de sentimento foi por vezes combinada com a aprendizagem profunda porque o sentimento (positivo, negativo ou neutro) do corpus pode ser entendido como um problema de classificação. Além disso, foi demonstrado que mecanismos de análise de sentimento comercial disponíveis publicamente baseados em aprendizagem profunda (por exemplo, AlchemyApi) fornecem métricas mais ricas para capturar sentimentos textuais em comparação com outras métricas ingênuas (por exemplo, pontuações baseadas em léxico) (Adamopoulos et al., 2018) .

Além do pré-processamento de texto, representação de texto, classificação e análise de sentimento, a literatura em sistemas de informação também apresenta outras aplicações de PNL. Por exemplo, Adamopoulos et al. (2018) primeiro pré-processou tweets e outros conteúdos gerados pelo usuário e, em seguida, combinou esses vetores de palavras com o dicionário psicolinguístico Linguistic Inquiry and Word Count (LIWC) para calcular pontuações relativas que refletem a pontuação percentual para categorias específicas de personalidade. Em um esforço para compreender melhor o uso da linguagem pelos líderes, Johnson, Safadi e Faraj (2015) exploraram as postagens dos líderes de comunidades online em três comunidades – Blender Artists, Gearbox Software e North-ern Sounds – da perspectiva da morfologia, lexical, análise sintática e semântica. Além disso, Wu, Lou, et al. (2019) recorreram a currículos online escritos por funcionários atuais e anteriores para medir as capacidades de análise de dados de uma empresa.

Em suma, os tópicos de pesquisa em sistemas de informação que utilizam a PNL como método analítico abrangem os níveis organizacional e individual. Os métodos mais comuns em estudos de sistemas de informação são bag-of-words, TF-IDF e LDA, que geralmente são aplicados na extração de informações para construir medidas, como a personalidade do cliente, o sentimento do UGC, a capacidade de análise de dados das empresas. e inovação.

4.4. Processamento de linguagem natural em marketing

4.4.1. A pesquisa de

marketing de aplicação relevante para a PNL visa refinar a experiência do cliente, melhorar o desempenho de vendas e manter a reputação da marca. O comportamento dos clientes em relação à pesquisa e navegação online, à comunicação com outros utilizadores e à expressão de opiniões nas redes sociais são atividades acompanhadas de perto pelas empresas. A invenção dos smartphones permite aos usuários postar rapidamente breves linhas de texto e expressar emoções a qualquer momento em computadores comparados (Melumad, Inman, & Pham, 2019). Essas tecnologias encurtam a distância

Machine Translated by Google

entre pessoas, mesmo estranhos, e permitir a troca imediata de ideias, o que pode impulsionar a inovação e permitir que clientes individuais impactem ideias de produtos/serviços (Stephen, Zubcsek, & Goldenberg, 2016) . Além da inovação, as mídias sociais oferecem oportunidades para os clientes compartilharem sua experiência de compra ou uso, que contém informações valiosas sobre qualidade do produto, preço, promoção e serviço (Archak, Ghose, & Ipeirotis, 2011; Caldieraro, Zhang, Cunha, & Shulman , 2018; Dotzel e Shankar, 2019; Liu, Lee e Srinivasan, 2019; Liu, Singh e Srinivasan, 2016; Xiong e Bharadwaj, 2014). Os padrões e opiniões dos clientes ajudam as empresas a prever as vendas e a ajustar estratégias para estimular positivamente a procura, embora tenha sido observado que o feedback negativo dos clientes nas redes sociais pode tornar-se desastroso se uma empresa não detectar e reduzir os impactos adversos (Herhausen, Ludwig, Grewal, Wulf e Schoegel, 2019).

4.4.2. Abordagem A

diversidade de métodos de pesquisa é uma das preocupações mais importantes para os pesquisadores de marketing. Como tal, todos os seis principais métodos de PNL – pré-processamento de texto, representação de texto, classificação, modelagem de tópicos, análise de sentimento e aprendizagem profunda – são aplicados em estudos de marketing. No pré-processamento de texto, a classe gramatical ainda é o método mais frequentemente adotado para identificar características, por exemplo, características do produto (Archak et al., 2011). Ao combinar o método de agrupamento, os pesquisadores podem separar palavras e frases esparsas em um conjunto de frases semelhantes e, em seguida, extrair o “contexto” em que uma palavra específica aparece.

O método mais frequentemente usado na representação de texto é o bag-of-words, que é bem estabelecido e fácil de usar. Por exemplo, para fornecer implicações para o design de produtos internacionais, Hermosilla, Gutiérrez-Navratil e Prieto-Rodríguez (2018) confiaram no saco de palavras e na métrica de “semelhança de cosseno” para processar o “enredo resumido” e a “sinopse” da IMDb. ”Para medir a semelhança do enredo. Além disso, Liu et al. (2016) usaram n-gram para examinar a variedade de conteúdo nos Tweets.

Para classificação, a rotulagem é um grande desafio. Os académicos contrataram assistentes de investigação (Villarroel Ordenes et al., 2019) ou externalizaram estas tarefas online (Lee, Hos-anagar, & Nair, 2018), através de crowdsourcing através de sites como o Amazon Mechanical Turk.
Além disso, para melhorar a precisão dos métodos de aprendizagem, o modelo de aprendizagem conjunto — que inclui regressão logística, Naive Bayes e máquinas de vetores de suporte — é frequentemente aplicado para identificar um grande número de características de texto, como menção de marca, menção de produto, índice de legibilidade, e mais (Lee et al., 2018). Com exceção dos algoritmos regulares, algoritmos avançados surgiram no campo da ciência da computação e foram adotados ativamente por estudiosos de marketing. Por exemplo, Liu et al. (2016) usaram DynamicLMClassifier para medir o sentimento em tweets. No entanto, alguns estudos focaram mais no algoritmo de agrupamento sem dados rotulados. Este algoritmo de agrupamento aglomerativo hierárquico é o método mais popular em marketing para extrair características de empresas e produtos (Archak et al., 2011; Ghose et al., 2019). Hoje em dia, o módulo PNL está incorporado na maioria dos softwares empresariais. Por exemplo, Caldier-aro et al. (2018) utilizaram algoritmos de classificação e processamento linguístico fornecidos pelo software SPSS para identificar os principais conceitos que aparecem na descrição do empréstimo no Lending Club. Com base nestes conceitos, os autores utilizaram as seis principais categorias como variáveis fictícias para controlar variações no conteúdo da descrição do empréstimo.

Enquanto isso, o LDA ainda é o algoritmo básico na modelagem de tópicos. Rutz, Sonnier e Trusov (2017) adotaram bag-of-words e LDA para capturar o conteúdo de anúncios de texto para obter uma melhor compreensão das percepções e do desempenho dos anúncios de busca pagos. Além

Machine Translated by Google

estudos de gerenciamento de mensagens online, Dotzel e Shankar (2019) aplicaram dois tópicos métodos de modelagem - LDA e o modelo de tópico correlacionado (CTM) - para medir o qualidade das inovações.

Existem dois métodos principais na análise de sentimento: o baseado em léxico método e algoritmo. No campo do método léxico, baseado na Investigação Linguística e Dicionários de mineração de texto de contagem de palavras (LIWC) e o analisador de sentenças e dependências gramaticais de Stanford. Herhausen et al. (2019) calcularam a proporção de palavras associadas a emoções negativas em postagens do Facebook para identificar e medir a intensidade de alta e baixa excitação para cada postagem negativa. Para fazer isso, eles usaram dicionários LIWC existentes para medo/ansiedade, raiva e tristeza, e desenvolveram um novo dicionário para localizar nojo, a fim de calcular uma pontuação de intensidade de acordo com o mencionado acima. categoria de palavra emoção. E, para algoritmos, Dotzel e Shankar (2019) aplicaram uma algoritmo de análise de sentimento – tidytext – para capturar o sentimento geral dos anúncios de inovação. Para combinar as vantagens de ambas as abordagens, vários pesquisadores conduziram análises abrangentes de sentimento de análises de produtos (Ordenes, Ludwig, De Ruyter, Grewal, & Wetzels, 2017), mensagens de mídia social (Melumad et al., 2019) e buzz online para videogames (Xiong & Bharadwaj, 2014). Os métodos usados continham: análise de sentenças e dependência gramatical de Stanford, SentiStrength, investigação linguística e contagem de palavras (LIWC) e sistemas de monitoramento de sentimentos de mídia social Scout-tlab/Lithium.

Com o rápido desenvolvimento do aprendizado profundo para garantir alta precisão, muitos pesquisadores introduziram esses algoritmos na PNL. Por exemplo, Liu et al. (2019) combinou dados rotulados e aprendizado profundo do Amazon MTurkers – Convolucional Redes Neurais (CNN), Rede Neural Recorrente (RNN) e Memória Longa e de Curto Prazo (LSTM) — para capturar as informações de qualidade e preço dos produtos. Além disso, Hu, Dang e Chintagunta (2019) analisaram a qualidade dos negócios do Groupon com base nos dados rotulados do MTurkers e em um modelo da CNN.

Finalmente, alguns estudos não destacaram especificamente os algoritmos que utilizaram. Para por exemplo, com base no boca a boca dos clientes no Facebook e no Twitter, Kumar, Bhaskaran, Mirchandani e Shah (2013) mediram o índice de viscosidade, definido como uma matriz do grau em que um usuário ou uma instância de boca a boca é específico para cada categoria de tópicos. Eles fizeram isso para identificar a proximidade de outras palavras-chave, como “sobremesa”, “sundae” e “comida” estão associados a uma palavra-chave focal como “gelo creme." Da mesma forma, examinar a inspiração entre os clientes em relação à geração de novas ideias, Stephen et al. (2016) quantificaram a similaridade de pares de ideias no nível de conceito baseado na etapa de pré-processamento na PNL.

Para concluir, os estudiosos de marketing aplicaram uma ampla variedade de algoritmos aos seus estudos, como classe gramatical, conjunto de palavras, métodos de classificação e algoritmos de aprendizagem profunda.

4.5. Processamento de linguagem natural em estratégia

4.5.1. Aplicativo

Os estudos de gestão estratégica têm se concentrado principalmente em startups e empresas maduras. Para os novos participantes, é fundamental traçar estratégias sobre como se posicionar de maneira ideal dentro mercados de produtos. Barlow, Verhaal e Angus (2019) propuseram que o ponto de entrada idealmente distinto está em um alto nível de similaridade exemplar (a categoria mais saliente membro ou um claro líder de mercado) e um baixo nível de similaridade de protótipo (o mais

Machine Translated by Google

membro representativo em uma categoria de mercado). A falta de experiência em gestão é outra característica proeminente dos empreendedores iniciantes. Descobriu-se que os conselhos oferecidos pelos seus pares influenciam o desempenho da sua startup (Chatterji, Delecourt, Hasan, & Koning, 2019). Para as empresas maduras, é urgente alcançar a inovação para obter vantagem competitiva. Para este efeito, os investigadores analisaram dois factores-chave da inovação, ou seja, até que ponto as organizações empreendedoras devem procurar melhorar as suas hipóteses de sucesso (Angus, 2019) e como as organizações devem combinar o conhecimento distante ou diversificado que reúnem em criatividade (Kaplan & Vakili, 2015).

4.5.2. Abordagem

Os pesquisadores em estratégia geralmente aplicam o índice de cálculo da PNL à medição de conceitos. Por exemplo, Barlow et al. (2019) aplicaram a PNL para limpar descrições de aplicativos e calcular a medição de dois conceitos – similaridade de protótipo e similaridade exemplar. Angus (2019) usou similaridade básica de cosseno em PNL para medir a distância entre as descrições de texto do primeiro e do segundo aplicativo de um desenvolvedor na Google Play Store. Chatterji et al. (2019) contaram a proporção de palavras de gestão em relação às palavras que descrevem o produto, tecnologia ou cliente após serem atribuídas a gestores com estilos formais ou informais para capturar a abordagem de aconselhamento. Kaplan e Vakili (2015) usaram modelagem de tópicos para extrair 100 tópicos do resumo do documento do USPTO. Para identificar se as patentes se originaram como ideias novas, eles selecionaram todas as patentes acima de um limite, que foi determinado por três codificadores especialistas e ponderado por tópico, bem como a exigência de que elas aparecessem nos primeiros 12 meses de formação do tópico (com base na data do pedido).

Em suma, uma das questões que mais preocupa os estudiosos da gestão estratégica é como fazer uma estratégia apropriada para obter vantagem competitiva. A estratégia é capturada principalmente por meio de modelagem de tópicos e análise de sentimento.

4.6. Processamento de linguagem natural na gestão de operações

4.6.1. Aplicação

Pesquisadores na área de gerenciamento de operações aplicaram vários métodos de PNL em uma ampla gama de tópicos, como gerenciamento de produtos, eficiência operacional, gerenciamento de estoque e previsão de vendas.

4.6.2. Abordagem

Jain, Girotra e Netessine (2014) combinaram algoritmos de reconhecimento de padrões de texto e inspeção manual para extrair informações fornecidas dos formulários de conhecimento de embarque brutos e não processados para cada transação de importação. Ko, Mai, Shan e Zhang (2019) rastrearam dados de avaliações médicas do Vitals (http://www.vitals.com) medir a importância das dimensões de qualidade técnica e interpessoal para os pacientes. Cui, Gallino, Moreno e Zhang (2018) usaram a valência, bem como a informatividade e o sentimento dos comentários do Facebook para medir o endosso. A informatividade foi determinada pelo número de palavras, sentenças e palavras únicas em um comentário. Como os comentários nas redes sociais são geralmente curtos e escritos por usuários heterogêneos, a simples análise de sentimento não pode classificá-los com precisão. Como tal, os autores

Machine Translated by Google

adotou a rede de tensores neurais recursivos (RNTN) no topo do corpus Stanford Senti-ment Treebank para classificar cada comentário em categorias de positivo, negativo ou neutro. Hoberg e Phillips (2018) analisaram as descrições de negócios em registros 10-K para capturar como a linguagem do produto se sobrepõe em diferentes níveis (em toda a indústria, dentro da indústria, entre indústrias). Eles formaram vetores de palavras para cada empresa com base no texto da descrição do produto de cada empresa e omitiram palavras comuns que são usadas por mais de 25% de todas as empresas. A similaridade de cosseno para vetores de duas palavras foi então calculada para medir semelhanças na linguagem entre setores e dentro do setor.

Essencialmente, as questões e aplicações da PNL na pesquisa de OM são diversas. Além da análise tradicional de frequência de palavras, a pesquisa OM também utilizou algoritmos de aprendizagem profunda para classificação de texto.

4.7. O processamento de linguagem natural em outras disciplinas de gestão

A PNL permite que os estudiosos analisem eventos políticos. Por exemplo, Berman, Melumad, Humphrey e Meyer (2019) examinaram tweets publicados durante e logo após quatro debates principais que antecederam as eleições presidenciais dos EUA de 2016 para compreender como o tweet evolui, nomeadamente em termos de mudanças no estilo linguístico, conteúdo tópico, e detecção robótica durante eventos políticos significativos. Num outro estudo, Srivastava, Goldberg, Manian e Potts (2018) analisaram mensagens eletrónicas trocadas entre funcionários a tempo inteiro para medir a adequação cultural. Eles usaram o LIWC para medir o estilo linguístico e combinaram essas categorias linguísticas com a divergência de Jensen-Shannon (JS) para calcular o ajuste cultural. Oettl (2012) usou o reconhecimento em artigos de imunologia para medir a ajuda dos cientistas aos outros. O autor aplicou algoritmos de identificação de nomes propostos por Councill, Giles, Han e Manavoglu (2005) para discernir aqueles que alcançaram o que chamaram de “estrela da utilidade ”.6 Além disso, a análise semântica latente permitiu a Tuertscher, Garud e Kumaraswamy (2014) para explorar a prevalência de justificativas em documentos produzidos por cientistas do AToroidal LHC Apparatus (ATLAS). Eles testaram a relação entre justificação e partilha de conhecimento no ATLAS, um sistema tecnológico complexo desenvolvido no CERN (Conseil Européenn pour la Recherche Nucléaire), Genebra. Para capturar a evolução da percepção de expertise ao longo do tempo, Croidieu e Kim (2018) adotaram LDA para extrair 98 tópicos e rotularam manualmente esses tópicos brutos em códigos descritivos, conceitos de primeira ordem, depois temas de segunda ordem, e desenvolveram quatro dimensões agregadas para legitimação de expertise.

4.8. Comparações interdisciplinares e oportunidades de pesquisa Ao

revisar a literatura relevante em todas as áreas de gestão, descobrimos que os sistemas de informação e os estudos de marketing analisam dados de múltiplas fontes, como mídias sociais, análises on-line e anúncios de empresas. Os dados são coletados em diferentes níveis, desde a opinião do cliente até o comportamento da empresa. Os conjuntos de dados utilizados por estudos em contabilidade, estratégia e gestão de operações são relativamente limitados, concentrando-se principalmente em documentos emitidos por empresas.

A reação do mercado é a concentração de estudos financeiros utilizando a técnica de PNL. Descobrimos que métodos analíticos, classificação, modelagem de tópicos e análise de sentimento são frequentemente usados em cada campo de pesquisa. Esses algoritmos tradicionais permitem que os estudiosos explorem temas, semelhanças e diferenças entre documentos e a orientação sentimental dos textos. No entanto, o aprendizado profundo, um método avançado de PNL

Machine Translated by Google

para a mineração completa do texto, foi aplicado apenas em sistemas de informação e estudos de marketing. Em termos de referencial teórico, quase todos os estudos na área da informação
Os campos de sistemas, gestão de operações e marketing adotam teorias de gestão existentes para explicar o modelo de pesquisa e justificar contribuições teóricas. No entanto, para
Nas áreas de contabilidade, finanças e estratégia, continua a haver falta de atenção à utilização e contribuição para as teorias existentes.

A análise da literatura passada em todas as disciplinas também fornece um caminho para conduzir Pesquisa em PNL na área de gestão. Para a contabilidade, um problema importante é o processamento impreciso de termos específicos nos registros contábeis, como “impostos” ou “passivos”.
Em estudos anteriores, essas palavras geralmente foram tratadas com orientação sentimental em análise de sentimento ou léxico, ambos os quais não estão em conformidade com o contexto da pesquisa. Portanto, os pesquisadores contábeis podem usar o aprendizado profundo para identificar esses termos em melhorando a precisão algorítmica. Em vez de depender de bases de dados ou plataformas existentes, o financiamento dos investigadores pode recorrer a métodos ou léxicos recentemente propostos que são mais adequados para seus cenários de pesquisa. Da mesma forma, os estudiosos de sistemas de informação e de marketing podem assumir o papel de precursores na exploração da PNL como forma de enriquecer teorias tradicionais de gestão. Para a pesquisa em estratégia, a chave para a adoção da PNL para a extração de informações precisas é construir regras de associação entre textos e estratégias. A aprendizagem profunda é uma forma viável de fazer isso, pois permite a extração e análise de textos relevantes para capturar estratégias. Por fim, vale mencionar aqui que, devido a uma grande variedade de tópicos de pesquisa em estudos de gestão de operações, o sucesso da aplicação da PNL depende da escolha do método. Encontrar métodos analíticos relevantes e eficazes na pesquisa em gerenciamento de operações exige que os estudiosos consultem à literatura de outras áreas com temas de pesquisa relevantes.

5. Métodos e kits de ferramentas de processamento de linguagem natural

Dadas as abundantes oportunidades de pesquisa para estudiosos de administração utilizarem a PNL para gerar descobertas, um tutorial passo a passo sobre como executar a PNL é fundamental. Esse seção aborda essa necessidade revisando as metodologias de PNL usadas com mais frequência em pesquisa, incluindo técnicas necessárias para converter texto em representações legíveis por máquina, bem como procedimentos para extrair a informação textual incorporada modelagem e análises subsequentes. O objetivo desta seção é apresentar as técnicas disponíveis, os pacotes usados com frequência e as vantagens e desvantagens de cada um. método.

Em geral, o processo de PNL pode ser dividido em quatro partes: pré-processamento de texto, representação de texto, treinamento de modelo e avaliação de modelo. O pré-processamento de texto visa obter um texto “limpo” para melhorar a eficiência e precisão do seguinte análise removendo símbolos sem sentido, verificando erros ortográficos, tokenização, Marcação de PDV, remoção de palavras irrelevantes e lematização. Depois de pré-processar o texto, os pesquisadores devem escolher a melhor forma de representar as palavras em tipos que possam ser efetivamente e calculado com precisão por computadores. A representação de texto converte palavras em números, que sempre serão vetor ou matriz nesta etapa. Com base nestas palavras vetores, é possível aplicar algoritmos - como classificação, análise de sentimento, e extração de tópicos, etc. - para treinar um modelo com o objetivo de resolver o problema real problema. Depois de treinar o modelo, os pesquisadores precisam avaliar o modelo para garantir que tenha generalização ideal para outros corpora. A Figura 5 demonstra um fluxograma que descreve as etapas de condução da PNL.

Machine Translated by Google

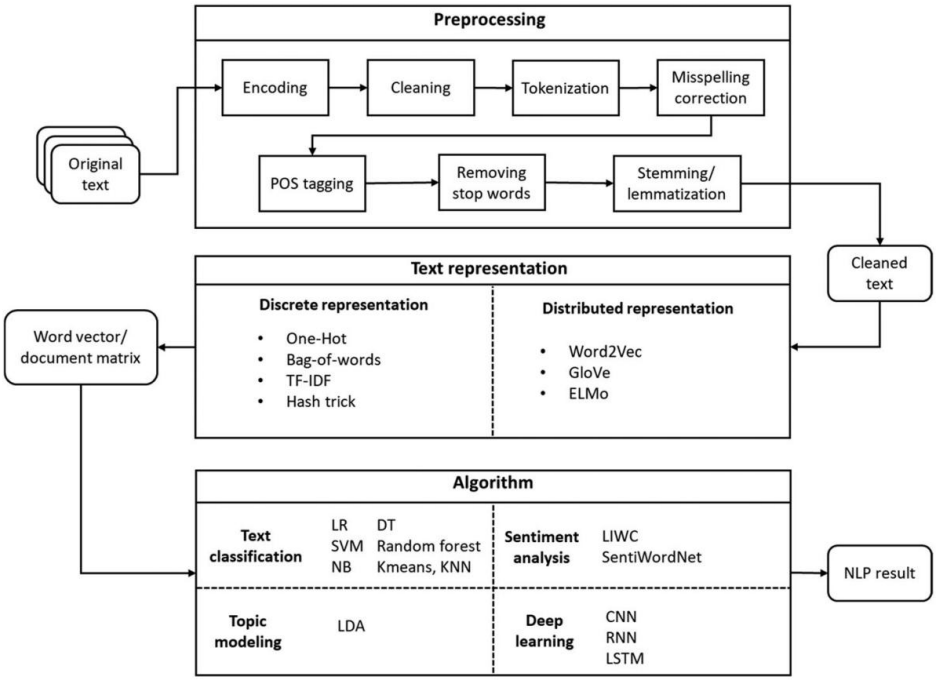

Figura 5. Fluxograma da PNL.

5.1. Pré-processamento

5.1.1. Codificação A

primeira etapa da PNL é a leitura dos dados para análise posterior. Porém, mesmo em inglês, um desafio recorrente é o manejo da codificação de caracteres. Para resolver esse problema, os pesquisadores podem primeiro escrever o script em UTF-8. Se as configurações de codificação forem ignoradas, o carregamento direto dos dados falhará devido à codificação padrão do Windows. É importante certificar-se de que cada arquivo esteja no formato de codificação “correto”. As configurações de codificação podem ser facilmente alteradas em arquivos txt antes de lê-los.

5.1.2. Limpeza

Recentemente, muitos pesquisadores rastrearam textos de vários sites (por exemplo, Twitter, Facebook, TripAdvisor.com, etc.). Esses dados geralmente contêm tags HTML e informações não textuais, como imagens e emojis, que devem ser limpas ou removidas do conjunto de dados. Dada a abundância de dados online e a irregularidade das informações a serem removidas, a limpeza é um processo muito complicado. Alguns pacotes em Python, como pattern.web, podem ser aplicados para remover tags HTML. Além disso, a combinação de beautifulsoup e expressão regular em Python também pode ser usada para reconhecer e remover tags. No entanto, as necessidades de limpeza podem depender da finalidade da análise, das imagens e de outras informações não textuais que devem ser retidas. Por exemplo, alguns investigadores prestaram atenção explícita aos emoticons para enriquecer os dicionários de sentimentos (Lee et al., 2018; Ordenes et al., 2017). Nesta etapa do processo, os pesquisadores devem estar atentos e remover frases que sejam

Machine Translated by Google

gerados automaticamente por computadores que podem ocorrer dentro do texto (por exemplo, “HTML”). Ao fazer isso, os pesquisadores podem manter o texto exato que desejam usar para análise na pesquisa.

5.1.3. Tokenização

A tokenização é o processo de dividir o texto em unidades, geralmente na forma de palavras e frases. Ao tokenizar, os delimitadores que definem um token (espaço, ponto, ponto e vírgula, etc.) precisam ser determinados. Por exemplo, em inglês, o espaço é usado para determinar uma palavra. Existem muitos pacotes de tokenização em Python que oferecem procedimentos inteligentes de tokenização, por exemplo, NLTK e StanfordCoreNLP. Independentemente disso, os pesquisadores são aconselhados a prestar muita atenção aos casos específicos dos corpora textuais. Por exemplo, ao analisar os registros 10-K das empresas, geralmente é necessário codificar o nome da empresa antes da tokenização.

5.1.4. Correção de erros ortográficos

O processo de detecção de erros ortográficos geralmente consiste em uma verificação, seja por meio de uma string de entrada como um índice válido ou uma palavra de dicionário, e a correção de erros ortográficos. A pesquisa de N-gram e de dicionário são duas técnicas bem conhecidas de detecção de erros ortográficos. Para algoritmos de correção ortográfica, os mais estudados são distância de edição, chaves de similaridade, técnicas baseadas em regras, técnicas baseadas em n-gramas, técnicas probabilísticas e redes neurais. A maioria dos pacotes de mineração de texto possui corretores ortográficos pré-empacotados que podem ajudar a corrigir erros ortográficos (por exemplo, o PyEnchant). Ao usar esses soletradores, os pesquisadores devem estar cientes do idioma específico do domínio que pode não aparecer no soletrador ou que o soletrador pode “corrigir” incorretamente.

5.1.5. Marcação POS A

marcação POS é um acrônimo para marcação de classe gramatical, um processo de anexar cada palavra em uma frase a uma tag adequada de um determinado conjunto de tags (por exemplo, N representa substantivo, ADJ representa adjetivo, ADV representa verbo, etc.) de acordo com a definição, contexto e classe gramatical. Um exemplo poderia ser a relação entre palavras adjacentes ou relacionadas em uma frase, sentença ou parágrafo. Alguns corpora marcados podem ser facilmente aplicados em pesquisas de gestão, como NLTK e Pattern em Python. Na pesquisa em gestão, alguns pesquisadores analisaram apenas substantivos e verbos com a ajuda desta técnica (Pan et al., 2019; Wang et al., 2018).

5.1.6. Removendo palavras

irrelevantes Palavras irrelevantes são palavras de ocorrência frequente em uma linguagem natural que carregam muito pouco ou nenhum contexto semântico significativo em uma frase e são desnecessárias para certas aplicações de PNL, como “a” e “the” em inglês. Ferramentas comuns de PNL (por exemplo, NLTK em Python) que contêm listas predefinidas de tais palavras irrelevantes podem ser aplicadas para remover essas palavras. Além disso, os pesquisadores podem baixar listas online de palavras irrelevantes e alterá-las de acordo com seus objetivos de pesquisa. Por exemplo, é sensato adicionar palavras comuns e específicas de domínio a estas listas, por exemplo, nomes de marcas num corpus de tweets sobre a marca.

Machine Translated by Google

5.1.7. Lematização/lematização

Lematização é o processo de redução das palavras em formas flexionais - palavras geralmente significativas - para formas gerais. Stemming refere-se a extraído radical de palavra ou formas de raiz que não podem necessariamente expressar semântica completa pensamento. Stemming é frequentemente aplicado na recuperação de informações para recuperação estendida. Na aplicação, também existem diferentes ênfases. Enquanto isso, a lematização é aplicado principalmente em mineração de texto e PNL e é usado para processos mais refinados e mais análise e expressão precisa de texto, por exemplo, tradução automática. Existem vários lematizadores predefinidos na maioria das ferramentas de mineração de texto, por exemplo, WordNet, SpaCy e Snow-ball em Python.

5.2. Representação de texto

Embora o pré-processamento permita dados de texto – dados não estruturados que são convertidos em dados estruturados – ainda é necessário ter métodos eficazes para representação de documentos. Esses métodos são necessários para análises de texto mais avançadas, como extração de informações, análise de sentimento, classificação de texto e muito mais. Apenas desta maneira os computadores podem “entender” o texto.

As duas representações mais comuns de texto incluem representação discreta e representação distribuída. A codificação One-Hot é tradicional e básica representação característica de uma palavra. Este método representa uma palavra como um vetor cuja dimensão é o comprimento de um texto gerado através de um corpus em que a posição da palavra atual tem valor 1 e a posição do restante é 0. O Dict-Vectorizer do scikit-learn (sklearn) em Python pode ser aplicado para obter esse tipo de texto vetorizado. No entanto, o One-Hot não consegue medir a relação entre palavras diferentes e a importância das palavras. Além disso, a matriz do documento é esparso, o que desperdiça uma grande quantidade de recursos de computação e armazenamento. Alternativamente, bag-of-words (BOW) é usado para formar um vetor que representa um documento usando a contagem de frequência de cada termo no documento. Sklearn em Python também oferece CountVectorizer para gerar rapidamente matrizes de documentos. Infelizmente, o O esquema de representação BOW tem suas próprias limitações: (1) alta dimensionalidade de a representação; (2) perda da relação semântica que existe entre os termos em um documento; e (3) interferência de palavras comuns com alta frequência de palavras. O termo frequência de documento inversa de frequência (TF-IDF) aborda o terceiro fraqueza. TF é a frequência com que uma palavra aparece no documento e IDF representa a proporção do texto que contém determinada palavra no corpus. Equação (1) é a fórmula clássica do TF-IDF usada para representação de texto. $w_{i,j}$ é o peso para a palavra i no documento j, $tf_{i,j}$ é a frequência da palavra i no documento j, df_i é o frequência documental do termo i em todo o corpus, e N é o número de documentos no corpus. TfidfVectorizer e a combinação de CountVectorizer e TfidfTransformer no sklearn pode ser usado para gerar matrizes de documentos TF-IDF. Um grande problema do TF-IDF semelhante ao do One-Hot e do BOW é o alto dimensionalidade das matrizes de documentos, ou o tamanho de todo o vocabulário em todo o conjunto de dados, o que resulta em cálculos enormes.

$$w_{i,j} = tf_{i,j} \times \log \frac{N}{df_i} \tag{1}$$

Machine Translated by Google

Hash Trick, o algoritmo de redução de dimensão de texto mais comum, pode ser usado para resolver o problema de alta dimensionalidade mencionado acima. O texto resultante após a redução da dimensão do hash trick não pode mais ser considerado um representante do texto original em termos de significado. Portanto, desde que o vetor do corpus não seja muito grande, é mais adequado usar os três métodos acima. Como esses métodos são altamente explicativos, saberemos qual palavra corresponde a cada característica unidimensional e a partir daí poderemos modificar o peso de cada palavra para melhorar ainda mais a representação do texto. Se o conjunto de dados for de grande escala, o Hash Trick pode melhorar a velocidade de geração de vetores para que os vetores após a redução da dimensionalidade ainda possam ajudar na conclusão da classificação e agrupamento. No HashingVectorizer do sklearn, o algoritmo baseado em um truque de hash assinado é implementado.

A ideia chave da representação distribuída é que o significado de uma palavra é dado de acordo com as palavras que aparecem frequentemente nas proximidades. Word2Vec utiliza as informações de contexto da palavra, portanto a informação semântica é mais rica e o vetor de palavras treinado é de baixa dimensão e denso. Gensim em Python oferece o método word2vec para treinar o modelo. Os pesquisadores podem escolher corpora apropriados para treinar a incorporação de palavras de acordo com seus contextos de pesquisa. Word2Vec é baseado em Cbow/Skip-Gram, um método de janela de contexto local que não consegue reter o relacionamento geral entre palavras, o que muitas vezes resulta em muito peso em vocabulário de alta exposição.

Porém, o Global Vector (GloVe) combina as estatísticas globais da Análise Semântica Latente (LSA) e a janela de contexto local, incorporando informações estatísticas globais a priori que podem acelerar o treinamento do modelo e controlar o peso relativo das palavras. ELMo é um novo tipo de representação de palavras profundamente contextualizada que modela as características complexas das palavras (como sintaxe e semântica) e as mudanças nas palavras no contexto da linguagem (ou seja, modelagem de palavras polissêmicas).

Ao contrário do Word2Vec, o objetivo principal do ELMo é treinar um modelo de linguagem completo e usar esse modelo para processar o texto que precisa ser treinado. A partir daí, ele gera um vetor de palavras correspondente. Desta forma, diferentes vetores de palavras podem ser gerados em diferentes sentenças para a mesma palavra no ELMo.

5.3. Modelagem

Nesta seção, revisamos algoritmos e modelos comuns que têm sido aplicados em estudos de gestão, a fim de inspirar estudiosos de administração a integrar esses modelos na pesquisa de gestão de forma adequada.

5.3.1. Classificação de texto A

maioria dos métodos de aprendizado de máquina foi aplicada na área de classificação de texto, em oposição a outras áreas. Esses métodos se enquadram em duas categorias: aprendizagem supervisionada e aprendizagem não supervisionada. A rotulagem de dados é um grande desafio na aprendizagem supervisionada. Os pesquisadores podem baixar conjuntos de dados rotulados ou realizar uma pesquisa no Amazon MTurk para terceirizar a rotulagem de dados (Ghose et al., 2019; Wang et al., 2018). Os algoritmos de aprendizagem supervisionada mais populares são Regressão Logística (LR), Máquina de Vetores de Suporte (SVM), Naïve Bayes (NB), Árvore de Decisão (DT) e Floresta Aleatória. Precisão, recall, F1, AUC e ROC são comumente usados para comparar o desempenho de diferentes algoritmos para que os pesquisadores possam escolher o algoritmo que funciona melhor para seus propósitos. Kmeans e K-Nearest-Neighbour (KNN) são os mais

Machine Translated by Google

algoritmos de cluster não supervisionados frequentemente usados. Embora não haja necessidade de rotular os dados antes do treinamento, a interpretação dos resultados do agrupamento costuma ser difícil. Como os algoritmos de agrupamento geralmente são calculados com base na distância entre os vetores, os resultados calculados a partir desses algoritmos diferem daqueles gerados a partir da análise lógica dos pesquisadores. Esta discrepância leva a uma situação em que palavras irrelevantes na análise lógica aparecem na mesma categoria. Os pesquisadores devem ser pacientes na identificação de padrões nos resultados. Sklearn em Python fornece vários tipos de algoritmos de classificação e agrupamento.

5.3.2. Análise de sentimento

Os métodos de classificação mencionados acima também podem ser aplicados na análise de sentimento se o conjunto de dados contiver rótulos de sentimento. Outra forma de capturar o sentimento de um documento ou frase é o léxico. Cada palavra recebe uma pontuação de sentimento no dicionário e a soma de todas as palavras em uma frase ou documento é a pontuação final de sentimento para a frase ou documento em questão. Os léxicos mais populares são o dicionário psicolinguístico Linguistic Inquiry and Word Count (LIWC), SentiWordNet, MPQA Subjectivity Cues Lexicon, General Inquirer e Bing Liu Opinion Lexicons.

5.3.3. Modelagem de

tópicos A modelagem de tópicos imita o processo de geração de dados em que o redator escolhe um tópico sobre o qual escrever e, em seguida, escolhe palavras para expressar esses tópicos. Os tópicos são definidos como distribuições de palavras que comumente ocorrem simultaneamente e, portanto, têm uma certa probabilidade de aparecer em um tópico. Um documento, então, é descrito como uma mistura probabilística de tópicos. A ferramenta mais utilizada para modelagem de tópicos é a alocação latente de Dirichlet (LDA), pois pode ser facilmente realizada com a ajuda do gensim em Python. A saída do LDA são os tópicos e as palavras-chave correspondentes. O número de tópicos e palavras-chave fica por conta dos usuários.

5.3.4. Aprendizado

profundo Com o rápido desenvolvimento do aprendizado profundo e do big data, alguns algoritmos de aprendizado profundo são aplicados na classificação de texto, como CNN, RNN, rede neural BP, LSTM e muito mais.

5.4. Avaliação do modelo

O modelo treinado precisa ser avaliado antes de ser implementado na análise de gestão para garantir que o modelo seja adequadamente generalizável para o corpus. Esses índices de avaliação auxiliam os pesquisadores na escolha do modelo mais adequado para seus contextos de pesquisa. O que se segue é uma breve análise dos indicadores utilizados com mais frequência Tabela 1.

Para algoritmos de classificação, a taxa de erro, exatidão, precisão, recall, pontuação F1, ROC e AUC são úteis para medir o desempenho. A taxa de erro é a proporção entre o número de amostras classificadas incorretamente e o número total de amostras. A precisão é a proporção entre o número de amostras classificadas corretamente e o número total de amostras. Para missões de classificação binária, precisão, recall e pontuação F1 podem ser

Machine Translated by Google

Tabela 1. Resumo de pesquisas gerenciais que aplicam processamento de linguagem natural (PNL).

		Modelo				
	Dados	Algoritmo Categoria	Algoritmo	Papel	Teoria	Oportunidades
Contabilidade	. Arquivos 10-K Dyer et al. (2017); Frankel et al. (2016) . Chamada de conferência Huang et al. (2018) . Mídia social Nguyen et al. (2019); Tang, (2018)	Classificação SVR Modelagem de Tópicos LDA Sentimento Análise	Léxico	Frankel et al. (2016) Dyer et al. (2017); Huang et al. (2018) Nguyen et al. (2019); Loughran e McDonald (2011)	. Teoria da psicologia Nguyen et al. (2019)	. Adote métodos de aprendizagem profunda para "entender" os termos e registros contábeis
Finança	. Notícias Calomiris & Mamaysky (2019); Hendershott et al. (2015) . Anúncio Froot et al. (2017)	Classificação Sentimento Análise	Algoritmo de detecção da comunidade Louvain Léxico Reuters algoritmo	Calomiris e Mamaysky (2019) Calomiris e Mamaysky (2019); Froot et al. (2017) Hendershott et al. (2015)	N / D	. Estenda o método analítico
Informação Sistemas	. Plataforma online Adamopoulos et al., (2018); Hong & Pavlou, (2017); Hwang et al. (2019); Johnson et al. (2015) . Loja de aplicativos Wang et al. (2018) . Patente Wu, Hitt et al. (2019) . Retomar	Pré-processando Texto representação Classificação	Parte do discurso Ghose et al. (2019) Saco de palavras Wu, Hitt, et al. (2019); Wang et al. (2018) TF-IDF Classificador Agrupamento	Hong e Pavlou (2017); Pan et al. (2019); Wang et al. (2018) Ghose et al. (2019) Ghose et al. (2019); Wang et al. (2018)	. . . . A teoria da similaridade interpessoal desenvolvida por Adamopoulos et al. (2018) . Teoria da sinalização Hong & Pavlou (2017) . Teoria do raciocínio analógico Hwang et al. (2019) . Liderança funcional teoria, teoria da troca líder-membro, teoria da liderança compartilhada,	. Combine a PNL com teorias de gestão

Machine Translated by Google

	Wu, Hitt et al. (2019); Wu, Lou e outros. (2019) . Motor de busca Gong et al. (2018)	Modelagem de Tópicos LDA		Adamopoulos et al. (2018); Hwang et al. (2019); Ghose et al. (2019); Gong et al. (2018)	a comunicação como constitutiva da teori organizadora Johns . Estrutura de pesquisa s ideal Ghose et al. (2019) . Teoria da busca econômica Gong et al. (2018)	
		Aprendizado profundo	Alchemyapi	Adamopoulos et al. (2018)		
Marketing	. Mídia social Lee et al. (2018); Herhausen et al. (2019); Hermosilla et al. (2018); Kumar et al. (2013); Melumad et al. (2019); Villarroel Ordenes et al. (2019); Liu et al. (2016); Xiong e Bharadwaj (2014) . Revisão online Archak et al. (2011); Ghose et al. (2012); Ordens et al. (2017); Liu et al. (2019) . P2P Caldieraro et al., (2018) . Anúncio Dotzel e Shankar (2019)	Pré-processando	Parte do discurso	Archak et al. (2011); Ghose et al. (2012)	. Teoria da contra-sinalização Caldieraro et al. (2018) . Visão baseada em recursos Dotzel e Shankar (2019) . Teoria da regulação emocional Herhausen et al. (2019) . Teoria do traço difuso Melumad et al. (2019) . Teoria da utilidade aleatória Rutz et al. (2017) . Sabedoria das multidões, sociologia organizacional e redes, perspectiva de brainstorming Stephen et al. (2016) . Teoria do mercado eficiente Xiong e Bharadwaj (2014)	. Combine a PN com teorias de gestão
			Saco de palavras	Hermosilla et al. (2018); Rutz et al. (2017)		
		Representação de texto	N-grama	Liu et al. (2016)		
		Classificação	Classificador	Villarroel Ordenes e outros. (2019); Lee et al. (2018); Liu et al. (2016); Caldieraro et al. (2018)		
			Agrupamento	Archak et al. (2011); Ghose et al. (2012)		
		Modelagem de Tópicos LDA		Rutz et al. (2017); Dotzel e Shankar (2019)		
			CTM	Dotzel e Shankar (2019)		
		Sentimento Análise	Léxico	Herhausen et al. (2019)		
			Algoritmo	Dotzel e Shankar (2019)		
		Aprendizado profundo	CNN, RNN, LSTM	Liu et al. (2019); Hu et al. (2019)		

(Contínuo)

Machine Translated by Google

Tabela 1. Continuação.

	Dados	Modelo			Teoria	Oportunidades
		Algoritmo Categoria	Algoritmo	Papel		
Estratégia	. Loja de aplicativos Angus (2019); Barlow et al. (2019) . Patente Kaplan e Vakili (2015)	Modelagem de Tópico Análise de sentimentos		Angus (2019) Kaplan e Vakili (2015); Barlow et al. (2019)	. Teoria da pesquisa problemática Angus (2019) . Teoria da tensão da criatividade Kaplan & Vakili (2015)	. Explorar apropriado corpus. Adote aprendizado profundo para analisar registros da empresa
Operações Gerenciamento	. Plataforma online Cui et al. (2018); Ko et al. (2019) . Arquivos 10-K Hoberg & Phillips (2018)	Classificação Modelagem de Tópicos LDA Sentimento Análise	Algoritmo de reconhecimento de padrão de texto RNTN	Jain et al. (2014) Ko et al. (2019) Cui et al. (2018)	. Teorias econômicas de orientação para metas, antecipatórias e de informação Ko et al. (2019) . Teoria de gerenciamento de operações Jain et al. (2014)	. Selecione o modelo apropriado

Machine Translated by Google

Tabela 2. Matriz de confusão.

	Valor Previsto	
Valor atual	Positivos	Negativos
Positivos	Verdadeiro Positivo (TP)	Falso Negativo (FN)
Negativos	Falso Positivo (FP)	Verdadeiro Negativo (TN)

calculado com base na matriz de confusão conforme mostrado na Tabela 2. Precisão $\frac{\text{Cidade}}{\text{TP + FP}}$ representa quantas das amostras positivas previstas são amostras positivas verdadeiras. Lembrar $\frac{\text{Cidade}}{\text{TP + FN}}$ representa quantos exemplos positivos na amostra foram previstos esteja correto. Pontuação F1 F1 = $\frac{\text{2 × Precisão × Recall}}{\text{Precisão + recall}} = \frac{\text{2×TP}}{\text{número da amostra + TP - TN}}$ mede diferentes preferências de precisão/recuperação. Muitos algoritmos geram uma previsão com valor real ou probabilística para a amostra de teste e depois comparam essa previsão valor com um limite de classificação. Se esta previsão for maior que o limite, é classificada como classe positiva; caso contrário, é uma classe negativa. As amostras são classificadas de acordo com os resultados de previsão do algoritmo. Eles são previstos um por um como positivos exemplos nesta ordem. Dois valores importantes são calculados a cada vez e plotados com as coordenadas horizontal e vertical respectivamente para obter a curva ROC. O ver-TP eixo tical é a Taxa Verdadeiramente Positiva $\frac{\quad}{\text{TP + FN}}$ e o eixo horizontal é o Falso Taxa Positiva $\frac{\text{FP}}{\text{A curva TN}}$. AUC é a área sob a curva ROC. Se o ROC + FP de um algoritmo pode cobrir completamente o outro, pode-se afirmar que a o primeiro é melhor que o último; mas se as duas curvas ROC se sobrepuserem, a AUC pode ser usado para julgamento.

6. Discussão

6.1. Desafios gerenciais e desenvolvimentos futuros

6.1.1. Dados

Dada a abundância de dados, muitos pesquisadores rastreiam dados de sites como o Twitter, Facebook e Amazon usando API ou programas autoconstruídos. A limpeza de tais enormes conjuntos de dados requerem enormes quantidades de tempo, energia e dinheiro, pois exigem pesquisadores para reequipar e aprender um novo conjunto de habilidades. Além disso, em tarefas de classificação, dados rotulados são um pré-requisito para análise. No entanto, existem alguns rótulos maduros conjuntos de dados na gestão. Para melhorar a qualidade e a precisão dos algoritmos, os pesquisadores devem codificar os dados manualmente, o que consome tempo e não pode garantir a qualidade. Felizmente, a combinação de codificação manual e algoritmos de treinamento pode garantir qualidade e eficiência (Song, Huang, Tan, & Yu, 2019). Ao rastrear dados públicos em algumas plataformas pode ser permitido por lei, pode entrar em conflito com as plataformas termos de serviço. Através de termos de serviço, as plataformas desenvolvem regras para controlar o acesso a conteúdo que os usuários optaram por disponibilizar publicamente (Berger et al., 2019).

Machine Translated by Google

6.1.2. Modelo

Devido à falta de modelos de PNL aplicáveis na disciplina de gestão, os estudiosos recorreram ao aprimoramento de algoritmos (Abbasi, Zhou, Deng, & Zhang, 2018; Rutz, Trusov, & Bucklin, 2011) ou desenvolveram novos dicionários (Loughran & Mcdonald, 2011) a fim de capturar características específicas dos cenários de gerenciamento. Os algoritmos convencionais não são precisos o suficiente para atender aos requisitos de cenários específicos, como pequenas amostras. O significado de alguns índices ou medidas em PNL, como a legibilidade, ainda não está bem definido nas pesquisas de gestão (Loughran & McDonald, 2016). No estudo da gestão, a precisão dos algoritmos não é a única forma de medir algoritmos; os estudiosos também precisam interpretar os resultados do algoritmo. No entanto, os resultados de alguns algoritmos de agrupamento podem não conseguir identificar claramente o significado específico de cada classe. Alguns estudiosos codificarão novamente manualmente esses resultados (Dyer et al., 2017), o que aumenta muito os custos. Por fim, é também necessário escolher um modelo adequado ao contexto da investigação, tarefa que também exige tempo e esforço.

6.1.3. Teoria É

difícil fazer contribuições teóricas puramente através da PNL. Por exemplo, embora a modelagem de tópicos e os algoritmos de agrupamento sejam geralmente aplicados na pesquisa de gestão para estudar as dimensões de um conceito, o design e a interpretação dessas dimensões com base na literatura e na teoria existentes ainda são necessários. Além disso, o núcleo de muitos algoritmos em PNL é um cálculo matemático que é difícil de entender do ponto de vista teórico. Além disso, como a aprendizagem profunda é um modelo altamente não linear e muito complexo, especialmente agora que é de ponta a ponta, a saída corresponde à entrada. Como resultado, todo o processo de treinamento é completamente modelado, deixando poucos espaços para intervenção manual. Para a gestão, muitas vezes é um resultado preciso e um processo de raciocínio. Por exemplo, para avaliar a satisfação dos clientes é necessário avaliar corretamente a pontuação. As empresas, por outro lado, precisam saber por que obtiveram a pontuação para que possam determinar qual parte não satisfez os clientes e como melhorar. Para o modelo totalmente caixa preta, até mesmo o aprendizado profundo revoluciona a PNL, melhorando muito a precisão das tarefas da PNL. No entanto, ainda é difícil para empresas e pesquisadores compreenderem os insights de negócios.
Observou-se, portanto, que os resultados de modelos específicos de PNL podem não ser generalizáveis para outros campos de pesquisa, considerando o caráter especial da medição ou dos métodos (Hong & Pavlou, 2017).

6.2. Desafios tecnológicos e desenvolvimentos futuros 6.2.1.

Compreensão da linguagem natural A questão

central da compreensão da linguagem natural (PNL) na PNL é que ela é um pré-requisito para muitas tarefas, como a geração de linguagem natural. Regras. O modelo atual de NLU ainda não obteve uma compreensão “real” da linguagem natural. Embora já existam algumas regras básicas para NLU, é difícil compreender a linguagem natural e para o aprendizado de máquina compreender as características inerentes apenas com base nessas regras, visto que o mesmo significado pode ser expresso de várias maneiras. É importante notar aqui que a linguagem humana nem sempre segue as regras que a regem. É possível que palavras omitidas e gramática de baixa qualidade não interfiram na comunicação, uma vez que os humanos podem especular o significado das frases. Para computadores,

Machine Translated by Google

no entanto, estes são obstáculos. Metáfora. Através de metáforas, múltiplos conceitos não relacionados podem ser combinados para gerar novos conceitos. Por exemplo, “esta sala é como um forno refere-se à alta temperatura de uma sala, mas um computador não consegue entender o significado dessas palavras usando representação de palavras e análise sintática. Criatividade. Há muitas palavras e expressões novas surgindo na Internet todos os dias.
Alguns são criados com base em eventos importantes ou cenários particulares, o que aumenta a dificuldade de descobrir e equipar computadores para compreender essas palavras.
Dado que a linguagem humana foi criada por milhares de pessoas durante um longo período de tempo, Gouws, Van Rooyen e Engelbrecht (2010) acreditam que os investigadores podem utilizar informações provenientes de fontes de dados estruturadas e bases de conhecimento. Os autores afirmam que os seres humanos aprendem a linguagem aplicando o ambiente ao objeto por meio da experiência e da interação. No entanto, o cálculo é enorme nesta situação. Finalmente, como a neurociência e a ciência cognitiva investigam o mecanismo subjacente de como o cérebro humano processa a linguagem, o conhecimento em neurociência e ciência cognitiva pode ser usado para construir modelos.

6.2.2. Construção de corpora em grande escala

As tarefas convencionais da PNL são baseadas em aprendizado de máquina estatística, o que requer um corpus em grande escala. Em muitas missões, esses corpora precisam ser construídos manualmente, o que é uma tarefa muito trabalhosa. A partilha de dados é, portanto, uma prática indispensável para promover a investigação e o desenvolvimento. Além disso, qualquer corpus, independentemente do tamanho ou tipo, não pode abranger de forma abrangente todos os casos num determinado domínio. Também não existe um padrão uniforme para os sistemas de rotulagem dos corpus. Se a categoria for muito ampla, é impossível descrever a linguagem de forma abrangente e meticulosa. Se for muito estreito, a eficiência da rotulagem será reduzida e resultará num sério problema de dispersão e fraca robustez do modelo treinado. Como anotar manualmente um corpus é uma tarefa demorada e trabalhosa, é necessário estudar como utilizar dados em grande escala sem dados manuais ou parcialmente rotulados. A aprendizagem semissupervisionada é particularmente imatura para uso nesse sentido.

6.3. Conclusão

A PNL é um ramo importante da inteligência artificial que adota algoritmos convencionais de aprendizado de máquina, métodos exclusivos de PNL e aprendizado profundo para construir modelos baseados em uma variedade de antecedentes de pesquisa para extrair informações de documentos e compreender documentos. Com o desenvolvimento de big data, computação em nuvem e aprendizagem profunda, a PNL é amplamente utilizada em diversas disciplinas, incluindo pesquisa de gestão. A PNL facilita a vida das pessoas e melhora efetivamente a eficiência e a precisão do trabalho.

Recentemente, a PNL experimentou um crescimento explosivo nos estudos de gestão. Com a melhoria contínua e o avanço de algoritmos e conjuntos de dados peculiares, a PNL está fornecendo aos estudiosos métodos analíticos mais precisos para dados textuais. Como resultado, a medição de conceitos e a montagem de métodos para resolução de problemas específicos no mundo dos negócios têm atraído muita atenção. No futuro, a PNL irá, sem dúvida, ajudar os investigadores a fazer contribuições teóricas e práticas para a literatura de gestão. Esperamos que esta revisão ofereça um roteiro sobre como a PNL pode ser aplicada como uma técnica analítica para pesquisa em gestão para gerar insights teóricos e práticos.

Machine Translated by Google

Declaração de divulgação

Nenhum potencial conflito de interesses foi relatado pelo(s) autor(es).

Financiamento Este trabalho foi apoiado pela Fundação Nacional de Ciências Naturais da China: [Número de concessão 71571177,71622009,71801204,71921001,71971202].

Notas

1. https://sg.news.yahoo.com/robo-journalism-gains-traction-shifting-media-landscape-014451181.html
2. https://www.aclweb.org/antology/P19-1289 3. https://www.iflyrec.com/ 4. https://patents.google.com/patent/US8285619B2/en 5. https://damo.alibaba.com/air/1235 6. A utilidade dos cientistas famosos beneficia outros ao influenciar a formação e a qualidade de novas ideias por meio de discussão, feedback, incentivo e crítica com colegas.

ORCIDA

Zhao Cai http://orcid.org/0000-0001-8705-4164 Chee-Wee Tan http://orcid.org/0000-0003-4245-541X Hefu Liu http://orcid.org/0000-0003-3854-7821

Referências

Abbasi, A., Zhou, Y., Deng, S. e Zhang, P. (2018). Análise de texto para apoiar a criação de sentido nas mídias sociais: uma perspectiva de ação linguística. MIS Trimestralmente, 42(2), 427–438.

Adamopoulos, P., Ghose, A. e Todri, V. (2018). O impacto dos traços de personalidade do usuário no boca a boca: plataformas de mídia social de mineração de texto. Pesquisa de Sistemas de Informação, 29(3), 612–640.

Angus, RW (2019). Distância de busca problemática e desempenho empreendedor. Revista de Gestão Estratégica, 40(12), 2011–2023.

Ansari, A., Li, Y. e Zhang, JZ (2018). Modelo de tópico probabilístico para sistemas de recomendação híbridos: uma abordagem bayesiana variacional estocástica. Ciência de Marketing, 37(6), 987–1008.

Archak, N., Ghose, A., & Ipeirotis, PG (2011). Derivando o poder de precificação dos recursos do produto, explorando as avaliações dos consumidores. Ciência de Gestão, 57(8), 1485–1509.

Bansal, N., Sharma, A. e Singh, RK (2019). Abordagem Fuzzy AHP para resumo de julgamentos legais. Journal of Management Analytics, 6(3), 323–340. doi:10.1080/23270012.2019. 1655672

Bao, Y. e Datta, A. (2014). Descobrir e quantificar simultaneamente os tipos de risco a partir de textos divulgações de risco. Ciência de Gestão, 60(6), 1371–1391.

Barlow, MA, Verhaal, JC e Angus, RW (2019). Distinção ideal, categorização estratégica e entrada no mercado de produtos na plataforma de aplicativos Google Play. Diário de Gestão Estratégica, 40(8), 1219–1242.

Barr, A. e Feigenbaum, EA (2014). O manual de inteligência artificial. Butterworth-Heinemann.

Berger, J., Humphreys, A., Ludwig, S., Moe, WW, Netzer, O., & Schweidel, DA (2019). Unindo as tribos: usando texto para obter informações de marketing. Jornal de Marketing, 84(1), 1–25.

Berman, R., Melumad, S., Humphrey, C. e Meyer, R. (2019). Uma história de duas Twitteresferas: microblogs políticos durante e após os debates primários e presidenciais de 2016. Jornal de Pesquisa de Marketing, 56(6), 895–917.

Caldieraro, F., Zhang, JZ, Cunha, M., & Shulman, JD (2018). Transmissão de informações estratégicas em mercados de empréstimos peer-to-peer. Jornal de Marketing, 82(2), 42–63.

Machine Translated by Google

Califf, ME e Mooney, RJ (2003). Aprendizagem relacional ascendente de regras de correspondência de padrões para extração de informações. Journal of Machine Learning Research, 4 (junho), 177–210.

Calomiris, CW e Mamaysky, H. (2019). Como as notícias e o seu contexto geram riscos e retornos em todo o mundo. Jornal de Economia Financeira, 133(2), 299–336.

Chanda, U. e Goyal, P. (2019). Um modelo de rede bayesiana sobre a interligação entre gestão de recursos humanos socialmente responsável, satisfação dos funcionários, comprometimento dos funcionários e desempenho organizacional. Journal of Management Analytics, 7(1), 105–138. doi:10.1080/23270012.2019. 1650670

Chatterji, A., Delecourt, S., Hasan, S., & Koning, R. (2019). Quando o conselho afeta o desempenho da startup? Diário de Gestão Estratégica, 40(3), 331–356.

Chi-Hsien, K. e Nagasawa, S. (2019). Aplicando aprendizado de máquina à análise de mercado: conhecendo seu consumidor de luxo. Journal of Management Analytics, 6(4), 404–419. doi:10.1080/ 23270012.2019.1692254

Collobert, R., Weston, J., Bottou, L., Karlen, M., Kavukcuoglu, K., & Kuksa, P. (2011). Processamento de linguagem natural (quase) do zero. Journal of Machine Learning Research, 12 (agosto), 2493–2537.

Councill, IG, Giles, CL, Han, H., & Manavoglu, E. (2005). Indexação automática de reconhecimento: Expandindo a semântica de contribuição na biblioteca digital CiteSeer. Anais da 3ª Conferência Internacional sobre Captura de Conhecimento.

Croidieu, G. e Kim, PH (2018). Trabalho de amor: legitimação de amadores e especialistas leigos no início do campo de rádio dos EUA. Ciência Administrativa Trimestral, 63(1), 1–42.

Cui, R., Gallino, S., Moreno, A. e Zhang, DJ (2018). O valor operacional das mídias sociais Informação. Gestão de Produção e Operações, 27(10), 1749–1769.

Das, SR e Chen, MEU (2007). Yahoo! para Amazon: Extração de sentimento de conversa fiada sobre a teia. Ciência de Gestão, 53(9), 1375–1388.

Dotzel, T. e Shankar, V. (2019). Os efeitos relativos das inovações de serviços business-to-business (vs. business-to-consumer) no valor e no risco da empresa: uma análise empírica. Jornal de Marketing, 83(5), 133–152.

Dyer, T., Lang, M. e Stice-Lawrence, L. (2017). A evolução da divulgação textual 10-K: evidências da alocação latente de Dirichlet. Jornal de Contabilidade e Economia, 64(2–3), 221–245.

Fang, F., Dutta, K. e Datta, A. (2014). Adaptação de domínio para classificação de sentimento à luz de múltiplas fontes. INFORMA Revista de Computação, 26(3), 586–598.

Frankel, R., Jennings, J. e Lee, J. (2016). Usando divulgações não estruturadas e qualitativas para explicar os acréscimos. Jornal de Contabilidade e Economia, 62(2–3), 209–227.

Froot, K., Kang, N., Ozik, G. e Sadka, R. (2017). O que as medidas de vendas corporativas em tempo real dizem sobre as surpresas nos lucros e os retornos pós-anúncio? Jornal de Economia Financeira, 125(1), 143–162.

Gabel, S., Guhl, D. e Klapper, D. (2019). P2V-MAP: Mapeando estruturas de mercado para grandes sortimentos de varejo. Jornal de Pesquisa de Marketing, 56(4), 557–580.

Genest, P.-E., & Lapalme, G. (2011). Estrutura para resumo abstrativo usando geração de texto para texto. Anais do Workshop sobre Geração de Texto para Texto Monolíngue.

Ghose, A., Ipeirotis, PG e Li, B. (2012). Projetar sistemas de classificação para hotéis em mecanismos de busca de viagens por meio da mineração de conteúdo gerado por usuários e de crowdsourcing. Ciência de Marketing, 31(3), 493–520.

Ghose, A., Ipeirotis, PG e Li, B. (2019). Modelando as pegadas do consumidor nos motores de busca: uma interação com as mídias sociais. Ciência de Gestão, 65(3), 1363–1385.

Gong, J., Abhisek, V. e Li, B. (2018). Examinando o impacto da ambigüidade de palavras-chave no desempenho da publicidade em buscas: uma abordagem de modelo de tópico. MIS Trimestralmente, 42(3), 805–829.

Gouws, S., Van Rooyen, G., & Engelbrecht, HA (2010). Medir a similaridade conceitual espalhando a ativação pela estrutura de hiperlinks da Wikipedia. Anais do 2º Workshop sobre A Web do Povo Encontra PNL: Recursos Semânticos Construídos Colaborativamente.

Verde, GM (2012). Pragmática e compreensão da linguagem natural. Routledge.

Hendershott, T., Livdan, D. e Schürhoff, N. (2015). As instituições estão informadas sobre as novidades? Jornal de Economia Financeira, 117(2), 249–287.

Herhausen, D., Ludwig, S., Grewal, D., Wulf, J., & Schoegel, M. (2019). Detectar, prevenir e mitigar tempestades online em comunidades de marcas. Jornal de Marketing, 83(3), 1–21.

Machine Translated by Google

Hermosilla, M., Gutiérrez-Navratil, F., & Prieto-Rodríguez, J. (2018). Os mercados emergentes podem inclinar o design global dos produtos? Impactos do colorismo chinês nos castings de Hollywood. Ciência de Marketing, 37(3), 356–381.

Hirschberg, J. e Manning, CD (2015). Avanços no processamento de linguagem natural. Ciência, 349 (6245), 261–266.

Hoberg, G. e Phillips, G. (2018). Escolha da indústria do conglomerado e linguagem do produto. Ciência de Gestão, 64(8), 3735–3755.

Hong, Y. e Pavlou, PA (2017). Sobre a seleção de compradores de prestadores de serviços em terceirização online plataformas para serviços de TI. Pesquisa de Sistemas de Informação, 28(3), 547–562.

Hou, J., Zhao, H., Zhao, X. e Zhang, J. (2016). Predição de comportamentos e localizações de usuários móveis usando redes bayesianas dinâmicas. Journal of Management Analytics, 3 (3), 191–205. doi:10.1080/23270012.2016.1198242 Hu, M., Dang, C. e Chintagunta, PK (2019). Pesquise

e aprenda em um site de ofertas diárias. Ciência de Marketing, 38(4), 609–642.

Huang, AH, Lehavy, R., Zang, AY e Zheng, R. (2018). Funções de descoberta e interpretação de informações do analista: uma abordagem de modelagem de tópicos. Ciência de Gestão, 64(6), 2833–2855.

Hwang, EH, Singh, PV e Argote, L. (2019). Valete de todos, mestre de alguns: Rede de informação e inovação em comunidades de crowdsourcing. Pesquisa de Sistemas de Informação, 30 (2), 389–410.

Jain, N., Girotra, K. e Netessine, S. (2014). Gerenciando sourcing global: desempenho de estoque. Ciência de Gestão, 60(5), 1202–1222.

Johnson, SL, Safadi, H. e Faraj, S. (2015). O surgimento da liderança comunitária online. Pesquisa de Sistemas de Informação, 26(1), 165–187.

Kaplan, S. e Vakili, K. (2015). A faca de dois gumes da recombinação em avanço inovação. Diário de Gestão Estratégica, 36(10), 1435–1457.

Ko, DG, Mai, F., Shan, Z. e Zhang, D. (2019). Eficiência operacional e cuidados de saúde centrados no paciente: uma visão das avaliações médicas online. Jornal de Gestão de Operações, 65(4), 353–379.

Kumar, V., Bhaskaran, V., Mirchandani, R. e Shah, M. (2013). Vencedor do prêmio prático - criando uma estratégia mensurável de marketing de mídia social: Aumentando o valor e o ROI de intangíveis e tangíveis para Hokey Pokey. Ciência de Marketing, 32(2), 194–212.

Law, KS e Chung, F.-L. (2020). Análise de decisão baseada em conhecimento para bancos comerciais. Jornal de Análise de Gestão, 1–22. doi:10.1080/23270012.2020.1734879 Lee, D., Hosanagar, K., & Nair, HS (2018).

Conteúdo publicitário e envolvimento do consumidor nas redes sociais: evidências do Facebook. Ciência de Gestão, 64(11), 5105–5131.

Lee, TY e Bradlow, ET (2011). Pesquisa de marketing automatizada usando cliente on-line avaliações. Jornal de Pesquisa de Marketing, 48(5), 881–894.

Li, XB e Qin, J. (2017). Anonimizar e compartilhar registros de textos médicos. Sistemas de informação Pesquisa, 28(2), 332–352.

Liu, B. (2012). Análise de sentimento e mineração de opinião. Palestras Síntese sobre Linguagem Humana Tecnologias, 5(1), 1–167.

Liu, J. e Toubia, O. (2018). Uma abordagem semântica para estimar as preferências de conteúdo do consumidor a partir de consultas de pesquisa on-line. Ciência de Marketing, 37(6), 930–952.

Liu, X., Lee, D. e Srinivasan, K. (2019). Análise de categorias cruzadas em larga escala do conteúdo de avaliações do consumidor sobre conversão de vendas, aproveitando o aprendizado profundo. Jornal de Pesquisa de Marketing, 56(6), 918–943.

Liu, X., Singh, PV e Srinivasan, K. (2016). Uma análise estruturada de big data não estruturado por aproveitando a computação em nuvem. Ciência de Marketing, 35(3), 363–388.

Loughran, TIM e McDonald, B. (2016). Análise textual em contabilidade e finanças: uma pesquisa. Jornal de Pesquisa Contábil, 54(4), 1187–1230.

Loughran, T. e Mcdonald, B. (2011). Quando uma responsabilidade não é uma responsabilidade? Análise textual, dicionários e 10-Ks. O Jornal de Finanças, 66(1), 35–65.

Lu, Y. (2019). Inteligência artificial: Um levantamento sobre evolução, modelos, aplicações e tendências futuras. Journal of Management Analytics, 6(1), 1–29. doi:10.1080/23270012.2019.1570365 Manning, CD, Manning, CD e Schütze, H. (1999). Fundamentos da estatística natural

processamento de linguagem. Imprensa do MIT.

Machine Translated by Google

McDonald, DD (2010). Geração de linguagem natural. Manual de Linguagem Natural Processamento, 2, 121–144.

Melumad, S., Inman, JJ e Pham, MT (2019). Seletivamente emocional: como o uso do smartphone altera o conteúdo gerado pelo usuário. Jornal de Pesquisa de Marketing, 56(2), 259–275.

Nguyen, H., Calantone, R. e Krishnan, R. (2019). Influência do boca a boca emocional das mídias sociais nas decisões dos investidores institucionais e no valor da empresa. Ciência de Gestão, 66(2), 887–910.

Och, FJ (2003). Treinamento de taxa mínima de erro em tradução automática estatística. Anais da 41ª Reunião Anual da Association for Computational Linguistics-Volume 1.

Oettl, A. (2012). Reconceitualizando estrelas: a utilidade dos cientistas e o desempenho dos pares. Ciência de Gestão, 58(6), 1122–1140.

Ordenes, FV, Ludwig, S., De Ruyter, K., Grewal, D., & Wetzels, M. (2017). Desvendando o que está escrito nas estrelas: analisando padrões de sentimento explícitos, implícitos e discursivos nas redes sociais. Jornal de Pesquisa do Consumidor, 43(6), 875–894.

Pan, Y., Huang, P. e Gopal, A. (2019). Nuvens de tempestade no horizonte? Novas ameaças de entrada e investimentos em P&D na indústria de TI dos EUA. Pesquisa de Sistemas de Informação, 30(2), 540–562.

Ricks, DA, Toyne, B. e Martinez, Z. (1990). Desenvolvimentos recentes na gestão internacional pesquisa de desenvolvimento. Jornal de Gestão, 16(2), 219–253.

Rohrbach, M., Qiu, W., Titov, I., Thater, S., Pinkal, M., & Schiele, B. (2013). Tradução de conteúdo de vídeo para descrições em linguagem natural. Anais da Conferência Internacional IEEE sobre Visão Computacional.

Rutz, OJ, Sonnier, GP e Trusov, M. (2017). Um novo método para auxiliar no teste de cópia de anúncios de texto de busca paga. Jornal de Pesquisa de Marketing, 54(6), 885–900.

Rutz, OJ, Trusov, M., & Bucklin, RE (2011). Modelagem de efeitos indiretos da publicidade de busca paga: quais palavras-chave levam a mais visitas futuras? Ciência de Marketing, 30(4), 646–665.

Schank, RC (1972). Dependência conceitual: Uma teoria de compreensão da linguagem natural. Psicologia Cognitiva, 3(4), 552–631.

Song, T., Huang, J., Tan, Y. e Yu, Y. (2019). Usando conteúdo gerado por usuários e profissionais de marketing para previsão de receita de bilheteria: diferenças entre microblogs e plataformas de terceiros. Pesquisa de Sistemas de Informação, 30(1), 191–203.

Srivastava, SB, Goldberg, A., Manian, VG e Potts, C. (2018). Trajetórias de enculturação: linguagem, adaptação cultural e resultados individuais nas organizações. Ciência de Gestão, 64(3), 1348–1364.

Stephen, AT, Zubcsek, PP e Goldenberg, J. (2016). Menos conectividade é melhor: Os efeitos da estrutura de rede na redundância de ideias e na inovação do cliente em tarefas de ideação interdependentes. Jornal de Pesquisa de Marketing, 53(2), 263–279.

Tang, VW (2018). Sabedoria das multidões: variação transversal na informatividade das informações de produtos geradas por terceiros no Twitter. Journal of Accounting Research, 56(3), 989–1034.

Toubia, O., Iyengar, G., Bunnell, R. e Lemaire, A. (2018). Extraindo características de produtos de entretenimento: uma abordagem de alocação de Dirichlet latente guiada e informada pela psicologia do consumo de mídia. Jornal de Pesquisa de Marketing, 56(1), 18–36.

Trusov, M., Ma, L. e Jamal, Z. (2016). Migalhas do cookie: perfil do usuário na análise da base de clientes e segmentação comportamental. Ciência de Marketing, 35(3), 405–426.

Tuertscher, P., Garud, R. e Kumaraswamy, A. (2014). Justificação e conhecimento entrelaçado no ATLAS, CERN. Ciência da Organização, 25(6), 1579–1608.

Verma, N., Malhotra, D. e Singh, J. (2020). Análise de big data para o setor de varejo usando a estrutura MapReduce-Apriori. Jornal de Análise de Gestão, 1–19. doi:10.1080/ 23270012.2020.1728403

Villarroel Ordenes, F., Grewal, D., Ludwig, S., Ruyter, KD, Mahr, D., Wetzels, M., ... Kopalle, P. (2019). Eliminando a confusão de conteúdo: como os atos de fala e imagem impulsionam o compartilhamento de mensagens de marca nas mídias sociais pelo consumidor. Jornal de Pesquisa do Consumidor, 45(5), 988–1012.

Wang, Q., Li, B. e Singh, PV (2018). Aplicativos móveis originais versus imitadores: um método de detecção de imitadores de aprendizado de máquina e análise empírica. Pesquisa de Sistemas de Informação, 29(2), 273–291.

Weber, D. (2002). Interface de usuário interativa com objetos usando reconhecimento de fala e linguagem natural em processamento. Patentes do Google. Patente dos EUA número 6434524.

Machine Translated by Google

Webster, J. e Watson, RT (2002). Analisando o passado para preparar o futuro: Escrevendo uma revisão de literatura. MIS Trimestralmente, 26(2), 13–23.

Wu, L., Hitt, L. e Lou, B. (2019). Análise de dados, inovação e produtividade empresarial. Ciência da Gestão.

Wu, L., Lou, B. e Hitt, L. (2019). A análise de dados apoia a inovação descentralizada. Ciência de Gestão, 65(10), 4863–4877.

Xiong, G. e Bharadwaj, S. (2014). Padrões de evolução do buzz pré-lançamento e desempenho de novos produtos. Ciência de Marketing, 33(3), 401–421.

Xu, B., Xu, K., Fu, L., Li, L., Xin, W., & Cai, H. (2016). Análise de dados de saúde: usando um abordagem de anotação de metadados para integração de registros hospitalares eletrônicos. Diário de Análise de Gestão, 3(2), 136–151. doi:10.1080/23270012.2016.1141331

Xu, K., Liao, SS, Lau, RYK e Zhao, JL (2014). Estratégias eficazes de aprendizagem ativa para o uso de classificadores de margem grande na anotação semântica: uma descoberta ideal de parâmetros perspectiva. INFORMA Revista de Computação, 26(3), 461–483.

Xu, T., Zhang, P., Huang, Q., Zhang, H., Gan, Z., Huang, X., & He, X. (2018). Attngan: Texto refinado para geração de imagens com redes adversárias geradoras de atenção. Processos da Conferência IEEE sobre Visão Computacional e Reconhecimento de Padrões.