Machine Translated by Google

Transações endossadas pela EAI em sistemas de informação escaláveis

Artigo de Pesquisa EAI.EU

Modelagem de tópicos: uma revisão abrangente

Pooja Kherwa1,*, Poonam Bansal1

[1] Instituto de Tecnologia Maharaja Surajmal, C-4 Janak Puri. GGSIPU. Nova Deli-110058.

Abstrato

A modelagem de tópicos é a nova revolução na mineração de texto. É uma técnica estatística para revelar a estrutura semântica subjacente em grandes coleções de documentos. Depois de analisar aproximadamente 300 artigos de pesquisa sobre modelagem de tópicos, uma pesquisa abrangente sobre modelagem de tópicos foi apresentada neste artigo. Inclui hierarquia de classificação, métodos de modelagem de tópicos, técnicas de inferência posterior, diferentes modelos de evolução de alocação latente de Dirichlet (LDA) e suas aplicações em diferentes áreas da tecnologia, incluindo Literatura Científica, Bioinformática, Engenharia de Software e análise de redes sociais. A avaliação quantitativa das técnicas de modelagem de tópicos também é apresentada em detalhes para melhor compreensão do conceito de modelagem de tópicos. No final, o artigo é concluído com uma discussão detalhada sobre os desafios da modelagem de tópicos, o que certamente dará aos pesquisadores uma visão para uma boa pesquisa.

Palavras-chave. Modelagem de Tópicos, Alocação de Dirichlet Latente, Análise Semântica Latente, Inferência. Redução de dimensão.

Recebido em 25 de fevereiro de 2019, aceito em 03 de julho de 2019, publicado em 24 de julho de 2019

Copyright © 2019 Pooja Kherwa *et al.,* licenciado para EAI. Este é um artigo de acesso aberto distribuído sob os termos da Licença Creative Commons Attribution (http://creativecommons.org/licenses/by/3.0/), que permite uso, distribuição e reprodução ilimitada em qualquer meio, desde que o trabalho original seja devidamente citado.

dois: 10.4108/eai.13-7-2018.159623

*Autor correspondente. E-mail: poona281280@gmail.com

Machine Translated by Google

1. Introdução

Hoje em dia, quando a maioria da literatura em todas as esferas da vida é digitalizada e armazenada eletronicamente nas bases de dados, através de bibliotecas digitais ou bases de dados de redes sociais. O pesquisador precisa de ferramentas automáticas poderosas para ler esses dados e compreender os temas subjacentes aos dados, como os seres humanos. A modelagem de tópicos é uma técnica que vem com um grupo de algoritmos que revelam, descobrem e anotam a estrutura temática em uma coleção de documentos [1]. O modelo de espaço vetorial é a base para muitas técnicas avançadas de recuperação de informações [2] [3] e modelos de tópicos [4].

O VSM (modelo de espaço vetorial) foi o primeiro modelo algébrico simples baseado diretamente no termo matriz de documento para extrair informações semânticas do uso de palavras [5]. Um modelo básico de espaço vetorial pode quebrar o texto em unigramas ou bigramas de caracteres. É baseado na abordagem Bag of Words (BOW), onde a ordem exata dos termos em um documento é ignorada, mas a frequência de ocorrência de cada termo é mantida como um fator importante [6][7]. O VSM abriu suas asas em uma variedade de aplicações, incluindo aprendizado de máquina, mecanismos de busca, processamento de linguagem natural, tradução automática que envolve medir a similaridade de conceitos, contexto entre palavras, frases e documentos [3][9]. Para modelar um sistema de recuperação como um mecanismo de busca ou uma coleção digital, todas as palavras em um documento não são igualmente importantes. Assim, atribuímos a cada termo de um documento um peso que depende do número de ocorrências do termo em um documento. O conceito de ponderação é dar mais peso aos eventos inesperados e menos peso aos eventos que ocorrem com frequência. A maneira mais popular de formalizar a ideia de matrizes de documentos de termo é (frequência de termo*frequência inversa de documento) [tf*idf], da família de funções de ponderação [8][10]. Algoritmos de modelagem de tópicos fornecem técnicas de múltiplas perspectivas para encontrar semântica oculta na coleção de documentos e agrupar os temas como tópicos. O modelo distribucional como espaço vetorial, análise semântica latente, modelo semântico latente probabilístico e alocação latente de Dirichlet podem ser usados para derivar a representação do significado das palavras com base na análise de estatísticas [2]. Nas últimas duas décadas, houve vários artigos e resultados de pesquisas dedicados a várias técnicas de modelagem de tópicos, incluindo LSA (análise semântica latente), Plsa (análise semântica latente probabilística) e LDA (alocação latente de Dirichlet). de várias áreas, matemáticos, estatísticos, cientistas da computação, biólogos e neurocientistas exploraram a modelagem de tópicos a partir de diversas perspectivas. Os principais pesquisadores na modelagem de tópicos são David M Blei, Michael I. Jordan, Thomas L.

Pesquisadores

Griffiths, Hanna M. Wallach, Jordan Boyd Graber, Mark Johnson, D. Mimno, Jonathan Chang e Katherine Heller Nestes David M Blei é o pesquisador mais dominante com

publicação de pesquisa contínua desde 2003 a 2017, com cerca de 200 publicações em vários periódicos e conferências internacionais de renome. Jordan Boyd Graber escreveu o primeiro artigo sobre modelagem de tópicos em 2007 com David M. Blei em

uso de modelagem de tópicos para desambiguação do sentido das palavras. Em 2008 apresentou o conceito de modelo de tópico multilíngue e modelo de tópico sintático e completou seu doutorado em extensão linguística de modelos de tópico em 2010. Em 2011 descobriu o conceito de modelagem de tópico interativo com Brianna Sati off.
Jordan contribuiu principalmente na análise de sentimentos, modelagem de tópicos multilíngues e modelagem de tópicos de fala –
modelagem de tópicos em grande escala e modelagem de tópicos eficiente baseada em árvore e modelagem de tópicos online. David Mimno veio com a ideia de detectar a influência do autor na coleção através da modelagem de tópicos do autor e mais na correlação entre tópicos e artigos no corpus usando modelos de alocação Pachinko.

Como a modelagem de tópicos é uma técnica muito poderosa, ela se espalhou em vários domínios, desde processamento de linguagem natural até literatura científica, engenharia de software, bioinformática, humanidades, etc.

centenas de artigos foram publicados, mas na literatura de modelagem de tópicos não existe nenhum artigo que explore toda a literatura de uma maneira única e abrangente. Algumas contribuições significativas do pesquisador principal estão apenas na alocação latente de Dirichlet (LDA) [11] [12]. O conceito de redução de dimensão e detecção de tema semântico é predominante na literatura desde o início de 1999. Portanto, neste artigo, motivamo-nos a fornecem uma revisão abrangente sobre modelagem de tópicos que inclui uma breve hierarquia de classificação, bem como uma explicação de cada método com algoritmos como análise semântica latente, análise semântica latente probabilística, fatoração de matriz não negativa e, finalmente, a alocação de Dirichlet latente (LDA) é apresentada em grande detalhe.

Portanto, na totalidade este artigo traz estas contribuições:

- Hierarquia de classificação de diferentes modelagem de tópicos métodos são projetados. E métodos de modelagem de tópicos são brevemente explicados.
- Neste artigo, artigo acadêmico de 2003-2018 relacionado ao tópico latente baseado em alocação de Dirichlet modelagem são explorados completamente e a taxonomia é projetado pela primeira vez.
- Aplicação de aplicativo de modelagem de tópicos em vários domínios como literatura científica, software Engenharia, Bioinformática, Análise de sentimento são discutidos em detalhes.
- Desafios da modelagem de tópicos para explorar o modelagem de tópicos de múltiplas perspectivas são fornecidas em detalhe.
- Avaliação quantitativa com métrica padrão em dois conjuntos de dados também são feitos em termos probabilísticos e não probabilístico (alocação latente de Dirichlet, Análise semântica latente) método de modelagem de tópicos.
- No final, algumas ferramentas e pacotes de modelagem de tópicos também são explicados.

Machine Translated by Google

2. Classificação de modelagem de tópicos

O modelo de tópico pode ser considerado como uma metodologia para apresentar o enorme volume de dados gerados devido ao avanço da tecnologia computacional e web em baixa dimensão e para apresentar os conceitos ocultos, características proeminentes ou variáveis latentes dos dados, dependendo do contexto da aplicação, devem ser identificados de forma eficiente. A redução de dimensão foi inicialmente vista através da perspectiva algébrica, decompondo a matriz original em matriz fatorial. Portanto, nossa estratégia de classificação de modelagem de tópicos nesta pesquisa é descrita como

- Modelo Probabilístico
- Modelo de tópico não probabilístico (modelo algébrico).

Abordagens não probabilísticas são abordagens algébricas de fatoração de matriz e surgiram no início de 1990 com o conceito de Análise Semântica Latente [13] e Fatoração de Matriz Não Negativa [14] [15] [16] [17]. Tanto LSA quanto NNMF funcionam na abordagem do saco de palavras, onde o corpus é convertido em matriz de documento de termos e a ordem dos termos é totalmente negligenciada, apenas os termos contam em questões de documentos. O modelo probabilístico surgiu para melhorar o modelo algébrico, como a análise semântica latente, adicionando o sentido de probabilidade usando abordagens de modelo generativo [1].

O próximo nível na árvore de classificação é baseado na abordagem supervisionada e não supervisionada para modelagem de tópicos, nesta hierarquia, cai o modelo de tópico probabilístico como Plsa e Latent Dirichlet Allocation. Inicialmente, tanto o Plsa quanto o LDA eram abordagens totalmente não supervisionadas, mas mais tarde muitos pesquisadores trabalharam no modelo Latent Dirichlet Allocation (LDA) com abordagem supervisionada para aprendizagem de modelo, o Plsa é explorado de forma semi-supervisionada em domínios de aplicação muito limitados. Os modelos não probabilísticos não encontraram contribuição significativa nas modas supervisionadas, sendo consideradas fora do escopo do artigo.

O último nível na hierarquia de classificação considera a sequência de palavras durante a modelagem do tópico. Até 2006, as abordagens completas de modelagem de tópicos baseadas em BOW (Bag of Words, em 2006 Hanna M. Wallach introduziu a importância de incorporar sequência de palavras na modelagem de tópicos por meio de estatísticas de n-gramas e um modelo hierárquico de Dirichlet Bigram com melhor precisão do que BOW abordagens são apresentadas [18]. Embora os pesquisadores estejam explorando a perspectiva de modelagem de tópicos baseada em Bigram e N-gram, até hoje a abordagem mais dominante ainda é baseada em Bag of Words, onde o corpus é convertido em matriz de documentos de termos e a ordem dos termos é totalmente negligenciados, apenas os termos contam em questões documentais.

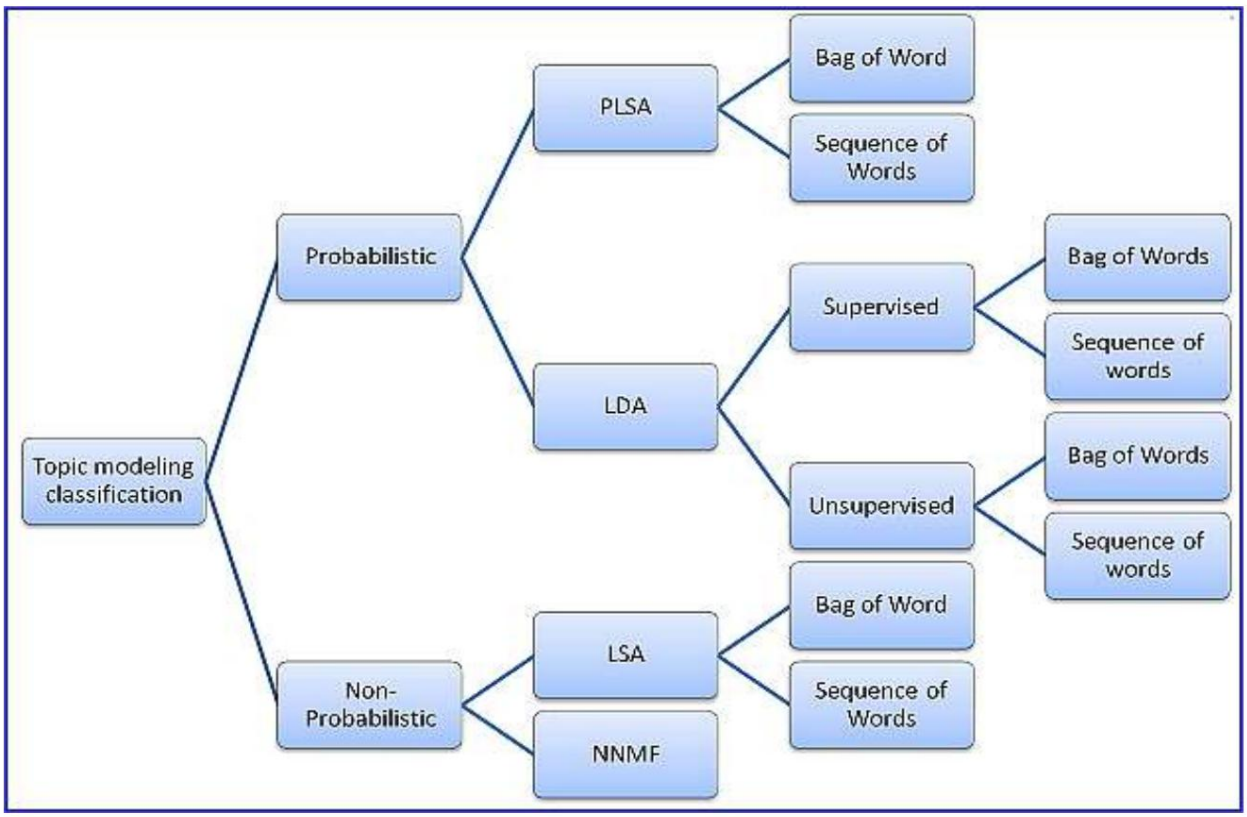

Figura 1. Hierarquia de classificação de modelagem de tópicos

Machine Translated by Google

3. Métodos de modelagem de tópicos

Os algoritmos de modelagem de tópicos mais populares que contribuíram com todas as esferas da análise de texto em vários domínios incluem análise semântica latente, análise não negativa Fatoração de matrizes, análise semântica latente probabilística e alocação de Dirichlet latente

3.1 Análise Semântica Latente

A análise semântica latente é um método algébrico baseado na decomposição de valor único (SVD) e que apresenta o espaço semântico dos documentos em que mais relacionamento semântico e uso contextual se aproximam. Ao contrário da criança humana, uma máquina aprende tudo com a linguagem. Em 1997, Landauer e Dumais propuseram a técnica de análise semântica latente [13]. Eles usaram a decomposição de valores singulares (SVD) que foi aplicada a muitas áreas diferentes, incluindo recuperação de informação, processamento de linguagem natural e modelagem do conhecimento da linguagem humana ou pelo menos a base do conhecimento humano [18][19][20].
A fundamentação teórica do LSA são hipóteses distributivas [42], que afirmam que termos com significado semelhante também ocorrem muito mais próximos em seu uso contextual. Toda a relação semântica entre os textos é inferida diretamente de determinado corpus textual. Ele usa representação vetorial de texto para calcular a semelhança entre textos para encontrar palavras semelhantes no texto, para organizar semanticamente o texto em grupos semânticos.
A Análise Semântica Latente tem sua aplicação na mineração de texto, incluindo classificação automática de redação, tutoria inteligente, recuperação de informações, análise de redes sociais e resumo de texto.

3.1.1 Algoritmo para LSA

1. Para corpus de texto é criado um termo por matriz de documento A onde M são os termos ou palavras em um documento e N é o número de documentos no corpus.
2. Cada entrada é ponderada com uma função que associa importância de cada palavra no documento e no todo corpus. Uma função de ponderação deve dar um peso baixo a um tipos de alta frequência que ocorrem em muitos documentos e alto peso para tipos que ocorrem em alguns documentos, mas não todos [19].
3. Aplique SVD (decomposição de valores singulares) à matriz A, que revela a correlação entre os termos nos documentos.

SVD decompõe a matriz A em três matrizes de modo que
A=UÿVT
Onde U é uma matriz ortogonal (UTU) e V é uma matriz ortogonal (VTV) e ÿ é uma matriz diagonal (ÿ=diagonal (ÿ1, ÿ2.....ÿK) com a célula da matriz restante toda zero [20]
4. A matriz A é truncada como Ak , o Ax truncado é o melhor ou mais próxima classificação k aproximação da matriz original A[21][22][23].Um experimento é conduzido para projetar o espaço de alta dimensão em baixa dimensão com decomposição de valor único (SVD) e mostrando a correlação de termos no espaço semântico com diferentes classificações [20].

3.2 Fatoração de Matriz Não Negativa (NNMF)

É uma nova técnica de redução de dimensão na qual o problema dos números negativos presentes no conjunto de dados é resolvido colocando restrições de não negatividade no modelo de dados. O conceito de NNMF usado por Pattero em 1994 para dados ambientais [24]. Em 1997, novamente usado em aprendizagem não supervisionada por Lee & Seung [25]. O NMF visa resolver o problema do componente negativo em modelos de dados, porque em muitas aplicações, os componentes negativos contradizem a realidade física. Portanto, o NMF é uma representação de dados confinados a vetores não negativos.
A ideia é decompor uma matriz não negativa B em fatores não negativos V e H, B=VH+C,
Vÿ0,Hÿ0.
Esta decomposição é de natureza aproximada e C é ruído ou matriz de erro.
Este conceito é chamado de fatoração de matriz não negativa ou também chamado de PMF (fatoração de matriz positiva). NNMF também suporta restrições de dispersão em muitas aplicações [26][27][28][29]. No conjunto de dados de microarranjos, muitas abordagens de aprendizado de máquina, como classificação e agrupamento, foram aplicadas à identificação do câncer usando um conjunto de dados de expressão gênica molecular [34] [39] [76]. Um experimento comparativo em um conjunto filtrado de genes para classificação de câncer usando métodos de discriminação [41] foi realizado e anormalidades no comportamento celular são destacadas com provas válidas. Na mineração de texto, a abordagem de resumo de texto baseada em NNMF e agrupamento também é apresentada com melhor desempenho do que agrupamento [40].NNMF tem sido usado em muitas aplicações, incluindo segmentação, redução de dimensão, reconhecimento de padrões, processamento de imagens, modelagem de linguagem

3.3 Análise Semântica Latente Probabilística

A Análise Semântica Latente Probabilística (PLSA) é uma técnica de redução de dimensão em mineração de texto baseada em saco de palavras (BOW) para detectar coocorrência semântica de termos usando estrutura probabilística em um corpus. Foi desenvolvido por Hoffman [30].
O primeiro modelo estatístico para revelar a coocorrência semântica na matriz de termos do corpus do documento foi o modelo Aspect [31]. Baseia-se no conceito de que cada palavra gerada a partir de um único tópico e diferentes palavras em um documento podem ser geradas a partir de diferentes tópicos. Cada documento é representado como uma lista de proporções de mistura para esses componentes da mistura e, portanto, reduzido a uma distribuição de probabilidade sobre um conjunto fixo de tópicos.

3.3.1 Algoritmo para PLSA

Machine Translated by Google

O modelo é definido com três parâmetros ÿ, ÿ e ÿ, onde ÿz é a distribuição de palavras nos tópicos latentes z dada por p(w|z), ÿd é a distribuição de tópicos no documento d dada por p(z|d) e pd é a probabilidade de escolher o documento d dada por p(d). As palavras são geradas como 1. Escolha o documento d~ÿ.

2.Escolha o tópico z~ ÿd.

3.Escolha a palavra w ~ ÿz.

$$P(d,w) = P(d)\int P(\theta|\alpha)\sum_{z} P(z|\theta)P(w|z) \quad (1)$$

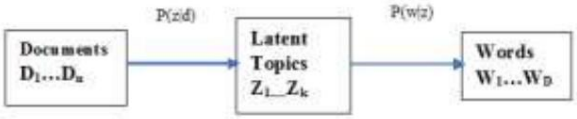

Figura 2. Análise Semântica Latente Probabilística (Plsa)

A probabilidade do par de documentos word observado(d,w) pode ser obtida por marginalização sobre tópicos latentes.

3.4 Alocação latente de Dirichlet

3.4.1 LDA Processo Gerativo Latent Dirichlet

Allocation (LDA) é uma abordagem, baseada no teorema definneti [32] para capturar estrutura estatística significativa inter e intradocumento por meio da mistura de suposições distributivas de que o documento surge de vários tópicos, um tópico é definido como distribuição em um vocabulário. Corpus está associado a um número predefinido de tópicos k, e cada documento do corpus contém esses tópicos em proporções diferentes. A Modelagem de Tópicos visa aprender esses tópicos a partir de dados ou corpus. LDA é baseado em modelo de variável oculta, predominante no aprendizado de máquina há décadas. O modelo generativo não considera a ordem das palavras na produção de documentos, portanto, é puramente baseado na abordagem do saco de palavras (BOW). A modelagem de tópicos consiste em descobrir automaticamente os tópicos de uma coleção de documentos, portanto, em um conjunto de dados, a distribuição de K tópicos deve ser aprendida por meio de inferência estatística. Este algoritmo definiu o processo generativo como uma distribuição de probabilidade conjunta sobre variáveis observadas e ocultas. O processo de aprendizagem da distribuição do tópico é descrito por meio da notação de placas dada na figura.

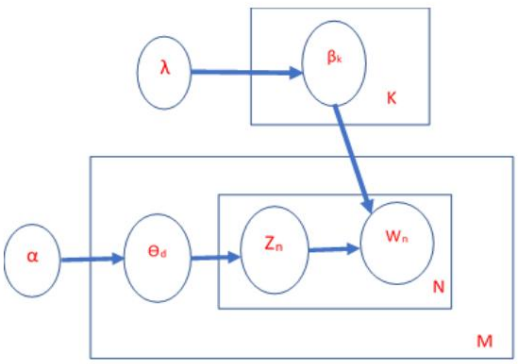

Figura 3. Placa de Alocação Latente de Dirichlet (LDA) Notação.

3.4.2 Algoritmo LDA

Para cada documento

(a) Distribuição por tópicos ÿd~Dir(ÿ). onde Dir(.)é um empate de uma distribuição uniforme de Dirichlet com parâmetro de escala ÿ.

(b) Para cada palavra do documento

1.Desenhe um tópico específico zd,n~ multi(ÿd)

2. Desenhe uma palavra wd,n~ÿz,d,n.

O problema inferencial central para LDA é determinar a distribuição posterior das variáveis latentes dado o

$$P(\theta, z|w, \alpha, \beta) = \frac{P(\theta, z, w|\alpha, \beta)}{P(w|\alpha, \beta)} \quad (2)$$

O objetivo da modelagem de tópicos é descobrir automaticamente os tópicos de uma coleção de documentos. Os documentos são observados, enquanto a estrutura do tópico, os tópicos, a distribuição de tópicos por documento e a atribuição de tópicos por documento por palavra são uma estrutura oculta. A utilidade da modelagem de tópicos vem da propriedade de que a estrutura oculta inferida se assemelha à estrutura temática da coleção.

Esta estrutura oculta interpretável anota cada documento da coleção e a anotação de teses pode ser usada na recuperação de informações, classificação e exploração de corpus

4. Inferência Posterior para Dirichlet Latente Alocação

Várias técnicas de inferência que fornecem solução aproximada para probabilidades marginais para dados observados sob vários modelos de tópicos incluem inferência variacional [4] [35], inferência variacional colapsada [36], propagação de expectativa [37] e amostragem de Gibbs [32]. Cada técnica de aproximação tem suas vantagens e desvantagens. Inferência Variacional fornece uma metodologia determinística para aproximar probabilidade e posteriores [38]. A inferência variacional é baseada na reformulação do problema de calcular o posterior distribuição como um problema de otimização, perturbando problema e encontrar soluções para o problema perturbado. A inferência variacional geralmente tem um desempenho pior do que métodos de amostragem devido a um viés aproximado, mas funciona mais rápido. Além disso, sendo mais rápido que os métodos de amostragem e é particularmente adequado para problemas de grande escala

4.1 Método Variacional do Campo Médio

Os métodos de campo médio baseiam-se na otimização da divergência de Kullback-Leibler (KL) em relação à chamada distribuição variacional. Em contraste com o posterior verdadeiro, a distribuição variacional do campo médio para LDA é aquela em que as variáveis são independentes umas das outras e cada uma governada por um parâmetro variacional diferente:

4.2 Amostragem de Gibbs

A amostragem de Gibbs é uma típica cadeia de Markov Monte Carlo

Machine Translated by Google

O método foi originalmente proposto para restauração de imagens [42].

5. Análise quantitativa por tópico

Métodos de modelagem

Para análise quantitativa de métodos de modelagem de tópicos, escolhemos duas técnicas de modelagem de tópicos: uma é escolhida do método algébrico e outra é do método probabilístico.
A técnica de modelagem algébrica de tópicos baseada na fatoração de matriz é a análise semântica latente (LSA) e a técnica de modelagem probabilística de tópicos é a alocação de Dirichlet Latente (LDA). O termo modelagem de tópicos na comunidade de aprendizado de máquina é dado por David Blie et al em 2003, ao usar o algoritmo de alocação latente de Dirichlet para detecção de temas semânticos em grandes coleções de texto, desde então LDA é considerado sinônimo de modelagem de tópicos na comunidade de aprendizado de máquina. Todos os algoritmos evolutivos de modelagem de tópicos, como modelo de tópico correlacionado, modelo de tópico dinâmico, modelo de tópico de autor, modelo de tópico multilíngue, modelo de tópico sintático e muitos mais discutidos na taxonomia projetada na seção 5, são extensão do LDA ou baseados em LDA. Portanto, até hoje o LDA é a abordagem mais utilizada para modelagem de tópicos.

5.1 Conjunto de dados escolhido

Para a avaliação empírica escolhemos dois conjuntos de dados. Crítica de filmes: o conjunto de dados rotulado consiste em 5.000 resenhas de filmes do IMDB, especialmente selecionadas para análise de sentimento. O sentimento das resenhas é binário, o que significa que uma classificação IMDB <5 resulta em uma pontuação de sentimento de 0, e uma classificação> = 7 tem uma pontuação de sentimento de 1. Nenhum filme individual tem mais de 30 resenhas do National Institutes of Health (NIH) : Este conjunto de dados contém informações sobre bolsas de pesquisa concedidas pelos Institutos Nacionais de Saúde (NIH) em 2014. Inclui arquivos de 'projetos' e 'resumos'. O conjunto de dados é um quadro de dados de 100 resumos e metadados de bolsas amostrados aleatoriamente

5.2 Pré-processamento

Para o pré-processamento do conjunto de dados, uma função de pré-processador é projetada que inclui a remoção de todos os dígitos numéricos do conjunto de dados e também a conversão de todos os caracteres de letras maiúsculas em minúsculas para processamento posterior. Na próxima etapa, um tokenizador de palavras também é construído e aplicado à entrada pré-processada. Este tokenizer dividirá o documento em nível de palavra individual e considerará essa palavra como token para processamento posterior.

Uma matriz de termos de documento baseada em vocabulário é criada, coletamos termos exclusivos de todos os documentos e marcamos cada um deles com um ID exclusivo usando a função de criação de vocabulário. Na modelagem típica de tópicos, começamos construindo uma matriz de termos de documento (DTM) a partir de documentos de entrada. Este é o primeiro passo para vetorizar texto, criando um mapa de palavras para um espaço vetorial.

5.3 Configuração de parâmetros

Para avaliação da modelagem de tópicos, definimos parâmetros de algoritmo tanto para o algoritmo semântico latente quanto para a alocação latente de Dirichlet. Embora ambos os algoritmos forneçam insights automáticos em grandes conjuntos de dados na forma de temas semânticos, a forma de modelagem é totalmente diferente nos algoritmos. A Análise Semântica Latente aprende tópicos latentes realizando a decomposição da matriz no termo matriz do documento. A alocação latente de Dirichlet (LDA) é um modelo probabilístico generativo que assume um Dirichlet anterior sobre os tópicos latentes [1]. Neste experimento, escolhemos K = 10 (número de tópicos em LDA e taxa de fatoração para SVD em LSA) em Filme analisa o conjunto de dados e K = 10 para NIH (de acordo com o tamanho dos dados).

5.4 Medida de Avaliação

Na literatura, perplexidade e log-verossimilhança são a abordagem mais amplamente usada para avaliar a qualidade do tópico do modelo de tópico [99], mas nossa abordagem de modelagem algébrica de tópicos, análise semântica latente, é um método de fatoração de matriz baseado na decomposição de valor único, portanto, não há uso de expectativa algoritmos de maximização em tópicos de aprendizagem. Portanto, escolhemos as métricas de avaliação que são aplicáveis a ambos os métodos de modelagem de tópicos, portanto, para esses modelos, escolhemos a coerência como as medidas de qualidade mais proeminentes. Coerência Probabilística: A coerência probabilística mede como as palavras estão associadas em um tópico, controlando a independência estatística. Por exemplo, suponha que você tenha um conjunto de artigos da seção de esportes de um jornal. Um tópico com as palavras {esporte, esportes, bola, torcedor, atleta} ficaria ótimo. Mas na verdade sabemos que é um tema terrível porque as palavras são tão frequentes neste corpus que perdem o sentido. Em outras palavras, eles são altamente correlacionados entre si, mas são estatisticamente independentes um do outro [100]. Para cada par de palavras {a, b} nas M principais palavras de um tópico, a coerência probabilística calcula P(b| a) - P(b), onde {a} é mais provável que {b} no tópico. Suponha que as 4 principais palavras em um tópico sejam {a, b, c, d}. Então, calculamos P(a|b) - P(b), P(a|c) - P(c), P(a|d) - P(d)

P(b|c) - P(c), P(b|d) - P(d)
P(c|d) - P(d)
E todas as 6 diferenças são calculadas em conjunto, dando a medida de coerência probabilística.

Machine Translated by Google

Tabela 1. Análise de Coerência para ambos os conjuntos de dados com diferentes números de tópicos

Conjunto de dados de resenhas de filmes (K = 10)									
LDA									
T1	T2	T3	T4	T5	T6	T7	P8	T9	T10
0,050	0,095	0,075	0,051	0,045	0,089	0,067	0,072	0,071	0,091
LSA									
T1 T2 0,059 0,068 **Institutos**		T3	T4	T5 T6 -0,002		T7	T8	T9	T10
Nacionais de Saúde (NIH)(K=10)		0,032	0,14	0,121		0,035	0,051	0,057	0,057
LDA									
T1	T2	T3	T4	T5	T6	T7	P8	T9	T10
0,084	0,039	0,077	0,11	0,28	0,07	0,12	0,055	0,16	0,12
LSA									
T1 T2 0,0018 0,14 **Institutos**		T3	T4	T5	T6	T7	T8	T9	T10
Nacionais de Saúde (NIH)(K=5)		0,25	0,39	0,71	0,58	0,048	0,54	0,32	0,18
LDA									
T1	T2	T3	T4	T5					
0,15	0,087	0,093	0,17	0,14					
LSA									
T1	T2	T3	T4	T5					
0,0018	0,14	0,25	0,39	0,71					

Tabela 2. Termos principais de ambos os algoritmos de modelagem de tópicos no Movie Review Dataset

LDA K = 10								
T1	**T2**	**T3**	**T5**	**T6**	**T7**		**T9**	**T10**
Mostrar	Papel	Personagens **T4** amam	Comédia M homem			Noite	Versão	guerra
Anos	Jogar	filmes vida	Melhor	Porquê aqui		de jogo	Produção	nós
Serra	personagem	personagem família	Engraçado	Sua ação		de	original	vida
Agora	John	trabalho pai	Diversão	Saiba fica		terror **T8** aqui	Livro	nosso
Televisão	diretor de performance	mulher sempre coisa			cena	filmes	Diretor	aqueles
LSA K = 10								
T1	**T3**	**T4**	**T5**	**T6**	**T7**		**T9**	**T10**
Filmes de personagens **T2**		filmes	Maria	Filmes	Mostrar filmes	Vida **T8**	Anos	homem
Filmes	personagens	papel	Lou	Mostrar	Mary	masculinos	zumbi M	onde
Homem	atores	de	Horror	Corrida	Lou	onde	página	diga	página
Onde	esse	jogo de	noite de	Horror	Noite de	cara	flic	alguma	aqui
Vida	personagem	vida de homem	formatura	Atores	formatura	cinza	aposta	coisa aos livros	Bettie

5.5 Resultados e Discussão

Nesta avaliação empírica, a coerência probabilística para ambos os conjuntos de dados, para ambos os métodos de modelagem de tópicos com número especificado de tópicos, é calculada em tópico individual. A pontuação de coerência para todos os dez tópicos é mostrada na tabela. No conjunto de dados Movie Review, é claramente visível que o modelo Latent Dirichlet Allocation fornece tópicos mais coerentes do que a análise semântica latente, exceto apenas o tópico 1. No caso do conjunto de dados de amostra NIH, onde consideramos apenas 100 amostras, e o número de tópicos abordados é 10, aqui na tabela mostra que a análise semântica latente dá tópicos mais coerentes. Mas em um pequeno conjunto de dados com apenas 100 amostras, o número selecionado de o tópico 10 é bastante grande, para bons resultados tomamos k (o número de tópicos 5, e depois a coerência probabilística, e é claramente visível na tabela que o LDA produz um número de tópicos mais coerente do que a análise semântica latente.

Na análise dos principais termos em ambos os algoritmos de modelagem de tópicos, é visível através da análise dos principais termos que ambos os algoritmos de modelagem de tópicos tentam fornecer uma imagem humana clara e verdadeira do conjunto de dados. mas quando comparamos minuciosamente outras medidas estatísticas já discutidas, os termos principais de todos os tópicos na alocação latente de Dirichlet mostram claramente tópicos muito nítidos, claramente separados e também coesos para dizer a natureza do tópico individual, como o tópico um é sobre programa de TV, o tópico 2 é sobre o desempenho de John na brincadeira, o tópico 3 é sobre o personagem do filme, o tópico 4 é sobre família, o tópico 5 é sobre diversão, etc. Na semântica latente, os tópicos são bastante claros, mas

Machine Translated by Google

como na alocação latente de Dirichlet, como o tópico 1 e o tópico dois, também não estão bem separados, os tópicos 4 e 5. Portanto, em conclusão, pode-se afirmar que a análise semântica latente pode ser usada em muitas aplicações de processamento de linguagem natural, como resumo de texto, detecção de ambigüidade de palavras em informações recuperação, mas para modelagem de tópicos eficiente, como apresentação de temas semânticos em uma grande coleção de grandes conjuntos de dados, a alocação de Dirichlet latente baseada na teoria probabilística fornece resultados aceitáveis.

6. Evolução dos modelos de tópicos baseados em LDA

A evolução no LDA começou com o objetivo de obter o melhor modelo de linguagem incorporando o interesse do modelador (de acordo com os requisitos do domínio) ou específico da aplicação e apresentando a semântica oculta do conjunto de dados tão real quanto dada pelo ser humano. Por exemplo: o usuário pode estar interessado em encontrar correlação entre os diferentes tópicos discutidos no corpus, como atas de conferências de muitas décadas e muitos domínios, de modo que o profissional pode estar interessado em interesse específico de pesquisa temporal, conteúdo do autor e como os domínios estão mudando com o tempo, como o vocabulário nos domínios está mudando com o tempo, assim como a terminologia do aprendizado de máquina está mudando com o tempo, da palavra-chave “aprendizado de máquina” para “aprendizado profundo” e isso é verdade para todos os domínios. Essas evoluções são geradas na literatura de modelagem de tópicos relaxando a suposição básica da alocação latente de Dirichlet, bem como excluindo parâmetros desnecessários ou adicionando parâmetros importantes.

6.1 Modelos de Tópicos Supervisionados

O modelo de tópico supervisionado é desenvolvido para usar modelagem de tópico em análise preditiva. Cada documento é apresentado com uma variável de resposta [44]. O STM fornece anotações de rótulo único e de rótulo múltiplo em problemas de classificação e regressão. Uma atualização supervisionada de LDA como Slda [44], Med-LDA [50] e Discriminative LDA (Disc-LDA) [49] são desenvolvidas para categoria de rótulo único de classificação. Para classificação multirótulo, o generativo o modelo é rotulado como LDA (L-Lda) [48]. É uma tecnologia para anotação ou rotulagem de imagens em cenas grandes e classificação de um documento baseado em revisão em página web, e em uma base científica coleção de artigos, anote o documento com o nº. de downloads em um determinado tempo. Trabalhos recentes sobre supervisão a modelagem de tópicos inclui Prior-LDA e Dependency-LDA, para classificação multirótulo. A vantagem do STM é que a previsão do rótulo é feita no nível da palavra, em vez de abordagens tradicionais de classificação onde isso é feito em nível do documento e a rotulagem de todos os documentos é concluída simultaneamente, novamente um fator importante para medições mais precisas classificação. Para uma perspectiva de regressão, diferente de Slda para abordagens mais relevantes são o multinomial de Dirichlet regressão [51] e o modelo de tópico de regressão inversa [52].

6.2 Modelo de Tópico Correlacionado

A alocação latente de Dirichlet é capaz o suficiente para ser considerada uma ferramenta eficaz para a análise estatística de coleções de documentos. O LDA considera que as palavras de cada documento surgem de múltiplos tópicos e cada tópico individual é uma distribuição no vocabulário. Nos dados da vida real, todos os tópicos coletados estão correlacionados de alguma forma.
Por exemplo, é mais provável que um documento sobre desporto seja sobre saúde do que sobre finanças. Assim, o algoritmo do modelo de tópico correlacionado é desenvolvido neste tópico, a proporção exibe correlação através da distribuição normal logística [53]. O Modelo de Tópico Correlacionado (CTM) com distribuição mais flexível nas proporções dos tópicos encontra uma estrutura de covariância entre os componentes [45]. Essa estrutura de covariância lançou as bases para revelar um modelo mais realista de estrutura de tópico latente para encontrar correlação entre os tópicos. No arquivo JSTOR de dados científicos de periódicos [12], é demonstrado que o CTM fornece uma maneira natural de visualizar e explorar a coleção de documentos. A inferência posterior é um grande desafio no CTM, portanto métodos variacionais de campo médio são usados para obter eficientemente uma aproximação dessa distribuição posterior.

6.3. Modelo de tópico de alocação Pachinko

Pachinko Allocation Topic Model (PAM) é um algoritmo avançado para explorar a correlação em documentos não estruturados complicados por meio de estrutura de gráfico acíclico direcionado (DAG) [54]. É poderoso o suficiente para aprender correlação de tópicos aninhados, arbitrários e esparsos no corpus. O PAM exibe correlação de palavras no vocabulário, bem como correlações entre tópicos [55]. Pode ser uma hierarquia simples ou um gráfico acíclico direcionado com arestas cruzadas ou com nós ausentes. No PAM cada nó folha está associado a uma palavra do vocabulário e cada nó interior corresponde a um tópico, com distribuição de Dirichlet sobre seus tópicos filhos e esses tópicos filhos são tópicos tradicionais no modelo de alocação latente de Dirichlet (LDA), representando assim uma mistura sobre tópicos. Embora o PAM forneça uma maneira poderosa de extrair correlação entre tópicos em grandes coleções de texto. Tem o mesmo problema tradicional – Como determinar o número ideal de tópicos. Portanto, uma contribuição significativa inclui Bayesiano não paramétrico antes de determinar automaticamente o número de tópicos [65].

6.4. Modelo de tópico hierárquico

O modelo de tópico hierárquico é um algoritmo que relaxa a teoria dominante de alocação de Dirichlet Latente (LDA) de que cada documento só poderia ter tópicos limitados. No LDA, a distribuição da mistura é feita em um número k predefinido de tópicos. Num CTM avançado, o LDA é alargado para considerar –
encontrar relacionamento entre diferentes tópicos, mas o número de tópicos é fixo, incapaz de traçar o nível de abstração de um tópico na hierarquia. Portanto, a modelagem hierárquica de tópicos é uma abordagem

Machine Translated by Google

na TM para encontrar tópicos mais absolutos e organizar os tópicos de acordo com uma hierarquia na qual os tópicos mais abstratos aparecem perto da raiz da hierarquia e os mais concretos aparecem perto das folhas [68]. O Hirarchial-lda gera uma distribuição de mistura em tópicos usando um CRP (Processo de Restaurantes Chineses) aninhado [56].

6.5. Modelos de tópicos esféricos

O Modelo de Mistura Esférica é um modelo de tópico que integra os recursos de mistura das distribuições de von Mises-Fisher (movMF) [57] com LDA, para modelar diferentes aspectos dos dados [58]. Tanto na modelagem de tópicos quanto na aplicação de redução de dimensionalidade, descobriu-se que o modelo de mistura esférica produz características de tópico mais relevantes do que o modelo de mistura esférica movMF ou LDA. Esférico
O modelo de mistura tem desempenho superior devido aos seus três atributos: distância do cosseno, termos negativos e ausência/presença de palavras. Outro modelo para modelar a ausência de palavras é a probabilidade multivariada de Bernoulli [59]. O modelo de mistura esférica usa a probabilidade de Mises Fisher para modelar dados com mais precisão do que o modelo multinomial [60]. O modelo de mistura esférica usa campo médio variacional como técnica de inferência.

6.6. Modelo de tópico do autor

O modelo de tópico do autor é uma abordagem de modelo generativo para o modelo de tópico do autor que simula o conteúdo do documento e o interesse dos autores [61]. É uma extensão do LDA para incluir informações de autoria. Cada autor está associado a uma distribuição multinomial sobre tópicos e cada tópico está associado a uma distribuição multinomial sobre vocabulário.
Antes do modelo de tópico do autor, outras abordagens eram baseadas em recursos estilométricos [62], como recursos estilísticos do corpus de texto, incluindo frequência de certas palavras, palavras irrelevantes, comprimento de frase e diversidade do vocabulário do autor usado para encontrar atributos de autores em coleções de texto.

6.7 Modelo de Tópico Multilíngue

Modelo de tópico multilíngue (MTM) é a metodologia para detectar temas ou tópicos semânticos em corpus, onde o vocabulário do corpus não se restringe a apenas um idioma. A rede mundial de computadores está contribuindo para que o conhecimento em vários idiomas surja de diferentes continentes [46]. O MTM tem suas raízes profundas em 2004, quando o primeiro modelo de análise semântica latente para línguas multilíngues foi desenvolvido [46].
PolyLDA é baseado no conceito de alocação latente de Dirichlet e o estende para extrair temas semânticos em vários idiomas paralelamente. Este modelo recebe informações de vários documentos, consiste em vários idiomas e descobre T tópicos em cada idioma paralelamente [45]. PolyLDA implementado para corpus de alemão, grego, inglês, dinamarquês e espanhol, etc. MuTo (modelo de tópico multilíngue para texto não alinhado) assume que temas semelhantes aparecem em vários idiomas e descobrem os tópicos em nível de vocabulário no corpus [47].

6.8 Modelo de Tópico Dinâmico

DTM é um modelo de tópico que limita a suposição de permutabilidade do LDA, ao contrário do CTM no nível do corpus. Supõe-se no CTM que os termos podem ser trocados tanto dentro do documento quanto no corpus. Mas na realidade, esta suposição não é apropriada, a literatura de qualquer domínio evolui com o tempo, e também o vocabulário usado para representar a área de estudo, por exemplo, Nanotecnologia em 1950 é
totalmente diferente do que era em 1990. Os temas da coleção evoluem com o tempo. Portanto, o DTM se preocupa em detectar os tópicos do corpus também com sua dinâmica.
O DTM revela a evolução dos tópicos nos corpora dividindo os corpora em intervalos de tempo. Por exemplo, por ano, por décadas, etc. Cada fatia é modelada com tópico de componente k
modelo e cada fatia de tempo t evolui da fatia t-1. Nesta logística é utilizada a distribuição normal e métodos variacionais são utilizados para inferência posterior aproximada. No DTM a distância de Hellinger é usada para pontuação de similaridade. Esta métrica de similaridade tem o potencial de fornecer uma noção de similaridade de documentos baseada no tempo. Os dois artigos sobre
a física pode ser semelhante, mesmo que se use vocabulário de 1950 e outro de 2017. Um modelo de tópico dinâmico de análise de aprendizagem Modelo de tópico dinâmico-iterativo (Iterativo-DTM) que pode acomodar a evolução de todo o número ilimitado de tópicos, os tópicos podem morrer ou nasce em qualquer época e a representação de cada tema evolui segundo uma dinâmica Markoviana [63].

6.9 Modelo de Tópico Sintático

Modelagem de tópicos baseada na abordagem BOW (Bag of Word), onde as palavras podem ser trocadas no corpus e sua probabilidade é estável na permutação [65]. Esses modelos provaram ser úteis para analisar rapidamente corpus muito grandes e bem-sucedidos para classificação e recuperação de informações [64].
O modelo de tópico baseado em BOW é suficiente onde a pegada estatística abstrata dos temas do documento é suficiente para o sucesso, mas falha onde são necessárias qualidades de linguagem mais refinadas. Portanto, modelo de tópico sintático, um modelo de tópico Bayesiano não paramétrico é desenvolvido para inferir tópicos sintática e semanticamente coerentes. Trabalhos anteriores sobre a consideração de recursos sintáticos incluem
modelo espacial [65] e modelos de sequência linear [66] [67]
Esses modelos têm um trabalho significativo no domínio da aplicação de desambiguação de sentido de palavras no processamento de linguagem natural.

Machine Translated by Google

7. Aplicações de modelagem de tópicos em diversas áreas de pesquisa de tecnologia

A modelagem de tópicos se espalhou em diversas áreas de pesquisa nas últimas duas décadas desde seu início, como Pesquisa Científica, Bioinformática, Redes Sociais, Software
Engenharia e em muitos outros domínios.

7.1 Pesquisa Científica

O primeiro modelo generativo para modelagem de tópicos conhecido como alocação de Dirichlet latente (LDA). Neste David M.Blei explora a literatura científica de 16.000 documentos de um subconjunto do corpus TREC AP (Harman 1992) com 100 tópicos [1]. o modelo estendido denominado modelo de tópico correlacionado e modelo de tópico dinâmico foi aplicado no conjunto de dados dos arquivos JSTOR ao artigo publicado de 1980-2002 [12]. 17.000 artigos da revista científica com 100 tópicos e do jornal jurídico de Yale com 20 tópicos foram feitos por David M Blei [4].

Thomas L Griffiths e Mark Steyvers usam modelagem de tópicos para conjuntos de dados de resumos PNAS e exploraram tendências de pesquisa em artigos publicados e os distinguem como tópicos quentes e frios.
Os tópicos descobertos pelo LDA usando a inferência de amostragem de Gibbs selecionam uma estrutura significativa da ciência e revelam algumas das relações entre artigos científicos em diferentes disciplinas [68]. Nicholas analisou uma área de pesquisa interdisciplinar financiada pela fundação científica usando algoritmos de modelagem de tópicos [69]. Isto ajuda os administradores de fundações científicas a compreender melhor o conteúdo e o contexto dos portfólios de financiamento, a fim de ajudar a promover futuros planos de financiamento científico. Um modelo de tópico é apresentado para modelar simultaneamente artigos, autores e locais de publicação, conhecido como modelo de tópico de conferência de autores [73]. Inclui dados de 14.134 autores, 10.716 artigos e 1.434 conferências de Arnet Miner. Em um modelo de tópico mais avançado onde a filtragem colaborativa tradicional e a modelagem probabilística de tópicos são combinadas e fornece um sistema para recomendar artigos científicos para usuários da comunidade online [70][71]72]. Uma outra perspectiva de modelagem de tópicos de campos de pesquisa por Michael Paul, neste LDA é usada para classificar artigos de pesquisa com base em tópico e idioma. Nestas várias estatísticas perspicazes e correlações dentro e entre três campos de pesquisa: linguística, linguística computacional, educação foram encontradas [85].

7.2 Bioinformática

O modo tópico é um método útil em comparação com meios tradicionais, como classificação e agrupamento em bioinformática, e aumenta a capacidade do médico de interpretar informações biológicas [87]. Em 2006, um estudo de modelagem estatística de corpora biomédicos por David Blei demonstra que um modelo LDA pode ser empregado para inferir fatores ocultos que permeiam um corpus de texto biomédico para sintetizar e organizar informações sobre fenômenos biológicos complexos [88]. A Análise Semântica Latente Probabilística (PLSA) em 2010 empregada em conjunto de dados de microarranjos de expressão para extração de bio-Clusters, este modelo agrupa simultaneamente genes e amostras. Um modelo de tópico Ensemble para compartilhar dados de saúde e prever o risco de doenças foi desenvolvido por Andrew et al. Nesta abordagem, o modelo é desenvolvido para permitir o compartilhamento de informações benéficas enquanto permanece dentro dos limites da privacidade dos dados [84].

A composição do nível do genoma das sequências de DNA é analisada usando modelos probabilísticos (74). John Barnett e Tommy Jakkola usam modelagem de tópicos para análise de expressão genética.
O perfil de expressão gênica fornece uma janela para o funcionamento interno da célula, conforme exibido através dos níveis de RNA mensageiro (75). Os medicamentos impactam diferentes vias dentro da célula e a via ativa pode ser diferente dentro dos tipos de células.
Compreender com mais precisão quais vias são afetadas por medicamentos em tipos de células específicos abre novas possibilidades para medicamentos mais direcionados ou terapias combinadas de medicamentos.

7.3 Análise de Redes Sociais

A grande quantidade de dados disponíveis nas plataformas sociais abre novas oportunidades para a mineração de informações sobre o mundo real. Devido à sua popularidade e ampla utilização, pode ser utilizado para inferir aspectos importantes sobre os usuários desses serviços e sobre o que acontece em seu entorno.
Young Chul Cha et al descreveram a análise de redes sociais usando modelo de tópicos, neste artigo, aplicaram LDA para analisar o gráfico de relacionamento em uma grande rede social [77]. Diferente das abordagens usuais que extraem tópicos de dados textuais como Bio e tweets, esta abordagem depende puramente de um gráfico de rede social que consiste em bordas de seguimento. Esse
abordagem é especialmente útil quando apenas dados de ligação estão disponíveis. Em 2009, Justin Grimmer apresentou um modelo de tópico hierárquico bayesiano para análise política para medir agendas expressas em comunicados de imprensa do Senado [78]. Ele aborda
as questões para medir eficientemente as prioridades que os actores políticos enfatizam nas declarações. Debashis Naskar et al desenvolveram SentLDA – um modelo generativo para identificar os sentimentos dos usuários na rede social por meio de suas conversas [79]. É desenvolvido um modelo de tópico de destinatário de autor para análise de rede social [81], que aprende a distribuição de tópicos com base na direção das mensagens sensíveis enviadas entre entidades. É desenvolvida uma alocação Dirichlet latente de múltiplos atributos (MA-LDA), na qual os atributos de tempo e hash tag de microblogs são incorporados ao modelo LDA [80].

Este método fornece fortes evidências da importância do fator temporal na extração de tópicos importantes.

7.4 Engenharia de Software

Com a evolução da indústria de software, um grande volume de dados é produzido em diversos repositórios de software, dentre esses dados, estima-se que entre 80% e 85% dos dados em repositórios de software não são estruturados. Por exemplo, código-fonte, documentação, casos de teste, repositórios de bugs, etc.
A mineração desses repositórios não estruturados pode revelar informações interessantes e acionáveis para apoiar várias tarefas de engenharia de software, como compreensão do programa, localização e recuperação de link de rastreabilidade [83].

Machine Translated by Google

A suposição subjacente para usar modelagem de tópicos em repositórios de software é que os fatos artísticos de software compartilham as mesmas características textuais que o texto em linguagem natural. Assim, a configuração do LDA para tarefas de Engenharia de software usando o mesmo parâmetro usado para linguagem natural é bastante fácil.
Assim, LDA-Ga, uma abordagem genética para tarefas de engenharia de software, como descoberta de link de rastreabilidade, foi desenvolvida para identificar uma configuração quase ideal de LDA. Para parâmetros LDA, mais especificamente, LDA-GA utiliza a coerência de documentos pertencentes ao mesmo tópico para derivar a evolução do GA
[82]. Novamente, uma análise detalhada da evolução do software no histórico do código-fonte dos conhecidos sistemas Hot Draw e J-Edit foi realizada usando modelagem de tópicos.

8. Desafios da modelagem de tópicos

Nas últimas duas décadas, embora a modelagem de tópicos tenha sido explorada em vários domínios, incluindo mineração de texto na literatura científica, engenharia de software, bioinformática e análise de redes sociais e muitas áreas de pesquisa de recuperação de informação. E milhares de artigos foram escritos e modelos foram desenvolvidos. De acordo com nossos estudos, alguns domínios onde a modelagem de tópicos pode ser utilizada ainda são inexplorados. E certos aspectos através dos quais a modelagem de tópicos pode ser entendida de forma mais significativa devem ser desenvolvidos. Portanto, de acordo com nosso estudo, algumas questões requerem mais pesquisas e exigem mais contribuições para explorar completamente a visão que a modelagem de tópicos da leitura à distância torna possível. Essas áreas de exploração adicional são as seguintes.

8.1 Visualização

Os modelos de tópicos representam uma modelagem abstrata que é totalmente abstrata para o modelador e para os usuários finais de várias maneiras [47]. Para entender a coleção de documentos, os tópicos em um modelo de tópico que é a distribuição de palavras com a probabilidade máxima em um tópico, explicar o que é um tópico. Portanto, a forma mais comum de entender os tópicos é por meio da visualização. A saída mais comum dos algoritmos de modelagem de tópicos são os principais termos de cada tópico individual usando uma lista de palavras. Outra abordagem mais popular é a nuvem de palavras. A visualização do modelo de tópico (TMVE) é uma ferramenta que representa cada tópico com os tópicos mais relacionados, bem como com a maioria dos documentos relacionados. Isso é calculado através de ÿd – a porcentagem da proporção dos tópicos em cada documento.

Ferramentas de visualização são desenvolvidas como cupim [85] Cupim é uma visualização interativa compacta e intuitiva dos tópicos em um modelo de tópico, mas incluindo apenas termos com alta classificação em saliência ou distinção, que são propriedades globais dos termos. Ele se restringe a fornecer uma visão global do modelo, em vez de permitir que um usuário inspecione profundamente um tópico individual, visualizando um conjunto de termos potencialmente diferente para cada tópico.

Topic Nets [86] usa redução de dimensão na composição de tópicos para plotar documentos em espaço 2D. Mas não mostra composições de tópicos ou documentos. LDAvis [87] aborda diretamente o problema de verificação de modelo auxiliando o tópico interpretação através de um método de relevância para classificação de termos dentro de tópicos para exibição aos usuários finais. Ele fornece uma visão global dos tópicos, ao mesmo tempo que permite uma inspeção profunda dos termos mais associados ao tópico individual. Os termos são classificados de acordo com sua probabilidade em um tópico abaixo do ideal. A incerteza nos modelos de tópicos surge devido a métodos multimodalidade, diferentes métodos de pré-processamento de texto e múltiplos pontos de vista e perspectivas humanas no julgamento da qualidade do tópico.

8.2 Interpretação da Modelagem de Tópicos

A visualização pode ajudar em detalhes sobre a compreensão da saída do modelo de tópico e dos problemas de modelagem. Avaliar a qualidade do modelo de tópico é uma etapa para a interpretabilidade por produto. A métrica mais amplamente utilizada para a qualidade do modelo de tópico foi a probabilidade mantida [96]. Chang et al., mostra que a métrica de qualidade da probabilidade mantida não é adequada para fornecer facilidade de interpretabilidade em modelos probabilísticos. A medição automática da qualidade do tópico é um bom candidato para verificações de qualidade e interpretabilidade [97] [98]. Outro trabalho enfatiza em encontrar o modelo de tópico adequado para aplicação específica e também em encontrar o relacionamento entre múltiplos modelos para melhor interpretável por humanos.

8.3 Modelagem de Tópicos com Eficiência de Memória

Os modelos de tópicos fornecem uma ferramenta útil na análise de coleções de textos complicadas, mas sua complexidade computacional tem dificultado seu uso em aplicações em larga escala e em tempo real.
Embora tenha havido trabalho suficiente sobre modelagem e melhoria da estimativa do tempo de treinamento em modelos de tópicos, foi feito [88] [89]. Tem sido dada pouca atenção ao importante problema prático de inferir a distribuição de tópicos, dados os modelos existentes. LDA é uma modelagem de tópicos eficaz usada na classificação, seleção de recursos e recuperação de informações; no entanto, o uso de LDA em grandes conjuntos de dados leva horas, até dias, devido à computação pesada e ao acesso intensivo à memória.

Portanto, a GPU (Unidade de Processamento Gráfico) é usada para acelerar o treinamento LDA em uma única máquina. Neste GLDA, alcance uma aceleração de 15X em relação ao LDA original baseado em CPU para treinamento eficiente de LDA em grandes conjuntos de dados em uma GPU por estimativa de média para modo [90]. A estimativa da média para o modo é uma variante da amostragem de Gibbs não recolhida que usa a média da distribuição de Dirichlet para fazer estimativas pontuais e pode ser implementada de forma eficiente em GPUs. O algoritmo expõe muito paralelismo e tem bom desempenho estatístico.

8.4 Estabilidade

Outro desafio importante na modelagem de tópicos é a estabilidade.
A estabilidade pode ser definida na modelagem de tópicos como aquele algoritmo de modelagem de tópicos aplicado ao mesmo conjunto de dados com os mesmos parâmetros em múltiplas execuções em vários momentos, a saída não é necessariamente a mesma. A análise de estabilidade na modelagem de tópicos mostrou que o resultado tradicional da modelagem de tópicos é instável tanto quando o modelo é retido na mesma entrada

Machine Translated by Google

documentos e quando é atualizado com novos documentos. Então, como podemos produzir um modelo de tópico definitivo que seja estável e preciso. Muito pouco trabalho feito sobre análise de estabilidade em algoritmos de fatoração de matrizes negativas e incluindo NNMF. A maioria dos autores de TM não aborda esse problema e, em vez disso, simplesmente utiliza uma única inicialização aleatória e apresenta o resultado da TM como definitivo. Outro desafio na MT é a identificação de tópicos coerentes em dados ruidosos, como tweets [91].

A estratégia mais comum para reduzir a instabilidade na aprendizagem não supervisionada é usar técnicas de agrupamento de conjuntos, que se baseiam na ideia de que a combinação de conjuntos grandes e diversos de agrupamento pode produzir soluções mais estáveis e precisas. [92] [93] [94], Trabalhos sobre o

otimalidade e consistência de soluções produzidas por algoritmos de clustering e Bio clustering. Em TM, alguns trabalhos iniciais de estabilidade usando conjuntos feitos em fatoração de matrizes. Isso inclui o uso de um esquema hierárquico para combinar fatoração múltipla, no estudo de redes de proteínas [95]. No entanto, estes estudos não investigaram a extensão dos problemas introduzidos pela instabilidade no contexto da Modelagem de Tópicos.

9. Kit de ferramentas de modelagem de tópicos

Duas décadas de pesquisa em modelagem de tópicos produziram vários kits de ferramentas para o desenvolvimento de uma ampla gama de aplicações de modelos de tópicos. Esses kits de ferramentas são usados em vários domínios, incluindo ciências cognitivas, análise social da web, bioinformática, processamento de linguagem natural, engenharia de software e em muitos outros.

Gensim: É uma biblioteca gratuita projetada para extrair automaticamente tópicos semânticos de documentos de forma muito eficiente em python.
Os algoritmos implementados no Gensim são LSA, LDA e Projeções Aleatórias. Esses algoritmos são de natureza não supervisionada, o que significa que padrões semânticos são encontrados estatisticamente em documentos sem quaisquer metadados, só precisam de um corpus de documentos de texto simples [107].

Caixa de ferramentas de modelagem de tópicos de Stanford (TMT): Esta caixa de ferramentas foi escrita no grupo de PNL de Stanford por Daniel Ramage e Evan Rosen em setembro de 2009 [108]. Foi escrito em linguagem Scala usando biblioteca de álgebra linear. O TMT pode ser usado apenas para detectar padrões semânticos em conjuntos de dados textuais. LDA e suas duas versões aprimoradas Labeled LDA e PLDA são implementadas em Stanford TMT.

MALLET: A implementação do modelo de tópico MALLET é uma ferramenta extremamente rápida e altamente escalável com amostragem de Gibbs, otimização de hiperparâmetros de tópico e módulos para inferir tópicos para novos documentos a partir de modelos treinados [106].
MALLET inclui Alocação Latente de Dirichlet, Alocação Pachinko e LDA Hierárquica. Para implementação otimizada do algoritmo de modelagem de tópicos, isso depende da otimização numérica.

Pacotes R: A linguagem R possui um rico conjunto de pacotes ou biblioteca especial para modelagem de tópicos eficiente, incluindo lsa [101], lsafun[102],lda[103],topicmodels[105],textmineR[100],text2 coisa[104].

10. Conclusão

Da última década e meia, a modelagem de tópicos usando alocação latente de Dirichlet (LDA) é muito popular na comunidade de aprendizado de máquina e processamento de linguagem natural para lidar com grandes quantidades de dados não estruturados e anotar esses dados com temas e tópicos. Neste artigo, fornecemos uma pesquisa abrangente sobre modelos de tópicos usando uma nova hierarquia de classificação. Diferentes métodos de modelo de tópicos, como LSA, NMF, PLSA e LDA, também são explicados em detalhes.

A avaliação quantitativa das técnicas de modelagem de tópicos também é apresentado com análise detalhada, diferentes modelos evolutivos de alocação de Dirichlet latente também são apresentados pela primeira vez, são explicadas diferentes áreas de aplicação do modelo de tópico, como pesquisa científica, bioinformática, análise de redes sociais e engenharia de software. Embora a modelagem de tópicos
foram explorados em muitas áreas de pesquisa, mas de acordo com nossos estudos, alguns domínios onde a modelagem de tópicos pode ser usada ainda são inexplorados, como processamento de fala, processamento de imagens e detecção de temas em conjuntos de dados de áudio e vídeo. E certos aspectos através dos quais a modelagem de tópicos pode ser entendida de forma mais significativa devem ser desenvolvidos. Neste artigo, vários aspectos desafiadores da modelagem de tópicos incluem visualização de tópicos, interpretação de tópicos como humanos, modelos de tópicos com eficiência de memória e estabilidade da modelagem de tópicos também são identificados e discutidos. Embora a modelagem de tópicos tenha percorrido um longo caminho em duas décadas, certas questões ainda não foram resolvidas. Isso inclui: • Como selecionar o número ideal de tópicos. alguns

abordagens como perplexidade, probabilidade logarítmica de retenção documentos, média harmônica, validação cruzada são algumas abordagens, mas os resultados ainda são ambíguos.

- Como escolher os anteriores, a escolha dos anteriores tem influência direta efeito sobre a probabilidade de documentos retidos e o qualidade dos tópicos inferidos. Quais anteriores são mais parecidas Simétrico ou Assimétrico e qual é o mais adequado para o problema em questão? Nenhum estudo rigoroso é disponível na escolha dos anteriores.
- Qual técnica de inferência é mais adequada para domínio do problema, como inferência variacional e A amostragem de Gibbs dominou a modelagem de tópicos das últimas duas décadas, mas o que é melhor ainda não é responsável?

Assim, com o avanço na modelagem de tópicos, várias versões estendidas do LDA e baseadas em teorias relacionadas passaram a existir e foram usadas nas últimas duas décadas em diversas aplicações, incluindo mineração de texto, pesquisa biomédica, análise de sentimentos, tecnologia de fala, processamento de imagens, filtragem colaborativa, dados de pesquisas sobre deficiência, genética populacional e modelagem de dados sequenciais e de usuários, etc.

Referências

[1] Blei, DM (2012) Probabilístico modelos de tópicos. *Comunicações da ACM,* 55(4): pp.77_84.

Machine Translated by Google

[2] Crain, SP, Zhou, K., Yang, SH e Zha, H. (2012) Redução de dimensionalidade e modelagem de tópicos: da indexação semântica latente à alocação latente de Dirichlet e muito mais. *Em Mineração de dados de texto. Springer, Boston,* pp.129_161.

[3] Ghorab, MR, Zhou, D., O'Connor, A., & Wade, V. (2013) Recuperação de informação personalizada: Pesquisa e classificação, *Modelagem de Usuário e Interação Adaptada ao Usuário,* 23(4): pp.381_443.

[4] Blei, DM, Ng, AY, & Jordan, MI (2003) Alocação latente de Dirichlet, *Journal of Machine Learning Research,* 3 (janeiro): pp.993_1022.

[5] Salton, G., Wong, A., & Yang, CS (1975) Um modelo de espaço vetorial para indexação automática, *Communications of the ACM,* 18(11): pp.

[6] Berry, MW, Drmac, Z. e Jessup, ER (1999). Matrizes, espaços vetoriais e recuperação de informação, *revisão SIAM,* 41(2): pp.335_362.

[7] Berry, MW, Dumais, ST, & O, Brien, GW (1995) Usando álgebra linear para recuperação inteligente de informação, *revisão SIAM,* 37(4): pp.573_595.

[8] Turney, PD, & Pantel, P. (2010) Da frequência ao significado: modelos de espaço vetorial de semântica, Journal of artificial intelligence research, 37: pp.141_188.

[9] Nakov, P., & Hearst, M. A, (2008) Resolvendo problemas de similaridade relacional usando a web como corpus, Proceedings of ACL-08: HLT, pp.452_460.

[10] Sparck Jones, K, “Uma interpretação estatística da especificidade do termo e sua aplicação na recuperação”, Jornal de documentação, 28(1), pp.11_21,2012.

[11] Jelisavcic, V., Furlan, B., Protiÿ, J e Milutinoviÿ. (2012) Modelos de tópicos e algoritmos avançados para perfil de conhecimento em artigos científicos, In MIPRO, Proceedings of the International Convention. págs.1030_1035.

[12] Alghamdi, R., & Alfalqi, K. (2015) Uma pesquisa de modelagem de tópicos em mineração de texto, Int. J. Adv. Computador. Ciência. Apl. (IJACSA), 6(1).

[13] Deerwester, S., Dumais, ST, Furnas, G. W, Landauer, TK, & Harshman, R. (1990) Indexação por análise semântica latente, Journal of the American Society for Information Science, 41 (6): 391.

[14] Paatero, P., & Tapper, U (1994) Fatoração de matriz positiva: Um modelo de fator não negativo com utilização ideal de estimativas de erro de valores de dados, Environmetrics, 5(2): pp.111_126.

[15] Paatero, P. (1997) Formulação de mínimos quadrados de análise fatorial robusta não negativa, Quimiometria e sistemas laboratoriais inteligentes, 37(1): pp.23_35.

[16] Lee, DD, & Seung, HS (1999) Aprendendo as partes de objetos por fatoração de matriz não negativa, Nature, 401: pp.6755_67788.

[17] Lee, DD, & Seung, HS (2001) Algoritmos para fatoração de matriz não negativa, em Avanços em sistemas de processamento de informações neurais, pp.556_562.

[18] Berry, MW, & Martin, D. (2005) Análise de componentes principais para recuperação de informações, In E. Kontoghiorghes (Série Ed.), Estatísticas: uma série de livros didáticos e monografias: Manual de computação paralela e estatística, pp. 399_413, [19] Buckley, C., Allan, J., & Salton, G. (1994) Roteamento automático e recuperação ad-hoc usando SMART: TREC 2. NIST PUBLICAÇÃO ESPECIAL SP: pp.45_45.

[20] Kherwa, P., & Bansal, P. (2017) Análise Semântica Latente: Uma Abordagem para Compreender a Semântica do Texto, Na Conferência Internacional sobre Tendências Atuais em Computação, Elétrica, Eletrônica e Comunicação (CTCEEC), pp.870_874.

[21] Berry, MW (1992) Cálculos de valores singulares esparsos em grande escala, The International Journal of Supercomputing Applications, 6(1), pp.13_49, [22] Golub, G. C, Van Loan. (1989) Matrix Computações, John Hopkins UP, Baltimore.

[23] Berry, MW, & Fierro, RD (1999) Decomposições ortogonais de baixa classificação para aplicações de recuperação de informação, Álgebra linear numérica com aplicações, 3(4): pp.301_327.

[24] Paatero, P., & Tapper, U. (1994) Fatoração de matriz positiva: Um modelo de fator não negativo com utilização ideal de estimativas de erro de valores de dados, Environmetrics,5(2): pp.111_126.

[25] Lee, DD, & Seung, HS (1999) Aprendendo as partes de objetos por fatoração de matriz não negativa. Natureza, 401: pp.6755_ 6788.

[26] Cai, D., He, X., Wu, X., & Han, J. (2008) Fatoração de matriz não negativa em variedade, In Data Mining, ICDM'08. Oitava Conferência Internacional IEEE sobre Mineração de Dados. páginas 63_72.

[27] Kreutz-Delgado, K., Murray, JF, Rao, BD, Engan, K., Lee, TW, & Sejnowski, TJ (2003) Algoritmos de aprendizagem de dicionário para representação esparsa, Computação Neural, 15 (2) : pp .349_3

[28] Zdunek, R., & Cichocki, A. (2007) Fatoração de matriz não negativa com otimização de segunda ordem restrita, *Signal Processing,* 87(8): pp.1904_1916.

[29] Cichocki, A., & Zdunek, R. (2007) Algoritmos de mínimos quadrados alternados regularizados para fatoração de matriz/tensor não negativa, *In International Symposium on Neural Networks:* pp.793_802, J. Springer, Berlim, Heidelberg.

[30] Hofmann, T. (1999) Análise semântica latente probabilística, *Em Anais da Décima Quinta Conferência sobre Inteligência Artificial de Incerteza,* pp.289_296.Morgan Kaufmann Publishers Inc..

[31] Hofmann, T. (2017) Indexação semântica latente probabilística”, *In ACM SIGIR Forum* Vol.51, No.

[32] De Finetti, B. (2017) Teoria da probabilidade: um tratamento introdutório crítico, Vol. 6, John Wiley e Filhos.

[33] Kintsch, W. (2006) Análise semântica latente: *Um caminho para o significado. Laurence Erlbaum.*

[34] Lee, DD e Seung, HS (1999) Aprendendo as partes dos objetos por fatoração de matriz não negativa, *Nature,* 401: pp.788-791.

[35] J.-P. Brunet, P. Tamayo, TR Golun e JP Mesirov (2004) Metagenes e padrão molecular

Machine Translated by Google

descoberta usando fatoração de matrizes, *Proc. Nat. Acad. Ciência. EUA,* vol. 101, não. 12. pp.4164–4169

[36] Xing, EP, Jordan, MI, & Russell, S. (2002) Um algoritmo de campo médio generalizado para inferência variacional em famílias exponenciais, *Em Anais da Décima Nona Conferência sobre Incerteza em* Inteligência Artificial. Pág.583_591. Morgan Kaufmann Publishers Inc.

[37] Teh, YW, Newman, D., & Welling, M. (2007) Um algoritmo de inferência bayesiana variacional colapsado para alocação latente de Dirichlet, *Em Avanços em sistemas de processamento de informações neurais,* pp.

[38] Minka, T., & Lafferty, J. (2002) Propagação de expectativa para o modelo de aspecto generativo, *In Proceedings of the Eighteenth Conference on Uncertainty in artificial intelligence,* pp.352_359. Morgan Kaufmann Publishers Inc.

[39] Wainwright, MJ e Jordan, MI (2005) A Princípio Variacional para Modelos Gráficos.

[40] K. Bryan, P. Cunningham e N. Bolshunov. (2006) Aplicação de recozimento simulado ao bioagrupamento de dados de expressão gênica. *IEEE Trans. Inf. Tecnologia. Biomédica.* vol. 10, não. 3: pp.519–525.

[41] Park, S., Cha, B., & An, D. (2010) Resumo automático de vários documentos com base em agrupamento e fatoração de matriz não negativa, *IETE Technical Review,* 27(2): pp.167_178.

[42] S. Dudoit, J. Fridlyand e T. P (2002) Velocidade: Comparação de métodos de discriminação para a classificação de tumor usando dados de expressão gênica, *J. Amer. Estado. Assoc.* vol. 97: pp.77_87.

[43] Geman, S. (1984) Distribuição Gibbs e restauração bayesiana de imagens, *IEEE Proc. Análise de Padrões e Inteligência de Máquina,* 6: pp.774_ 778.

[44] McAuliffe, JD, & Blei, DM (2008) Modelos de tópicos supervisionados, *Em Avanços em sistemas de processamento de informações neurais,* pp.121_128.

[45] Blei, DM, & Lafferty, JD (2007) Um modelo de tópico correlacionado da ciência", The Annals of Applied Statistics, pp.17_35.

[46] Mimno, D., Wallach, HM, Naradowsky, J., Smith, D. A., & McCallum, A. (2009) Modelos de tópicos polilíngues, *Em Anais da Conferência de 2009 sobre Métodos Empíricos em Processamento de Linguagem Natural,* Volume2: pp.880_889.

[47] Boyd-Graber, J., & Blei, DM (2009) Modelos de tópicos multilíngues para texto não alinhado, *Em Anais da Vigésima Quinta Conferência sobre Incerteza em Inteligência Artificial,* pp. Imprensa AUAI.

[48] Liu, X., Duh, K. e Matsumoto, Y. (2015) Modelos de tópicos multilíngues para extração de dicionário bilíngue, *Transações ACM em processamento de informações em idiomas asiáticos e de poucos recursos,* 14(3), 11.

[49] Ramage, D., Hall, D., Nallapati, R., & Manning, CD (2009) Rotulado LDA: Um modelo de tópico supervisionado para corpora de atribuição de crédito, *em Anais da Conferência de 2009 sobre Métodos Empíricos em Processamento de Linguagem Natural:* Volume 1, pp.248_256.Associação para computacional Linguística.

[50] Lacoste-Julien, S., Sha, F. e Jordan, MI (2009) Disc-LDA: Aprendizagem discriminativa para redução e classificação de dimensionalidade, *Em Avanços em sistemas de processamento de informação* neural.pp.897_904.

[51] Zhu, J., Ahmed, A., & Xing, EP (2012) Med-LDA: Modelos de tópicos supervisionados com margem máxima, *Journal of Machine Learning Research,* 13: pp.2237_2278.

[52] Mimno, D. (2008) Modelos tópicos condicionados a recursos arbitrários com regressão multinomial de Dirichlet, *em Anais da 24ª Conferência sobre Incerteza em Inteligência Artificial 1.*

[53] Rabinovich, M., & Blei, D. (2014) O modelo de tópico de regressão inversa, *Na Conferência Internacional sobre Aprendizado de Máquina,* pp.

[54] Aitchison, J. (1982) A análise estatística de dados composicionais, *Journal of the Royal Statistical Society,* Série B, (Metodológico): pp.139_177.

[55] Li, W., & McCallum, A. (2006) Alocação de Pachinko: modelos de mistura estruturados em DAG de correlações de tópicos, *em Anais da 23ª conferência internacional sobre aprendizado de máquina,* pp. , Jordan, MI, Tenenbaum, JB, & Blei, DM (2004) Modelos de tópicos hierárquicos e o processo de restaurante chinês aninhado, Em *Avanços em sistemas de processamento de informações neurais,* pp.17_24.

[57] Wang, C., & Blei, D. M (2009) Inferência variacional para o processo de restaurante chinês aninhado, *In Advances in Neural Information Processing Systems,* pp.1990_1998.

[58] Banerjee, A., Dhillon, IS, Ghosh, J., & Sra, S. (2005) Clustering na hiperesfera unitária usando distribuições de von Mises-Fisher, *Journal of Machine Learning Research,* 6 (setembro): pp.1345_1382.

[59] Reisinger, J., Waters, A., Silverthorn, B., & Mooney, RJ (2010) Modelos de tópicos esféricos, *em Anais da 27ª conferência internacional sobre aprendizado de máquina* (ICML-10): pp.

[60] McCallum, A., & Nigam, K. (1998) Uma comparação de modelos de eventos para classificação de texto ingênua de Bayes, *No workshop AAAI-98 sobre aprendizagem para categorização de texto,* Vol. 752, nº 1: pp.41_48.

[61] Banerjee, A., Dhillon, IS, Ghosh, J., & Sra, S. (2005) Clustering na hiperesfera unitária usando distribuições de von Mises-Fisher, *Journal of Machine Learning Research,* 6, pp.1345_1382.

[62] Rosen-Zvi, M., Griffiths, T., Steyvers, M., & Smyth, P (2004) O modelo autor-tópico para autores e documentos, *em Anais da 20ª conferência sobre incerteza em inteligência artificial,* pp 487_494.

[63] Holmes, DI (1998) A evolução da estilometria nos estudos de humanidades, *Computação literária e linguística,* 13(3): pp.111_117.

[64] Girolami, M., & Kabán, A. (2004) Misturas simpliciais de cadeias de Markov: Modelagem distribuída de perfis dinâmicos de usuários, *Em Avanços em sistemas de processamento de informações neurais,* pp.

Machine Translated by Google

[65] Steyvers, M., & Griffiths, T. (2007) Modelos de tópicos probabilísticos, *Manual de análise semântica latente,* 427(7), pp.424_440.

[66] Padó, S., & Lapata, M. (2007) Construção baseada em dependência de modelos de espaço semântico, *Computational Linguistics,* 33(2): pp.161_199.

[67] Griffiths, TL, Steyvers, M., Blei, DM, & Tenenbaum, JB (2005) Integrando tópicos e sintaxe, *Em Avanços em sistemas de processamento de informações neurais,* pp.537_544.

[68] Gruber, A., Weiss, Y., & Rosen-Zvi, M. (2007) Modelos de Markov de tópico oculto, *em inteligência artificial e estatística.* págs.

[69] Griffiths, TL, & Steyvers, M. (2004) Encontrando tópicos científicos, *Proceedings of the National academy of Sciences,* 101, suppl 1: pp.5228_5235.

[70] Aletras, N., & Stevenson, M. (2014) Medindo a similaridade entre tópicos gerados automaticamente, *In Proceedings of the 14th Conference of the European Chapter of the Association for Computational Linguistics,* volume 2: Short Papers. págs. 22_27.

[71] Wang, C., & Blei, DM (2011) Modelagem colaborativa de tópicos para recomendação de artigos científicos, *em Anais da 17ª conferência internacional ACM SIGKDD sobre descoberta de conhecimento e mineração de dados,* pp.

[72] Paul, M., & Girju, R. (2009) Modelagem de tópicos de campos de pesquisa: Uma perspectiva interdisciplinar, *Em Anais da Conferência Internacional RANLP-2009,* pp.337_342.

[73] Liu, L., Tang, L., Dong, W., Yao, S. e Zhou, W. (2016) Uma visão geral da modelagem de tópicos e suas aplicações atuais em bioinformática, *Springer Plus,* 5(1),1608.

[74] Wang, J., Hu, X., Tu, X., & He, T. (2012) Modelo de conexão de tópico autor-conferência para pesquisa de rede acadêmica, Anais da 21ª conferência internacional ACM Gestão de informações e conhecimento . Págs.2179-2183.

[75] Zhao, W., Zou, W., & Chen, JJ (2014) Modelagem de tópicos para análise de cluster de grandes conjuntos de dados biológicos e médicos, *In BMC bioinformatics* Vol. 15, nº 11: pág. S11,

[76] Barnett, J., & Jaakkola, T. Research Abstracts-2007 [77] Bindra, A. (2012) Social-lda Modelagem de tópicos escaláveis em redes sociais, *Universidade de Washington.*

[78] Cha, Y., & Cho, J. (2012) Análise de redes sociais usando modelos de tópicos, *Em Anais da 35ª conferência internacional ACM SIGIR sobre Pesquisa e desenvolvimento em recuperação de informação,* pp.

[79] Grimmer, J. (2009) Um modelo de tópico hierárquico bayesiano para textos políticos, *apêndice suplementar.*

[80] Naskar, D., Mokaddem, S., Rebollo, M., & Onaindia, E. (2016) Análise de sentimento em redes sociais por meio de modelagem de tópicos, 2016. Em LREC.

[81] Wang, J., Li, L., Tan, F., Zhu, Y. e Feng, W. (2015) Detectando informações de pontos de acesso usando o modo de tópico baseado em vários atributos, l. PloS um, 10(10.

[82] Kuang, X., Chae, HS, Hughes, B., & Natriello, G. Um modelo de tópico LDA e análise de rede social de uma plataforma de blog escolar.

[83] Panichella, A., Dit, B., Oliveto, R., Di Penta, M., Poshynanyk, D., & De Lucia, A. (2013) Como usar efetivamente modelos de tópicos para tarefas de engenharia de software? uma abordagem baseada em algoritmos genéticos, *In Proceedings of Software Engineering (ICSE-2013) 35ª Conferência Internacional sobre Engenharia de Software.* págs.522_531.

[84] Hindle, A., Godfrey, MW e Holt, RC (2009) O que é interessante e o que não é: análise de tópicos para desenvolvedores em janelas, *In Software Maintenance, ICSM-2009.IEEE International Conference on Software Maintenance,* pp.

[85] Yao, L., Mimno, D. e McCallum, A. (2009). Métodos eficientes para inferência de modelos de tópicos em coleções de documentos de streaming. Nos Anais da 15ª conferência internacional ACM SIGKDD sobre descoberta de conhecimento e mineração de dados. páginas 937-946. ACM.

[86] Chuang, J., Manning, CD e Heer, J. (2012). Cupim: Técnicas de visualização para avaliar modelos de tópicos textuais, *em Anais da conferência internacional de trabalho sobre interfaces visuais avançadas,* pp. 74-77. ACM.

[87] Gretarsson, B., O'Donovan, J., Bostanjiev, S., Höllerer, T., Assunção, A., Newman, D., & Smyth, P. (2012). Redes de tópicos: Análise visual de grandes corpora de texto com modelagem de tópicos, *ACM Transactions on Intelligent Systems and Technology (TIST),* 3(2), 23.

[88] Sievert, C. e Shirley, K. (2014). LDAvis: Um método para visualizar e interpretar tópicos. *Nos Anais do workshop sobre aprendizagem interativa de línguas, visualização e interfaces.pp.* 63-70.

[89] Newman, D., Smyth, P., Welling, M., & Assunção, A.. U. (2008). Inferência distribuída para alocação latente de Dirichlet. *Em Avanços em sistemas de processamento de informação neural.* páginas 1081-1088.

[90] Porteous, I., Newman, D., Ihler, A., Assunção, A., Smyth, P., & Welling, M. (2008). Amostragem de Gibbs rapidamente recolhida para alocação de Dirichlet latente, *em Anais da 14ª conferência internacional ACM SIGKDD sobre descoberta de conhecimento e mineração de dados.pp.* 569-577.

[91] Tristan, JB, Tassarotti, J., & Steele, G. (2015). Treinamento eficiente de lda em uma GPU por estimativa de média por modo. *Na Conferência Internacional sobre Aprendizado de Máquina,* pp.

[92] Iwata, T., Yamada, T., & Ueda, N. (2009). Modelagem de dados de anotação social com relevância de conteúdo usando um modelo de tópico. *Em Avanços em Sistemas de Processamento de Informação Neural.* pp. 835-843.

[93] Bertoni, A. e Valentini, G. (2005, julho). Projeções aleatórias para avaliar a estabilidade do cluster de expressão gênica. *Em Processo. Conferência Conjunta Internacional IEEE de 2005 sobre Redes Neurais,* 2005. (Vol. 1, pp.149-154.

[94] Pio, G., Ceci, M., Malerba, D., & D'Elia, D. (2015). ComiRNet: um sistema baseado na web para análise de

Machine Translated by Google

Bioinformática regulatória do gene redes. *BMC* miRNA , 16(9), S7.

[95] Strehl, A. e Ghosh, J. (2002). Conjuntos de cluster --- a estrutura de reutilização de conhecimento para combinar vários partições. *Diário de aprendizado de máquina pesquisa,* 3 (dez), pp.583-617.

[96] Greene, D., Cagney, G., Krogan, N., & Cunningham, P. (2008). Fatoração de matriz não negativa em conjunto métodos para agrupar proteína-proteína interações. *Bioinformática,* 24(15), pp.1722-1728.

[97] Wallach, HM, Murray, I., Salakhutdinov, R., Mimno, D. (junho de 2009). Métodos de avaliação por tópico modelos. *Nos Anais do 26º Anual conferência internacional sobre aprendizado de máquina.pp.* 1105-1112.

[98] Mimno, D., & Blei, D. (2011) Verificação Bayesiana para modelos de tópicos, *em Anais da Conferência sobre Métodos Empíricos em Processamento de Linguagem Natural.* págs. 227-237. Associação de Computacional Linguística.

[99] Lau, JH, Newman, D. e Baldwin, T. (2014). Folhas de chá de leitura automática: avaliação automática coerência do tópico e qualidade do modelo de tópico, *em Anais da 14ª Conferência da União Europeia Capítulo da Associação para Computacional Lingüística.pp.* 530-539.

[100] Thomas W. Jones. (2019) TextmineR: Função para Pacote Mineração de Texto e TopicModeling.R. https://cran.rproject.org/web/packages/textmineR/index.html

[101] Fridolin Wild.(2015)Análise Semântica Latente(lsa): O projeto R para pacote estatístico. https://cran.r-project.org/web/packages/lsa/index.html .

[102] Fritz Guenth. Análise Semântica Latente Aplicada (LSA) Funções: O projeto R para pacote estatístico. https://cran.rproject.org/web/packages/LSAfun/LSAfun.pdf

[103] Bettina Grun, Kurt Hornik.(2018)modelos de tópico: An R Pacote para ajuste de modelos de tópicos. https://cran.r-project.org/web/packages/topicmodels/index.html

[104]Dmitriy Selivanov(2018). text2vec: Texto Moderno Estrutura de mineração para R. https://cran.r-project.org/web/packages/text2vec/vignettes/text- vectorization.html

[105] Jonathan Chang.(2015) Alocação latente de Dirichlet: Métodos de amostragem de Gibbs recolhidos para Modelos de tópicoshttps://cran.rproject.org/web/packages/lda/index.html

[106] McCallum, AK (2002). Mallet: um aprendizado de máquina para kit de ferramentas de linguagem.

[107] Radim Rehuk. Gensim: modelagem de tópicos para humanos .https://radimrehurek.com/gensim/

[108] https://nlp.stanford.edu/software/tmt/tmt-0.4/

Pooja Kherwa é professor assistente do Instituto de Tecnologia Maharaja Surajmal, em Nova Delhi. Ela recebeu seu M. Tecnologia em Tecnologia da Informação pela Universidade Guru Govind Singh Indraprastha; Dwarka, Nova Delhi em 2010. Atualmente ela está cursando seu doutorado na Universidade Guru Govind Singh Indraprastha, Dwarka- Nova Delhi. Seus interesses de pesquisa incluem Modelagem de Tópicos, Análise de Sentimentos e Aprendizado de Máquina.

Poonam Bansal é professor do Instituto de Tecnologia Maharaja Surajmal. Também atuando como Diretor Adjunto do Instituto. Ela recebeu seu doutorado da Universidade Guru Govind Singh Indraprastha, Dwarka, Nova Delhi em 2010. Sua área de interesse inclui reconhecimento de fala, mineração de dados, aprendizado de máquina