Machine Translated by Google

Sistemas de Informação 94 (2020) 101582

Listas de conteúdos disponíveis em ScienceDirect

Sistemas de informação

página inicial da revista: www.elsevier.com/locate/is

Uma revisão dos métodos de modelagem de tópicos

Ike Vayansky e, Sathish AP Kumar b,ÿ

[a] Departamento de Ciências da Computação, Coastal Carolina University, Conway, SC 29528, EUA

[b] Departamento de Engenharia Elétrica e Ciência da Computação, Cleveland State University, Cleveland, OH, 44115, EUA

informações do artigo

Historia do artigo:
Recebido em 17 de março de 2020
Recebido em formato revisado em 13 de junho de 2020
Aceito em 15 de junho de 2020
Disponível on-line em 18 de junho de 2020
Recomendado por Dennis Shasha

Palavras-chave:
Modelagem de tópico
Redes bayesianas probabilísticas
Análise de texto
Correlação de tópico
Análise temporal
Análise de mídia social
Algoritmos de inferência

abstrato

A modelagem de tópicos é uma ferramenta analítica popular para avaliação de dados. Vários métodos de modelagem de tópicos foram desenvolvidos que consideram muitos tipos de relacionamentos e restrições dentro de conjuntos de dados; no entanto, esses métodos não são frequentemente empregados. Em vez disso, muitos pesquisadores gravitam em torno da Análise Latente de Dirichlet, que, embora flexível e adaptável, nem sempre é adequada para modelar relacionamentos de dados mais complexos. Apresentamos diferentes abordagens de modelagem de tópicos capazes de lidar com a correlação entre tópicos, as mudanças de tópicos ao longo do tempo, bem como a capacidade de lidar com textos curtos, como os encontrados em mídias sociais ou dados de texto esparsos. Também revisamos brevemente os algoritmos usados para otimizar e inferir parâmetros na modelagem de tópicos, o que é essencial para produzir resultados significativos, independentemente do método. Acreditamos que esta revisão incentivará mais diversidade ao realizar a modelagem de tópicos e ajudará a determinar qual método de modelagem de tópicos melhor atende às necessidades do

Publicado pela Elsevier Ltd.

1. Introdução

Um dos objetivos mais críticos da análise de dados é determinar as características que os pontos de dados compartilham. Na análise de texto, isso geralmente significa determinar quais eventos ou conceitos um documento está discutindo. Esta informação é clara para um ser humano que lê um documento, mas um programa recebe apenas o texto conforme está escrito e não o assunto de cada documento. Para realizar essa tarefa em um programa, os cientistas de dados utilizam um método chamado modelagem de tópicos. A modelagem de tópicos é uma ferramenta estatística popular para extrair variáveis latentes de grandes conjuntos de dados [1]. É particularmente adequado para uso com dados de texto; no entanto, também tem sido usado para analisar dados de bioinformática [2], dados sociais [3] e dados ambientais [4]. Esta análise pode ajudar na organização de conjuntos de dados em grande escala para um acesso mais conveniente; alguns exemplos dessas aplicações são a estruturação de bancos de dados de periódicos e artigos em grupos baseados em foco semelhante [1], usuários de mídia social por conteúdo de postagem semelhante [3] e dados genômicos por estrutura de sequência semelhante [2]. Apesar de sua popularidade, a modelagem de tópicos está sujeita a sérios problemas de otimização, sensibilidade ao ruído e instabilidade, que podem resultar em dados não confiáveis [5]; algumas técnicas também não são representativas de relacionamentos de dados do mundo real [6].
Isso se deve a suposições sobre parâmetros-chave no processo de cálculo e à ineficiência de muitos métodos de otimização, que muitas vezes tentam superar a incerteza realizando muitas iterações demoradas para determinar o melhor valor para o parâmetro. Também existem poucas revisões acadêmicas discutindo os diferentes métodos de modelagem de tópicos e as abordagens que podem ser usadas para otimizar melhor a modelagem de tópicos para um conjunto de dados.
Neste artigo, revisaremos criticamente algumas das literaturas científicas mais citadas sobre processos de modelagem de tópicos, bem como os trabalhos mais recentes sobre o assunto. Ao revisar esses trabalhos, analisaremos quais propostas melhor combatem os diferentes limites da modelagem de tópicos e quais modelos são mais bem utilizados para diferentes cenários de análise.

A extração de estatísticas e recursos significativos de um conjunto de dados depende da escolha dos métodos adequados. Embora as abordagens atuais de modelagem de tópicos tenham um desempenho significativamente melhor do que os algoritmos anteriores, elas ainda requerem otimização e ajuste para fornecer resultados confiáveis [5]. Como afirmado anteriormente, diferentes métodos de modelagem de tópicos foram projetados para uso com relacionamentos e estruturas de dados mais específicos, como textos curtos [7], dados sequenciais de longo prazo [8], dados altamente correlacionados [6] e dados com estruturas complexas. relacionamentos [9]. Para um pesquisador que tenta iniciar um projeto de análise de dados, é imperativo compreender as diferenças entre os modelos e seus algoritmos subjacentes, a fim de formar um procedimento de modelagem de tópicos que melhor atenda aos seus propósitos. No entanto, apesar da riqueza de pesquisas realizadas no desenvolvimento de modelos de tópicos e na melhoria de algoritmos, não temos conhecimento de nenhuma publicação focada especificamente na comparação de abordagens e métodos de modelagem de tópicos. Assim, nosso objetivo nesta revisão é descrever uma seleção de estruturas de modelos de tópicos bem documentadas que podem ser utilizadas tanto para ajudar aqueles que exploram métodos possíveis para estudos futuros, bem como aqueles que

ÿ Autor correspondente.
Endereço de e-mail: s.kumar13@csuohio.edu (SAP Kumar).

https://doi.org/10.1016/j.is.2020.101582 0306-4379/
Publicado pela Elsevier Ltd.

Machine Translated by Google

buscando criticar trabalhos publicados utilizando modelagem de tópicos. Aqui descreveremos diversas considerações para modelagem de tópicos, apresentaremos uma variedade de diferentes abordagens de modelagem de tópicos, bem como alguns derivados recentes desses modelos, e discutiremos técnicas e algoritmos usados ao otimizar a modelagem de tópicos para um conjunto de dados. Embora este trabalho pretenda delinear e resumir o projeto básico de métodos de modelagem de tópicos, ele não deve ser considerado um guia completo para a execução desses algoritmos. Esta também não é uma revisão completa das abordagens de modelos de tópicos, uma vez que existem numerosos modelos diferentes e métodos alternativos neste campo de análise de dados. Encorajamos aqueles que estão lendo este artigo a procurar nas publicações originais aqui citadas quaisquer métodos que possam interessá-los, a fim de compreender completamente o processo de modelagem de tópicos, e a permanecerem abertos a outras abordagens que possam descobrir ao revisar trabalhos publicados. Este artigo pretende atuar como uma visão geral de vários métodos frequentemente citados e oferecer opções para diferentes tipos de cenários de dados. Quando aplicável, é fornecido um link para o código do método.

Nossa revisão está organizada na seguinte estrutura: A Seção 2 discute brevemente algumas das técnicas que contribuíram para o desenvolvimento das abordagens de modelos de tópicos utilizadas hoje. A Seção 3 define termos importantes que serão usados para descrever abordagens de modelagem de tópicos no artigo. A Seção 4 descreve diversas abordagens de modelagem de tópicos padrão diferentes com base nos recursos de dados que elas consideram. A Seção 5 discute métodos de otimização do processo de modelagem de tópicos por meio de algoritmos de inferência e aproximação. A Seção 6 conclui o artigo descrevendo as abordagens de modelagem de tópicos que apresentamos e como elas podem ser utilizadas para alcançar os resultados desejados a partir de um conjunto de dados.

2. Antecedentes

A modelagem de tópicos foi originalmente desenvolvida na década de 1980 e ramificou-se da área de “modelagem probabilística generativa” [2]. Este tipo de modelagem assume que as variáveis observadas interagem com parâmetros não observados, ou latentes, em um relacionamento probabilístico específico que então gera os dados dentro de um conjunto de dados [10]. O desenvolvimento desses processos surgiu da necessidade de descrever brevemente elementos dentro de grandes coleções crescentes de dados, sem comprometer as relações estatísticas necessárias para completar análises mais diretas, como classificação e sumarização [11]. O primeiro método desenvolvido para esta tarefa foi denominado esquema de redução *tf-idf* e foi proposto por dois pesquisadores na área de recuperação de informação, Salton e McGill, em 1983 [12]. Neste método, cada documento individual em um corpus é considerado por seu vocabulário, e o número de ocorrências de cada palavra é computado para formar um valor de contagem para formar uma contagem de frequência de termo (tf) *específica* para aquele documento para aquela palavra. O total de instâncias de uma palavra em todo o corpus, chamado de contagem inversa de frequência de documento *(idf),* também é calculado. Depois de normalizar esses valores para o conjunto de dados conforme necessário, os dois valores são comparados formando uma matriz termo por documento contendo os valores *tf – idf* para todos os documentos dentro das colunas [12]. Isso reduz um corpus a uma matriz dimensional V por D e documentos a vetores de comprimento fixo compostos de números reais positivos. Embora eficaz na identificação de conjuntos de palavras que distinguem documentos numa coleção, a redução do comprimento da descrição foi relativamente insignificante e a abordagem produziu poucas informações significativas sobre as relações estatísticas dentro ou entre documentos [11] .

A redução *Tf-idf* foi sucedida por outro método de redução de dimensionalidade desenvolvido por Deerwester et al. chamada de indexação ou análise semântica latente (LSI/LSA) em 1990 [13]. No LSI, a matriz *tf – idf* é fatorada por decomposição de valor singular (SVD), resultando em três matrizes separadas - duas matrizes unitárias de dimensões *V*- por-V e D-por-D respectivamente e uma matriz V-por-D contendo números reais não negativos em sua diagonal, conhecidos como valores singulares da matriz original. As matrizes resultantes são usadas para encontrar um subespaço linear dentro do espaço da matriz *tf-idf* original que descreve a maior parte da variação no corpus [13]. Quando realizado em grandes corpora, o LSI pode atingir uma compactação significativa de dados; entretanto, um método de análise mais direto poderia ser implementado formando um modelo generativo e ajustando-o usando métodos probabilísticos [11]. Esta melhoria foi proposta por Hofman em 1999 e foi chamada de modelo probabilístico LSI ou LSA (pLSI/pLSA), às vezes chamado de “modelo aspecto” [14]. Esta abordagem afastou-se dos métodos de redução de dimensionalidade e concentrou-se mais na modelagem probabilística. Dentro de um documento, cada termo é considerado uma amostra de um modelo de mistura composto de variáveis multinomiais arbitrárias, cada uma delas podendo ser considerada como representando um tópico.

Isto significa que um documento é caracterizado como uma coleção de diferentes proporções de componentes de mistura, algo como uma receita de documento. A partir disso, a descrição de um documento pode ser concentrada em uma distribuição de probabilidade sobre um conjunto predeterminado de tópicos, representando uma melhoria significativa na redução em relação aos métodos anteriores [14]. Infelizmente, esta abordagem carecia de um modelo probabilístico para determinar as proporções de mistura de um documento; portanto, os parâmetros totais do modelo aumentam linearmente em relação ao aumento do tamanho do corpus, causando sérios problemas de sobreajuste. Isso também significava que o pLSI era incapaz de considerar documentos fora do conjunto de treinamento [11]. Apesar das suas deficiências, isto marcou o primeiro exemplo de métodos probabilísticos adoptados para identificação de tópicos. Esses métodos levaram ao que são atualmente consideradas as abordagens de modelagem de tópicos mais populares, que são centradas principalmente em teoremas bayesianos, distribuições normais logísticas ou fatoração de

3. Definições de termos

Na modelagem de tópicos, o tipo de dados analisados pode vir de uma variedade de fontes e formas, incluindo sequências genéticas e bioquímicas [2], imagens [15], vídeo [16] e dados geoespaciais [17].

Para simplificar, discutiremos a modelagem de tópicos em termos relacionados ao seu uso para dados baseados em texto. Neste artigo, uma "palavra" ou "termo" representará a unidade fundamental de dados individuais, um "documento" representará uma string composta por *N* palavras, e um "corpus" representará um conjunto feito de *M* documentos geralmente abrangendo todo o conjunto de dados. Um "vocabulário" será definido como a coleção de todas as palavras distintas dentro de um corpus, e um "tópico" será caracterizado como uma distribuição de probabilidade abrangendo um determinado vocabulário. Algoritmicamente, as palavras podem ser designadas por vetores unitários que abrangem as dimensões de um vocabulário indexado por {1,. . . , V}; considerando isso em notação sobrescrito, o v-ésimo termo de um vocabulário seria denotado como um vetor V-dimensional *w* tal que $w^v = 1$ e $w^{\ddot{v}} = 0$ para $\ddot{v} \neq u$. Em termos mais básicos, um único componente que representa a posição da palavra no vocabulário nesses vetores é igual a um e todos os outros componentes são iguais a zero. Seguindo esse raciocínio, um documento pode ser considerado como uma matriz unitária representada por **w** = *(w1,w2, . . . , wN)* onde *wi* representa a i-ésima palavra na sequência e *N* define o número de palavras dentro do documento. Um corpus é assim representado por ***D*** = (w1, w2, . . . , *wM)* ou ***D*** = (d1, d2, . . . , *dM)* em que *dn* é equivalente a *wn* e significa o enésimo documento no corpus e *M* define o número total de documentos dentro do corpus. Os tópicos são representados por diferentes distribuições probabilísticas ou estocásticas dependendo do método utilizado e, em alguns casos, também podem representar distribuição sobre outros tópicos. Na sua forma mais simples e sem considerar hierarquias ou relacionamentos sequenciais, isso pode ser representado por **z** = (z1, z2, . . . , *zK)* com *zj* representando o j-ésimo tópico e *K* definindo o número de tópicos que abrangem o corpus [11].

Machine Translated by Google

Salvo indicação em contrário, os parâmetros ÿ e ÿ são vistos como pesos de mistura e caracterizam o significado das palavras para um determinado tópico e o significado dos tópicos dentro de um documento específico, respectivamente. Assim, uma fórmula como ÿ *(z)* = P(w|z) refere-se à distribuição multinomial de termos sobre um determinado tópico *z* enquanto a fórmula ÿ *(d)* = *P(zd)* refere-se à distribuição multinomial de tópicos em um determinado documento *d* [10].

Nesta revisão, sintetizamos as informações encontradas na literatura sobre modelagem de tópicos da melhor maneira possível e de uma maneira que acreditamos ser mais lógica para o leitor. As pesquisas discutidas nesta revisão baseiam-se em teorias estatísticas e processos generativos semelhantes, mas muitas vezes definem variáveis de forma independente e, portanto, as representações de parâmetros podem variar entre os artigos [18–23]. Para maior clareza, alteramos os símbolos daqueles descritos nos trabalhos originais quando necessário, a fim de manter a consistência ao longo desta revisão. Ao revisar essas publicações, reserve um tempo para se familiarizar completamente com as variáveis definidas pelos autores, a fim de evitar confusão.

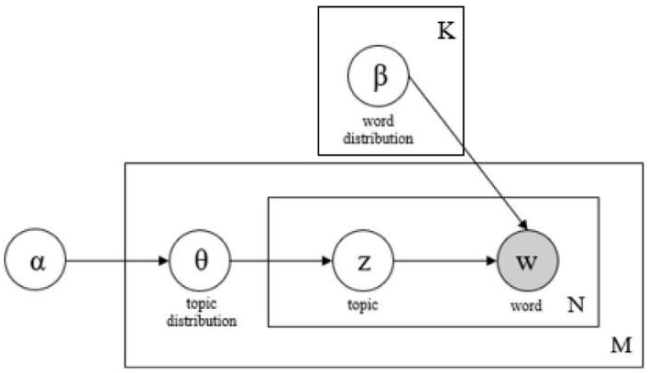

Figura 1. Ilustração do processo generativo do LDA. A caixa externa *M* denota a amostragem repetida para cada documento e a caixa interna *N* representa a amostragem dentro de cada documento. A caixa *K* representa a amostragem para cada tópico.

4. Abordagens de modelo de tópico padrão

4.1. Abordagens básicas

4.1.1. Alocação latente de Dirichlet

Um dos primeiros e mais frequentemente utilizados métodos de modelagem de tópicos que será discutido é chamado "Latent Dirichlet Allocation" (LDA), desenvolvido por Blei, Ng e Jordan em 2003 [11] (https:// github . com/blei-lab/ lda-c); o código fornecido é do autor e utiliza inferência EM variacional, na linguagem de codificação C. Esta abordagem estrutura os dados em três níveis – palavra, tópico e documento. O LDA considera os documentos gerados a partir de misturas aleatórias de tópicos ocultos, que são vistos como distribuições de probabilidade sobre palavras. Para gerar cada documento, ele primeiro amostra um vetor K ÿ representando a proporção de mistura de *k* tópicos de uma distribuição anterior de Dirichlet p(ÿ|ÿ).

A variável *k* definirá a dimensão desta distribuição e, portanto, a dimensão da variável de tópico ***z*** também, mas também representa o número total de tópicos que serão retornados no modelo. É importante notar que este valor é assumido como estático e conhecido nesta abordagem. Além disso, uma matriz ÿ com as dimensões k×V parametriza probabilidades de palavras tais que *ÿij* = p(w *j K* e *j* = 0, V. Quando ÿiÿ 0 e *ÿk* 1, . . . , = 1|z = 1) onde *i* = 0, 1, . . . , eu=1 *ÿi* = 1, uma variável de Dirichlet ÿ de k-dimensionalidade pode ocupar valores no (k-1)-simplex e tem uma densidade de probabilidade neste simplex determinada pela seguinte equação:

$$p\,(\ddot{y}|\ddot{y}) = \frac{\ddot{y}\,(\ddot{y}k\ i{=}1\ \ddot{y}i\,)\ \ddot{y}k}{{}_{eu=1}\ C\ (ai)} \quad (1)$$

O parâmetro ÿ na Eq. (1) é o hiperparâmetro da distribuição de Dirichlet. Pode ser vista como uma contagem prévia das vezes que um tópico individual é observado em um documento, incorporada por um vetor k de elementos *ÿi* > 0. Em algumas situações, principalmente aquelas com um número desconhecido de tópicos contidos em cada documento, pode é benéfico utilizar um Dirichlet simétrico anterior, onde todos os valores de ÿ são iguais e podem, portanto, ser simplificados para um ÿ singular em todo o corpus [10]. As combinações de tópicos são influenciadas pelo valor deste parâmetro, com valores de ÿ mais elevados fazendo com que a distribuição dos tópicos seja afastada das extremidades do simplex resultando no que é chamado de "suavização" [11] . É procedimento comum usar ÿ < 1, que localiza os modos da distribuição de Dirichlet nos cantos do simplex e cria uma tendência para a esparsidade [10]; isso é especialmente recomendado para trabalhos que utilizam conteúdo de mídia social, que muitas vezes é restrito por limites de caracteres [3]. O hiperparâmetro ÿ também é um anterior de Dirichlet simétrico e pode ser visto de forma semelhante como o número de ocorrências de palavras amostradas de um tópico antes da observação de qualquer palavra dentro do corpus [10] ; este valor influencia o grau de suavização das distribuições de palavras em todos os tópicos [11]. A seleção de valores para ÿ e ÿ depende do tamanho do vocabulário e do número de tópicos selecionados; Steyvers e Griffith sugerem ÿ = 50/K e ÿ = 0,01 como uma escolha ampla que eles descobriram funcionar bem com uma variedade de coleções de textos [10]. Para mais derivações e suposições envolvendo inferência e estimativa de parâmetros em LDA, consulte [11].

O processo generativo básico deste modelo pode ser visto na Figura 1; este formato é chamado de “notação de placa” e será usado ao longo deste trabalho, bem como em muitas das publicações originais. As caixas nesta figura são chamadas de 'placas' e indicam ações de replicação dentro do modelo, com o rótulo da placa referindo-se à variável correspondente ao número de replicações. Os círculos representam variáveis ou parâmetros, com círculos brancos indicando que a variável está latente ou oculta e círculos sombreados indicando informações que são fornecidas. As setas demonstram a hierarquia de influência de uma variável sobre outra. Por exemplo, a placa *K* contendo o parâmetro ÿ indica que as palavras serão amostradas individual e independentemente da distribuição ÿ para cada tópico de *k* tópicos.

A abordagem LDA demonstrou uma melhoria significativa em relação ao trabalho anterior ao considerar a inferência de documentos invisíveis e compreender dados não estruturados; no entanto, são necessárias várias etapas adicionais de estimativa de parâmetros para ÿ e ÿ , a fim de maximizar a probabilidade logarítmica marginal dos dados. Vários processos propostos para esta tarefa foram métodos de inferência variacional [11], cadeia de Markov Monte Carlo (MCMC) [24] e amostragem de Gibbs colapsada rapidamente [25]. O problema com esses métodos de aproximação é que os resultados finais podem diferir muito para os mesmos dados usando o mesmo algoritmo dependendo das condições iniciais, o que resulta em dificuldade de reprodução de modelos e problemas significativos de ruído [10] . Além disso, o LDA demonstrou problemas de dispersão ao encontrar grandes tamanhos de vocabulário em corpora [11,26]. A instabilidade e a inferência de parâmetros não são os únicos obstáculos para esta abordagem de modelagem de tópicos. O LDA faz diversas suposições em seus cálculos que podem não ser eficazes para gerar modelos de tópicos precisos ou realistas, dados conjuntos de dados do mundo real. A primeira suposição é que o valor de *k* é fixo e conhecido [1]; esta variável caracteriza a estrutura de tópicos que o modelo gera e, portanto, impacta significativamente a resolução entre os tópicos. Para a maioria das aplicações do mundo real que utilizam modelagem de tópicos, não existe um número ideal de tópicos estabelecidos para um corpus antes da geração de um modelo. Os meios para melhor

Machine Translated by Google

a determinação deste valor não está bem definida para a maioria dos métodos de modelagem de tópicos, incluindo LDA. Para determinar esse valor, os pesquisadores geralmente geram modelos de tópicos de forma iterativa para os mesmos dados usando diferentes valores de *k* e, em seguida, analisam certas métricas, como perplexidade, para comparar os resultados [27]. Para grandes conjuntos de dados isto é ineficiente e impreciso, pois o valor da perplexidade dos resultados pode flutuar devido à natureza aleatória do

Algoritmos de aproximação LDA e amostragem de peso interno; esse processo também consome mais tempo e poder computacional à medida que o tamanho do corpus aumenta, uma vez que cada modelo de tópico individual leva mais tempo para ser produzido [27]. A segunda suposição feita no LDA é que todos os tópicos são independentes uns dos outros e, portanto, este modelo não leva em conta a correlação entre os tópicos [11]. Essas correlações são uma parte comum de muitos tipos de dados, especialmente dados de texto e de mídia social. Isto limita a capacidade deste algoritmo de lidar com big data com precisão e fazer previsões para novos documentos, o que, por sua vez, reduz a sua aplicação em cenários do mundo real. Da mesma forma, a LDA também assume que tanto os documentos como as palavras dentro dos documentos são independentes, o que significa que a sua ordem não importa [1]; a suposição de independência de documentos é inerente à probabilidade de Dirichlet [11] e a independência de palavras é chamada de suposição de "saco de palavras" e faz parte de muitos modelos estatísticos [1]. A ordem das palavras dentro de uma frase e as relações entre documentos ao longo do tempo são características importantes dos dados textuais ou linguísticos do mundo real [8]. Nenhuma otimização ou etapas adicionais podem superar essas falhas no LDA, uma vez que a suposição de independência está enraizada nos algoritmos da própria distribuição de Dirichlet [11]. Assim, novos métodos tiveram que ser desenvolvidos para considerar correlações de tópicos e documentos nesses modelos. Preocupações adicionais com este processo estão envolvidas no treinamento do algoritmo. Como outros métodos de análise de dados e como mencionado anteriormente com métodos de aproximação, o LDA é propenso ao que é chamado de "efeitos de ordem", ou variação nos resultados em resposta à ordem dos dados de treinamento usados [5]. Uma prática geral em análise de dados é gerar conjuntos de treinamento a partir de apenas uma parte do conjunto total de dados usando uma semente aleatória. Isso significa que a cada iteração o modelo pode criar tópicos diferentes a partir dos mesmos dados e atribuir palavras diferentes a tópicos semelhantes entre execuções. Este é um obstáculo significativo para tarefas de classificação que utilizam LDA para geração de dados de treinamento, especialmente aquelas que não otimizam as configurações padrão do modelo [5]. Isso causa grande instabilidade nos modelos LDA e é uma das razões pelas quais o teste iterativo de diferentes valores *de k* é ineficaz para otimizar tópicos.

Houve uma variedade de derivações de LDA propostas para tarefas e melhorias específicas. Alguns exemplos desses modelos são o modelo de mistura latente de Dirichlet (LDMM) [28], fatoração de matriz por meio de LDA (fLDA) [29] e a alocação hierárquica de Dirichlet Latente (hLDA) [30]. Cada um desses novos métodos combina os recursos tradicionais do LDA com outro processo probabilístico ou estatístico para melhorar o desempenho, integrar inferência ou otimização ou considerar relacionamentos avançados de tópicos, mantendo a abordagem básica do LDA.

Muitas das novas pesquisas publicadas sobre métodos de modelagem de tópicos são derivadas do LDA ou da combinação dele com outros modelos.

Os métodos LDA tradicionais e LDA revisados têm sido usados por um um grande número de finalidades, tornando o LDA o método mais citado na pesquisa de modelagem de tópicos [1]. É propenso a falhas e requer otimização significativa para resultados de qualidade; no entanto, é adaptável em termos de integração com outros modelos e aplicação a uma variedade de tipos de dados diferentes. Também marcou um ponto de viragem significativo na modelação de texto e dados discretos e, portanto, é frequentemente referido como uma referência para todos os outros modelos em publicações.

Tem sido utilizado em estudos sobre mídias sociais e padrões da web, semântica, comportamento, linguística, avaliação de documentos, padrões de rede, modelos preditivos, processamento de imagens e vídeos, e muitos outros tópicos [1]. Também pode ser realizado como uma abordagem supervisionada, não supervisionada e semissupervisionada com alterações mínimas [11]. Apesar das suas deficiências, o LDA pode ser ajustado para se adequar à maioria das tarefas de análise geral e tem uma riqueza de trabalhos anteriores para rever e considerar. No entanto, se este método for selecionado, a otimização é crucial para a produção de dados significativos e as técnicas devem ser cuidadosamente revisadas para atender às necessidades do estudo.

4.2. Modelos de tópicos com relacionamentos de tópicos avançados

4.2.1. Modelo de tópico correlacionado

O próximo grande desenvolvimento nos métodos de modelos de tópicos foi o "modelo de tópicos correlacionados" (CTM), que também foi proposto por Blei em conjunto com Lafferty em 2006 [6] (https://github.com/bleilab/ctm -c); o código fornecido é do autor e utiliza inferência variacional, na linguagem de codificação C. Semelhante ao método anterior, esta abordagem considera documentos individuais como misturando proporções de tópicos e segue um processo generativo quase idêntico; entretanto, quando amostras LDA de uma distribuição de Dirichlet, as misturas de tópicos no CTM são amostradas a partir de uma distribuição logística normal. Esta distribuição transforma uma variável aleatória normal multivariada em um simplex e através de uma matriz de covariância da distribuição normal permite um arranjo global entre a variância entre os elementos da distribuição. Isto foi originalmente estudado para a análise de dados composicionais observados, mas Blei e Lafferty estendem seu uso a um modelo hierárquico para descrever a composição latente de tópicos associados dentro de cada documento em um corpus [6] . A parametrização natural da distribuição multivariada *K*-dimensional é determinada a partir da seguinte equação:

$$p\ (z|\ddot{y}) = \exp\{\ \ddot{y}\ \text{Nesta}^{T} z\ \ddot{y}\ \textit{uma}\ (n)\ \} \tag{2}$$

Eq. (2), *z* pode assumir valores de *K* e é representado por um vetor K-dimensional. A função de mapeamento da parametrização média, ou simplex, e esta parametrização natural é expressa como:

$$\ddot{y}i = \log \ddot{y}i/\ddot{y}k \tag{3}$$

Sob a distribuição logística normal, ÿ é assumido como normalmente distribuído e usando o inverso da Eq. (3) é então mapeado para a parametrização média, ou simplex. O processo pelo qual os documentos são gerados no CTM é ilustrado no seguinte gráfico de notação de placa exibido na Fig .

Para demonstrar o valor deste método na sua publicação original, duas abordagens de modelos de tópicos – LDA e CTM – foram aplicadas a um corpus de 15.744 artigos *científicos ;* o log de probabilidade médio mantido, uma estatística que indica a probabilidade de um resultado específico, dos dois modelos foi calculado e comparado para avaliar o desempenho. Os resultados mostraram que a abordagem CTM proporcionou um melhor ajuste aos dados e, adicionalmente, foi capaz de apoiar um maior número de tópicos em geral. O desempenho do modelo LDA atingiu o pico em 30 tópicos antes de diminuir significativamente, enquanto o CTM mostrou um pico em 90 tópicos, com declínio mínimo na probabilidade logarítmica para contagens de tópicos superiores a 90. As diferenças entre as estatísticas do modelo mostraram que o CTM sempre deu um resultado melhor. ajuste comparado ao LDA com base na perplexidade dos modelos. Verificou-se que depois de observar uma proporção relativamente pequena de palavras num documento, o CTM tinha um valor de perplexidade significativamente menor e, portanto, significativamente mais certeza, em comparação com o LDA. Isto ocorre porque o CTM utiliza a correlação de tópicos para apoiar a sua previsão, inferindo que palavras de tópicos relacionados também podem ser prováveis no documento; por outro lado, o LDA é incapaz de antecipar as palavras restantes de um documento até que seus tópicos estejam totalmente representados, exigindo que a proporção observada do documento seja significativamente maior [6].

Machine Translated by Google

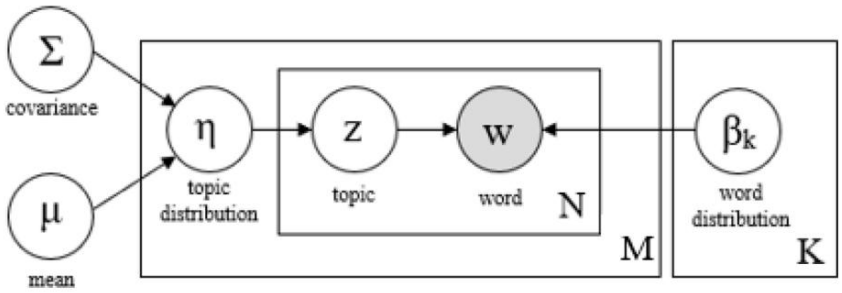

Figura 2. Uma notação em placa da abordagem CTM. A designação das placas é comparável àquelas vistas na Fig .

Este modelo é mais expressivo que o LDA e leva em conta relações mais realistas entre diferentes tópicos dentro de um documento e ao longo de corpora. O uso de uma matriz de covariância permite uma estrutura que também pode ser utilizada para tarefas mais diversas, como explorar e navegar em um grande corpus de documentos, formar distribuições preditivas e filtragem colaborativa otimizada [6] . O elemento mais desafiador desta abordagem é contabilizar a inferência posterior, que é mais uma vez difícil de calcular. Este problema é semelhante ao problema encontrado com LDA, porém uma variedade maior de algoritmos de inferência aproximada é adequada para uso em LDA. O método sugerido para aproximar esta distribuição é através do uso de métodos variacionais de campo médio; esses métodos buscam formar uma distribuição fatorada das variáveis ocultas que são parametrizadas por parâmetros variacionais, que são variáveis livres ajustadas de forma que a divergência de Kullback-Leiber (KL) seja suficientemente minimizada entre o posterior aproximado e o posterior verdadeiro. No CTM, a normal logística não é conjugada ao multinomial, portanto um algoritmo variacional não poderia ser derivado automaticamente. Em vez disso, era necessário derivar um algoritmo tendo em conta a estrutura e as distribuições especiais utilizadas no CTM, que Blei e Lafferty apresentam no seu artigo. Sua descoberta pode ser encontrada no apêndice A de [6]. Além disso, este método também assume *que k* é um valor conhecido e, portanto, não oferece um método para determinar o *k* ideal para um corpus. O CTM é menos sensível a *k* comparado ao LDA [31], mas isso ainda representa um obstáculo para os pesquisadores que utilizam este método. Uma limitação digna de nota deste método é que as correlações só podem ocorrer entre dois tópicos ao mesmo tempo; não há consideração por relacionamentos de documentos maiores ou mais complexos. No geral, esta é uma abordagem adequada para a maioria dos dados e funcionaria bem com conjuntos dos quais se espera que tenham tópicos fortemente correlacionados, como o conjunto de exemplos recolhidos a partir de artigos de uma única revista.

4.2.2. Modelo de alocação Pachinko

Na mesma época da publicação do CTM, outro modelo de correlação de tópicos denominado "Modelo de Alocação Pachinko" (PAM) foi desenvolvido [9]; embora os autores não tenham uma implementação disponível publicamente, o kit de ferramentas TOMOTOPY para modelagem de tópicos em Python tem uma função para PAM, bem como muitos outros métodos (https://github.com/bab2min/tomotopy). Ao contrário do modelo anterior que foi concebido utilizando a estrutura do LDA, os autores do método PAM – Li e McCallum – adoptaram uma abordagem diferente. Enquanto o CTM reconhece correlações entre quaisquer dois tópicos ao mesmo tempo, o PAM cria um modelo de mistura de gráfico acíclico direcionado (DAG) para capturar uma variedade de diferentes tipos de relacionamentos de tópicos. Isso inclui correlações arbitrárias, aninhadas ou esparsas, bem como tópicos sobre tópicos, formando classes de super e subtópicos dentro de um corpus. Isto é conseguido considerando o tópico não apenas como distribuições sobre palavras, mas também como distribuições sobre outros tópicos, resultando em uma hierarquia de relacionamentos de tópicos. A estrutura básica deste modelo é composto por um DAG gerado aleatoriamente em que cada palavra do vocabulário corresponde a um nó folha e cada tópico se relaciona a um nó interior; os nós internos do grafo podem assim ser vistos como nós "pais", que são distribuídos pelos nós "filhos" (tanto folhas quanto não-folha) que se unem a ele [9] . Devido a este desenho, a estrutura de um tópico tradicional em LDA pode ser considerada um nó interior que inclui apenas folhas como seu Os nós internos que contêm nós não-folha dentro de seus filhos representam uma mistura de tópicos e capturam correlações entre palavras e tópicos. É possível definir arbitrariamente parâmetros para a distribuição de um nó interior sobre seus filhos; entretanto, Li e McCallum propõem usar uma distribuição de Dirichlet parametrizada por um vetor com dimensionalidade equivalente ao total de nós filhos que ela abrange, semelhante ao LDA [9]. Como resultado, o modelo PAM é composto por DAG onde a distribuição de cada nó pai sobre seus nós filhos é representada por um Dirichlet único. Os documentos são gerados primeiro por amostragem de cada Dirichlet para selecionar um multinômio antes de gerar cada palavra no documento. As palavras são formadas começando no vértice base do DAG, descendo para um de seus nós filhos e amostrando em correspondência ao seu multinomial, e continuando a amostragem em cada nível até que não haja mais arestas a seguir e um nó folha seja alcançado; esse processo resulta na geração de uma única palavra e é repetido para cada palavra do vocabulário [9]. A estrutura é altamente flexível e dependendo do layout dos nós interiores e folhas pode variar na forma final de um gráfico de árvore a um DAG arbitrário com características complexas, como conexões onduladas e arestas que passam por níveis [9] .

Neste modelo, a probabilidade combinada de produzir um documento d, as atribuições de tópico **z** (d) e os multinômios ÿ (d) é expressa como:

$$P(d, z^{(d)}, eu\ ia)\ \ddot{y}\ddot{y}) = \ddot{y}s_{eu=1} P(eu^{\ldots}\ \ddot{y}\ddot{y}i) \times \ddot{y}_{w\ (\ddot{y}Lw\ i=2} P(zwi\ \ddot{y}\ (d)\ zw(i\ddot{y}1))\ P(w^{\ldots}_{zwLw)}) \quad (4)$$

onde **zw** é um caminho de tópico, zwi é um tópico no caminho e Lw é o comprimento deste caminho. Para este modelo, *s* é considerado o número de tópicos (equivalente a *k* nos modelos anteriores) e é separado em conjuntos com base nos níveis do DAG; os tópicos de nível superior são chamados de supertópicos, enquanto os tópicos de nível inferior são considerados subtópicos. O artigo apresenta uma estrutura PAM de quatro níveis, que foi usada para comparar o desempenho com um modelo LDA tradicional. Uma representação desta estrutura e seu processo generativo é vista na Figura 3.

Este modelo tem vantagens notáveis sobre o CTM e o LDA. Em primeiro lugar, não só leva em conta a correlação de tópicos, mas também considera relações de tópicos e níveis de correlação mais complexos. Ele permite uma estrutura de modelo versátil que pode se adaptar a uma variedade de corpora diferentes. Além disso, ao comparar o desempenho do PAM com CTM, LDA e processos hierárquicos de Dirichlet (HD

Machine Translated by Google

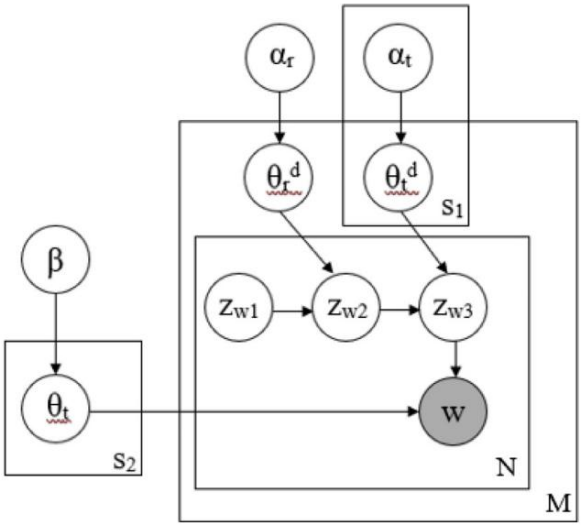

Figura 3. Representação do modelo gráfico da estrutura PAM de quatro níveis. A placa rotulada *s1* corresponde à iteração de amostragem multinomial através de supertópicos, *s2* corresponde à amostragem multinomial para os subtópicos. As variáveis *ÿr* e *ÿr* indicam o processo de amostragem multinomial para a raiz, nível inicial do DAG, que é feito individualmente a partir dos supertópicos de cada documento. As variáveis zw1, zw2 e zw3 indicam os tópicos dentro de um caminho de tópico para a palavra w.

O PAM demonstrou a capacidade de suportar um número significativamente maior de tópicos em comparação com o próximo modelo de melhor desempenho, o CTM. Enquanto o desempenho do CTM atingiu o pico em 60 tópicos e superou o PAM em números de tópicos mais baixos, o desempenho do PAM atingiu o pico em 160 tópicos e teve um desempenho significativamente melhor em uma faixa maior de números de tópicos. Porém, por ainda se basear no mesmo algoritmo probabilístico primário, ainda não existe um mecanismo de aprendizagem do valor de *s (k* em LDA e CTM) com base no corpus.
Portanto, otimizar o número de tópicos continua sendo um processo ineficiente; isso é agravado no PAM pela adição de uma hierarquia sobre tópicos que, portanto, exigem mais consideração pela estrutura do modelo. Os autores sugerem o uso da amostragem de Gibbs como o método preferido para inferir e estimar parâmetros neste processo em relação a outras abordagens variacionais, porque o algoritmo anterior demonstrou ter dificuldades com tarefas de modelagem de tópicos PAM devido aos muitos máximos locais. Como na amostragem de Gibbs presume-se que os parâmetros de Dirichlet ÿ sejam fornecidos, mas no PAM esses parâmetros precisam ser aprendidos para representar com precisão as relações entre subtópicos, ÿ é aproximado usando correspondência de momento para evitar iteração e simplificar o processo [9].

O PAM pode envolver mais otimização e despesas computacionais do que o LDA, mas os relacionamentos que ele modela são únicos, pois não considera apenas relacionamentos únicos entre dois tópicos como o CTM, mas considera hierarquias e níveis de tópicos. Provavelmente, isso é mais adequado para estudos em que se deseja uma estrutura de tópico detalhada, como modelagem de tópicos para tendências de consumo ou conjuntos de dados de foco muito amplo para fins de descoberta de padrões.

4.3. Modelos de tópicos baseados em tempo

4.3.1. Modelos de tópicos dinâmicos

Ao modelar tópicos em uma série de documentos, há outras suposições feitas pelo LDA que não são necessariamente como os dados interagem. Por exemplo, dentro de um corpus em LDA, todos os documentos de um corpus são tratados de forma intercambiável [11]. Para conjuntos que abrangem longos períodos de tempo, isto pode não refletir com precisão as mudanças que ocorrem nos tópicos ao longo do tempo; por exemplo, um artigo sobre uma doença específica no início de 1900 discutiria aspectos muito diferentes coisas do que um artigo sobre a mesma doença na década de 2000. Foi para tais cenários que o modelo de tópicos dinâmicos (DTM) também foi desenvolvido por Blei e Lafferty, que considera a "evolução dos tópicos ao longo do tempo" [8] (https://github.com/blei-lab/dtm); o código fornecido é do autor e é composto principalmente de código Shell, C++ e C. A consideração de tópicos em evolução foi realizada usando modelos de espaço de estado no espaço de parâmetros naturais tanto para os multinômios de tópico subjacentes quanto para distribuições normais logísticas, que serão usadas para modelar proporções de tópicos específicos de documentos. A sua abordagem básica era encadear uma sequência de modelos com base numa unidade de tempo definida, t, que poderia variar de um período de dias a um período de anos, dependendo das necessidades do conjunto de dados. Esta unidade é considerada uma 'fatia' de tempo e é usada para formar modelos distintos de componentes K nos quais os tópicos produzidos para a fatia *t* são desenvolvidos a partir dos tópicos encontrados para a fatia *t* ÿ 1 [8].

Considerando um modelo com *V* palavras no vocabulário, ÿt,k denota o vetor V-dimensional de parâmetros naturais para um tópico *k* dentro da fatia t. Utilizando a parametrização média para representar a distribuição multinomial V-dimensional com o parâmetro médio denotado por ÿ, a i-ésima componente do parâmetro natural ÿ é dada pelo mapeamento *ÿi* = log(ÿi/ÿV). Como a distribuição de Dirichlet não é adequada para modelagem sequencial, os parâmetros naturais de cada tópico são encadeados usando um modelo de estado espacial que evolui por ruído gaussiano, cuja versão mais simples é modelada pela seguinte função:

$$\ddot{y} \quad \ddot{y}\ddot{y}t\ddot{y}1,k \; \ddot{y} \; N \; (\; \ddot{y}t\ddot{y}1,k, \; \ddot{y}^{2}_{eu)} \tag{5}$$

ÿt,k No DTM, a incerteza sobre as proporções de tópicos específicos do documento é expressa usando uma normal logística com média ÿ. A estrutura sequencial entre modelos é mais uma vez representada com um modelo dinâmico simples:

$$\ddot{y}\,\ddot{y}t \quad \ddot{y}\ddot{y}t\ddot{y}1 \; \ddot{y} \; N \; (\; \ddot{y}t\ddot{y}1, \; \ddot{y}2 \; I \;) \tag{6}$$

Através desta abordagem, o DTM vincula uma coleção de modelos de tópicos sequencialmente, formando uma ligação entre as distribuições de ambos os tópicos e as proporções dos tópicos. Considerando uma coleção serial de documentos, o processo de geração da fatia *t* começa, portanto, extraindo tópicos da Eq. (5) e então desenhando distribuições da Eq. (6). Então, no documento d, o parâmetro médio da distribuição multinomial ÿ(ÿ) é usado para desenhar um tópico *Z* para cada palavra e a palavra *Wt,d,n* é extraída do parâmetro médio da distribuição multinomial *ÿ(ÿt,z)* . O processo generativo é ilustrado na Fig .

Semelhante ao LDA e ao CTM, a inferência posterior é intratável e, portanto, precisa ser aproximada; uma vez que este modelo não é estático como o LDA ou o CTM, a abordagem para isto é bastante diferente. Os autores sugerem duas abordagens diferentes para calcular a inferência aproximada para os parâmetros do tópico natural e afirmam que a distribuição variacional das variáveis latentes no nível do documento segue os mesmos cálculos usados no LDA.

Os dois métodos para inferência de parâmetros naturais são a filtragem variacional de Kalman, que considera as propriedades simétricas da densidade gaussiana para produzir parâmetros variacionais, e a regressão wavelet variacional [8]. A aplicação de ambas as abordagens aos dados da análise de artigos dos 120 anos da revista *Science* , 250 artigos por ano, mostrou que ambas as aproximações suavizaram as flutuações locais em comparação com o modelo unigrama de controle, porém a regressão wavelet foi capaz de super-resolver picos muito próximos nos tópicos, enquanto a filtragem de Kalman proporcionou um melhor ajuste geral para cronogramas de tópicos mais dispersos.

A aproximação de regressão wavelet variacional pode ser melhor aplicada a corpora sequenciais que abrangem períodos de tempo mais curtos e, portanto, requerem melhor resolução entre picos, ou quando há expectativa de problemas com resolução de tópico localizada. A filtragem de Kalman seria mais adequada para intervalos de tempo mais longos

Machine Translated by Google

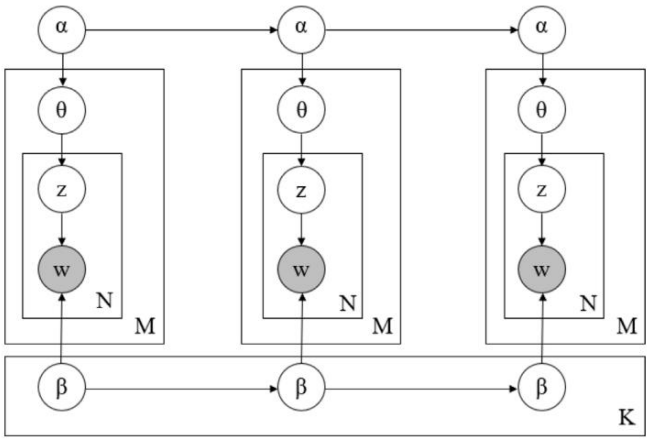

Figura 4. Diagrama de notação de placas para abordagem DTM. As setas horizontais representam a evolução dos parâmetros entre fatias de tempo (ex. *t* a tÿ1), enquanto as setas verticais representam a progressão do processo generativo através de cada modelo de tópico na sequência. As variáveis neste gráfico são as mesmas vistas no LDA, porém as distribuições no DTM são Gaussianas, não Dirichlet.

que exigem uma perspectiva mais ampla dos dados e onde há expectativa de uma distribuição mais uniforme dos temas.

A forma como o DTM representa a passagem do tempo é preocupante; este método requer que o usuário defina uma unidade discreta de tempo. Isto levanta questões sobre como *t* é selecionado e quais características dos dados são perdidas pela discretização do tempo ao longo do corpus. Além disso, este modelo não leva em conta as correlações entre os tópicos para simplificar, embora uma abordagem combinada CTM-DTM seja teoricamente possível, já que o CTM não é extraído de uma distribuição de Dirichlet [8]. Esta abordagem não fornece um método imediato para determinar o valor *k* ideal para o conjunto de dados, semelhante a todos os métodos anteriores. Este processo pode ser mais difícil com esta abordagem de modelagem de tópicos devido à variação entre os dados dentro dos intervalos de tempo. O artigo apresenta um cenário 'perfeito' com um número equivalente de documentos para cada ano, que poderia facilmente ser reproduzido para outros estudos; no entanto, não descreve os obstáculos envolvidos numa distribuição mais realista dos documentos ao longo do tempo. Contudo, para um corpus filtrado ou especificamente estruturado, este método pode fornecer um modelo de tópico muito mais informativo do que o LDA sozinho.

Esta abordagem à modelagem de tópicos é adequada para corpora que abrangem períodos de tempo significativos, pelo menos vários anos. Os conjuntos que cobrem menos de um ano provavelmente não beneficiariam da evolução dos tópicos, uma vez que as mudanças nas distribuições dos tópicos seriam muito menos significativas e mais difíceis de representar em intervalos de tempo distintos; no entanto, isto não significa que não existam conjuntos de curto período de tempo que beneficiariam desta abordagem.
Um número significativo de artigos utilizou esse método para pesquisas envolvendo padrões de tópicos para publicações acadêmicas, citações de autores, visões gerais sequenciais ou de linha do tempo do desenvolvimento de tópicos e métodos combinados de modelagem de tópicos [32] . Também tem sido muito citado em trabalhos envolvendo estudos sobre mídias sociais e tendências online [33]; no entanto, tais tarefas provavelmente seriam mais adequadas aos métodos descritos na seção seguinte, que são responsáveis pelo baixo comprimento do documento. É teoricamente possível aplicar tanto o DTM como as abordagens da Secção 4.4, embora estes métodos ainda sejam bastante novos, pelo que nenhum trabalho deste tipo foi realizado.
A investigação centrada em dados que não são altamente influenciados por eventos externos, como catástrofes ou eventos atuais, ou que são geralmente divulgados num padrão sequencial estruturado, poderia beneficiar do DTM, uma vez que, por definição, fornece modelos em unidades discretas que podem ser facilmente comparados.

4.3.2. Modelagem de tópicos em tempo contínuo Como mencionado anteriormente, há diversas preocupações com o uso de um modelo de tempo discreto para modelagem de tópicos. Embora possa simplificar os processos computacionais, impor uma escala fixa para a criação de modelos não é uma representação precisa de como os tópicos podem mudar ao longo do tempo. Por exemplo, os tópicos nos meios de comunicação social e nas redes podem mudar muito rapidamente como resultado de tendências virais, mas ainda podem ser influenciados por eventos temporais recorrentes, como feriados ou eleições, ou por eventos externos ou globais imprevisíveis, como guerra, agitação civil, e desastres. Todas essas influências podem abranger diferentes períodos de tempo ou ocorrer simultaneamente durante os mesmos períodos de tempo. Para modelos LDA básicos e algoritmos de modelos de tópicos correlacionados, esses tipos de ocorrências podem confundir os dados e levar a uma baixa coerência do tópico e a altos Embora o DTM possa ser capaz de expressar algum grau da evolução do tópico nestas situações, ele não pode mapear de forma realista os padrões de mudança ao longo do tempo. Para modelar com precisão padrões de tópicos temporais complexos, o tempo deve ser visto como uma entidade contínua.

Vários métodos diferentes foram desenvolvidos na modelagem de tópicos que consideram o tempo de maneira contínua. Tal como acontece com os modelos anteriores, existe um projeto bayesiano que considera o tempo continuamente pela aplicação de uma mistura de conceitos de processos homogêneos de Markov e redes bayesianas denominada Rede Bayesiana de Tempo Contínuo (CTBN) [33] . Este método proporcionou melhorias em relação a métodos como modelos de redes Bayesianas Dinâmicas (DBN), evitando a discretização, mas não foi projetado diretamente para o processo de modelagem de tópicos. Também pressupõe pelo menos um ponto fixo de conhecimento sobre as transições de estado em um conjunto de dados, que pode não ser conhecido ao realizar análises de dados do mundo real. Um método muito mais adequado para modelagem de tópicos foi projetado usando uma distribuição multinomial de tópicos por documento Dirichlet em combinação com uma distribuição Beta por tópico ao longo do tempo. Este método permite não apenas a consideração de padrões temporais dentro de modelos de tópicos, mas também pode levar em conta a correlação entre tópicos de um para um e as mudanças nessas co-ocorrências ao longo do tempo. Esta abordagem foi proposta por Wang e McCallum e é chamada de Topics Over Time (TOT) [34]; os autores não fornecem uma implementação pública, no entanto, um código Python de código aberto foi feito por Abhinav Maurya da Carnegie Mellon que está diretamente relacionado ao descrito no artigo (https://github.com/ahmaurya/topics_over_time). TOT possui dois métodos básicos para produzir um modelo. O primeiro é mais adequado para dados vistos ou dados conhecidos pelo algoritmo.

Aqui, para cada tópico, *k* multinômios (ÿz) são gerados primeiro a partir de um anterior de Dirichlet, ÿ, e multinômios por documento *(ÿd)* a partir de um anterior de Dirichlet, ÿ. Dentro de um determinado documento d, um tópico *z* é extraído de *ÿd* para cada palavra. Uma palavra *wdi* é então extraída do multinômio *ÿzdi* e, finalmente, um carimbo de data/hora é extraído da distribuição Beta *ÿzdi.* Embora os carimbos de data e hora sejam obtidos para cada palavra, o carimbo de data e hora do documento é considerado equivalente aos carimbos de data e hora de todas as palavras desse documento. A amostragem de Gibbs é usada aqui para realizar inferência aproximada. A outra abordagem usada no TOT é mais adequada para documentos não vistos, como seriam encontrados em tarefas de análise de dados em grande escala e tarefas de aprendizagem não supervisionadas; este é o procedimento representado na Figura 5. Ao contrário da abordagem anterior, apenas um carimbo de data / hora por documento é gerado a partir de uma combinação das distribuições Beta por tópico ao longo do tempo, onde o peso de uma mistura é o multinômio por documento sobre os tópicos que foi amostrado da distribuição de Dirichlet ÿ. O modelo pode, portanto, prever uma atribuição de tempo dada a palavra contida em um documento. A introdução de um hiperparâmetro de balanceamento, como o usado para funções de suavização em LDA, torna os processos de estimativa de parâmetros entre as duas abordagens quase equivalentes e redimensiona a probabilidade para a combinação com diferentes modelos [34] .

Machine Translated by Google

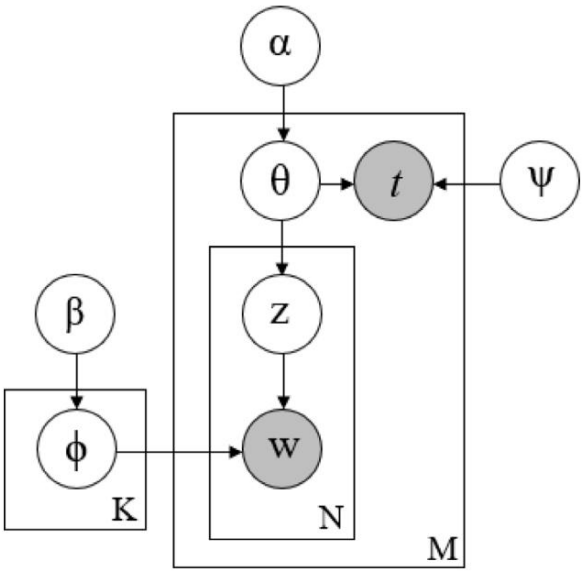

5. Um diagrama de notação de placa do processo TOT adequado para encontrar dados invisíveis. Neste gráfico, *t* indica o carimbo de data/hora de um único documento, enquanto ÿ descreve as distribuições beta por tópico ao longo do tempo. Todas as outras variáveis são semelhantes às observadas nas figuras anteriores.

Embora este método tenha sido muito citado em outros trabalhos e demonstre grande versatilidade em suas aplicações, sua proposta original apenas comparou o desempenho do TOT com um modelo LDA e não com métodos mais comparáveis, como modelagem de tópicos DTM ou MDL. Os autores discretizaram o modelo LDA em unidades anuais, no entanto, isso foi feito post-hoc e não inclui considerações para a evolução das distribuições de tópicos, como foi usado no DTM [34]. Isto limita a capacidade de avaliar com precisão as melhorias deste método, uma vez que o LDA não foi concebido para modelação de dados sequenciais e, portanto, não se espera que tenha um bom desempenho. A comparação das pontuações de divergência KL entre TOT e LDA em três corpora distintos demonstrou que o TOT foi capaz de produzir tópicos mais diferenciados entre si. Além disso, histogramas de tópicos ao longo do tempo e distribuições beta para os modelos TOT em comparação com os modelos LDA mais similares produzidos mostraram que o TOT foi capaz de formar picos de tópicos altamente resolvidos no tempo. Isto permitiu um isolamento muito específico de padrões temporais relativos a eventos históricos; por exemplo, os autores demonstram que o TOT pode isolar o tema do Canal do Panamá nos anos que cercam a virada do século 20, enquanto o LDA comparável formou grandes estruturas de pico por volta de 1850 e 1900, com sinais significativos até 2000. Outros corpora testado no artigo também demonstrou aplicações TOT em outros campos, como análise de trabalhos acadêmicos, documentos de e-mail e correspondência e discursos escritos [34]. Em comparação com outros modelos de tópicos em dificuldade computacional, o TOT é simples, o que lhe confere uma vantagem sobre alguns modelos que requerem vários estágios de estimativa e otimização de parâmetros. No entanto, como os modelos anteriores, presume-se que *k* seja conhecido para cálculos, o que significa que encontrar a contagem de tópicos ideal requer etapas adicionais.

Considerando os resultados da comparação dos próprios autores e as aplicações deste método na literatura, esta abordagem é adequada para campos como análise de mídias sociais, análise de mídia noticiosa e estudos on-line. Embora tenha havido muitos estudos utilizando esta abordagem para a análise de arquivos acadêmicos e estudos de autores-documentos, o DTM também tem sido igualmente, se não mais, popular para tais tarefas. Este modelo seria recomendado para qualquer pesquisa que seja altamente dependente de pesquisas complexas ou irregulares.

eventos temporais, eventos históricos e tendências virais. Além disso, o TOT é adequado para combinação com outros processos de modelagem de tópicos ou com outros modelos probabilísticos para extrair medidas mais abstrusas, como explosão e padrões espaço-temporais. No geral, esta abordagem é altamente versátil e pode ser usada para praticamente qualquer aplicação; no entanto, seu valor para análise de dados temporais e correlacionados deve ser considerado predominantemente ao selecionar outros processos de modelagem de tópicos.

4.4. Modelos de tópicos otimizados para texto curto

Embora a modelagem de tópicos seja frequentemente usada para classificação de documentos on-line e análise de tendências, foi demonstrado que as abordagens tradicionais de modelagem de tópicos têm dificuldades quando se trata de documentos coletados em sites de mídia social, que muitas vezes estão sujeitos a um limite de caracteres e, portanto, têm um número significativo de caracteres. comprimento de documento mais curto [3]. A redução na eficácia da modelagem de tópicos nessas situações é o resultado do conjunto muito limitado de co-ocorrências entre palavras que ocorrem em documentos de extensão tão curta em comparação com outras fontes documentais mais tradicionais. Muitas abordagens foram desenvolvidas para lidar com essas questões de dispersão, e pesquisas significativas estão sendo feitas neste campo específico de modelagem de tópicos. Várias estratégias que foram propostas consideram diretamente as co-ocorrências de palavras em vez de modelar identidades de documentos [7], considerar cada documento curto como decorrente de um tópico latente [35] e considerar laços heurísticos entre documentos, a fim de encadeá-los em "pseudodocumentos" maiores [36,37].

Uma proposta inicial para modelagem de textos curtos foi um processo chamado modelo de mistura de unigramas (MU), que considerava cada documento curto como sendo o resultado da amostragem de um único tópico latente [11,35]. Esta abordagem demonstra uma melhoria significativa em relação ao LDA [7] e demonstrou ter um desempenho competitivo com métodos mais novos e mais complicados [36], mas não reflete a realidade de que um texto curto pode cobrir uma variedade de tópicos. Outra abordagem semelhante foi proposta, chamada modelo de tópico biterm (BTM) [7] (https://github.com/xiaohuiyan/ BTM); o código fornecido é do autor e foi escrito principalmente em C++ e um pouco de Python. O BTM modela diretamente o processo gerador de co-ocorrência; isso também é semelhante ao modelo Bi-gram, que considera associações entre palavras aplicando o conceito de ordem das palavras ao processo de modelagem; no entanto, o modelo Bigram também usa co-ocorrências como estatística para apoiar a produção de tópicos em vez de modelar as co-ocorrências, e dá mais importância à ordem das palavras do que à co-ocorrência [7] . Embora o BTM pretendesse maximizar o uso de co-ocorrências em textos curtos, muitas vezes não conseguia diferenciar entre documentos curtos e longos [37]. Outro método chamado modelo de tópico esparso duplo (DSTM) substituiu o anterior de Dirichlet no LDA pelo que é chamado de anterior de Spike e Slab, que em teoria aprende tópicos e termos específicos para um documento [38] . Ambas as abordagens mencionadas acrescentam pouco nos meios de coocorrência de palavras e, portanto, ainda encontram problemas de escassez de dados. Como tal, não forneceremos uma explicação detalhada desses métodos em nossa análise. O modelo de mistura de unigramas também não será descrito, pois buscamos dar preferência a métodos de modelagem mais recentes e avançados para esta seção.

4.4.1. Modelos de tópicos auto-agregáveis A

abordagem de 'pseudo-documento' demonstrou ser significativamente mais eficiente quando se deparam com tais problemas de dispersão. Muitos métodos para isso são documentados em pesquisas de mídia social, como estudos do Twitter, e geralmente são agregados por alguma métrica observável, como autor, hashtags ou localização [3].

Esses métodos não requerem mudanças significativas na modelagem

Machine Translated by Google

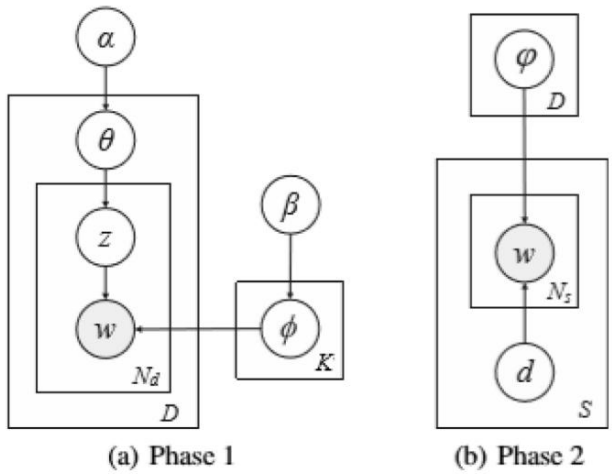

Figura 6. De Quan et al. um diagrama de notação de placa representando o processo generativo para SATM. Aqui, *D* indica o número de pseudodocumentos enquanto *S* representa os textos curtos presentes no corpus de dados original [36].

processo, já que a agregação de dados em torno de determinados parâmetros pode ser realizada facilmente pelo pré-processamento de dados. Embora essa agregação simples tenha sido benéfica para estudos específicos com interesse especial na modelagem de tópicos em torno de usuários ou locais, isso não é aplicável a dados de texto curto mais gerais, onde tais informações podem não estar prontamente disponíveis. O desenvolvimento de métodos de agregação generalizados para textos curtos foi desenvolvido mais recentemente e supera o obstáculo do contexto limitado. A primeira dessas abordagens é chamada de "Modelo de tópicos baseado em autoagregação" (SATM), desenvolvido por Quan, Kit, Ge e Pan em 2015 [36] (https://github.com/WHUIR/SATM); este código é do Wuhan University Information Retrieval Group e está escrito em Java. Este modelo não agrega métricas por autor ou palavras-chave, como hashtags, mas agrega textos curtos com temas semelhantes.

Em um corpus, presume-se que cada texto curto original seja uma amostra de um pseudodocumento há muito tempo não observado, que é atribuído ao encontrar sua "documentação"; este método é realizado integrando o processo de modelagem e o processo de autoagregação durante o curso da inferência de tópicos, baseando inicialmente a agregação na afinidade geral de tópicos dos textos, conforme aplicável a vários formatos de texto curto. Existem duas fases na geração do modelo, a primeira das quais segue a suposição do LDA de gerar documentos *D* de comprimento padrão; um documento individual gerado *d* é composto por uma sequência de palavras *wd* com tamanho de documento *Nd,* representando o número total de palavras. Isto corresponde ao desenvolvimento dos longos pseudodocumentos. Na segunda fase, cada um desses documentos é usado para gerar alguns textos curtos, sendo que cada texto curto pertence a exatamente um documento seguindo as suposições de uma mistura de unigramas. Um pequeno trecho de texto *é* composto por uma sequência de palavras *versus* um total de *Ns* palavras.

Este processo é apresentado na Fig .

Este método foi avaliado usando o conjunto de dados NIPS para produzir 200.879 textos curtos, tratando os documentos originais neste conjunto como pseudodocumentos longos latentes para comparar o desempenho. Uma coleção de 88.120 perguntas coletadas do Yahoo!

As respostas, que foram tomadas como textos curtos, também foram utilizadas para avaliação. Para o conjunto NIPS, o modelo foi julgado com base na sua capacidade de produzir tópicos a partir do conjunto de peças curtas que fossem comparativamente significativos aos tópicos gerados a partir dos longos documentos originais. Foi demonstrado que o SATM superou as abordagens de agrupamento Unigram e K-means na agregação de textos. Além disso, o SATM superou consistentemente o LDA, o Unigram e o BTM na formação de tópicos alinhados com os documentos longos originais em três valores *K* diferentes . O desempenho de SATM usando o corpus de texto curto coletado do Yahoo! mostrou que, embora tenha superado o BTM e o LDA, teve um desempenho significativamente melhor do que qualquer um dos outros modelos quando treinado pela primeira vez com um classificador SVM usando as categorias de perguntas retiradas do Yahoo! Site de respostas. Ao considerar a pós-inferência, o BTM tem um desempenho competitivo, mas ainda abaixo do SATM [36].

Apesar do forte desempenho deste modelo em sua proposta, existem muitos contratempos para esta abordagem específica. Primeiro, este modelo emprega variáveis latentes não observadas adicionais que devem ser consideradas na otimização – o número de pseudodocumentos. Isto é discutido no artigo e propõe-se que o número de pseudodocumentos que melhor se adapta a um conjunto de dados provavelmente depende da contagem ideal de tópicos; portanto, para encontrar o valor ideal para pseudodocumentos, seriam necessários mais testes iterativos, o que requer uma grande quantidade de computação para cada iteração e também torna a determinação do *k* ideal mais difícil. O total de variáveis no SATM aumenta à medida que conjuntos de dados maiores são usados, tornando o modelo suscetível a overfitting e resultando em uma complexidade de tempo inaceitável para uso prático. Embora seja necessário mais trabalho para melhorar este modelo, ele demonstra potencial e vale a pena considerá-lo para aqueles que têm meios para executar tais algoritmos. No entanto, para trabalhos relacionados com meios de comunicação social ou outros documentos ricos em contexto, métodos simples de agregação, como a agregação de autores ou palavras-chave, seriam mais adequados.

Com base no trabalho do SATM, um novo método denominado modelo de tópico baseado em pseudo-documento (PTM) foi desenvolvido por Zuo et al. em 2016 [37]; não há implementação pública fornecida pelos autores, porém este modelo foi incorporado em outro projeto por. Este método reduziu a autoagregação de textos curtos em um único processo generativo [37]. Aqui o número de documentos será representado por *P* enquanto o número de textos curtos é representado por D. A distribuição multinomial de textos curtos sobre documentos é representada por ÿ, que é amostrado de um Dirichlet ÿ. Enquanto a amostragem de uma palavra no SATM custa *O(PK)* tempo devido ao seu processo de duas etapas, o custo de amostragem de uma palavra no PTM é *O(K)* e, portanto, é menos intensivo [37]. Além disso, a segunda etapa do SATM significa que a probabilidade de pseudodocumentos em textos curtos deve ser estimada pelo processo de inferência de forma independente, resultando no aumento linear dos parâmetros com o aumento do tamanho do corpus; é isso que faz com que o SATM seja propenso a overfitting em casos de dados de treinamento limitados. Em comparação, o PTM produz textos curtos seguindo o procedimento utilizado na LDA dado o pseudodocumento singular a que pertencem.

Cada pseudodocumento é essencialmente um "tópico híbrido" gerado a partir dos tópicos individuais dos múltiplos textos curtos que contém [37]. Infelizmente, isto significa que nos casos em que o número total de pseudodocumentos é reduzido, os tópicos tendem a ser menos específicos e significativos. Portanto, considerando cenários onde *P* é pequeno, Zuo et al. também propõem uma versão esparsa do PTM que utiliza o Spike and Slab prior, chamada SPTM [37].

Este método é significativamente mais complexo que o PTM e não será descrito em detalhes, mas pode ser encontrado em [37]; os processos generativos para PTM e SPTM são fornecidos na Fig .

Usando dados de sites de notícias, títulos de artigos de conferências em diversos campos da ciência da computação, perguntas feitas em um determinado site e tweets rotulados vinculados a sites, foi demonstrado que o SPTM superou LDA, MU e DSTM consistentemente na modelagem de tópicos de texto curto, embora outros métodos podem ter sido competitivos. O SATM superou muito o SPTM na modelagem de tweets e superou por pouco o SPTM na modelagem quando a quantidade de dados de treinamento era pequena [37]. Este método apresenta grande potencial e tem sido frequentemente citado em trabalhos recentes; no entanto, mesmo no âmbito do seu documento de proposta, foi superado em vários conjuntos de dados e muitas vezes esteve muito próximo do desempenho de outros métodos. Representa uma solução muito mais rentável para modelar textos curtos que têm contexto limitado em comparação com o SATM e, portanto, certamente deve ser considerado se alguém estiver procurando modelar tais dados.

Machine Translated by Google

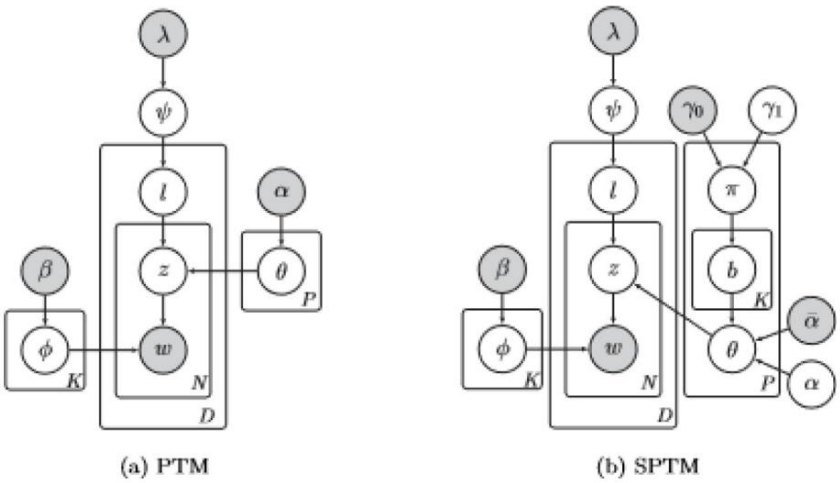

Figura 7. De Zuo et al. uma notação de placa representando o processo generativo para PTM e SPTM. A variável *l* representa um pseudodocumento na geração de textos curtos [37].

4.5. Outros designs de modelos de tópicos significativos

Um algoritmo alternativo ao LDA é a Fatorização de Matriz Não Negativa (NMF) [39], desenvolvida em 1999 por Lee e Seung. Embora tenha precedido a proposta do LDA, este método demonstrou funcionar de forma eficaz para extrair tópicos de corporações de texto [40]. O NMF não é supervisionado, comparado ao LDA, que pode ser supervisionado ou não, e utiliza métodos de redução de dimensionalidade para 'matrizes não negativas', ou uma matriz composta apenas por componentes de valor positivo ou zero [39] . Isso é semelhante a muitas das abordagens das quais a modelagem de tópicos evoluiu, como redução *tf-idf* [12] e LSI/LSA [13]. Ao contrário da redução *tf – idf ,* um corpus aqui é considerado como uma matriz documento por termo da dimensão V por D e esta abordagem busca aproximar esta matriz como o produto de dois fatores não negativos k-dimensionais contendo a adesão pesos de seus componentes, que podem ser chamados de **W** e **H** [39,41]. As linhas de **H** podem ser vistas como os pesos para cada termo respectivo das *V* palavras contidas no vocabulário do corpus, representando *k* tópicos, dando-lhe uma dimensionalidade de k por V. As colunas de **W** representam então os pesos relativos a cada um dos documentos *D* em relação a cada tópico, conferindo-lhe uma dimensionalidade de D-por-k. Se pegarmos **H** e ordenarmos cada uma de suas linhas, será formada uma classificação dos termos em relação ao tópico daquela linha, fornecendo assim um descritor de tópico. Este método é geralmente inicializado pela atribuição aleatória de pesos aos elementos de **W** e H, e então melhorando iterativamente esses fatores através da aplicação de um algoritmo de otimização que visa reduzir o erro de aproximação até que o processo atinja um mínimo localizado [41]. Embora o NMF tenha menos parâmetros que precisam ser selecionados para o processo de modelagem e tenha demonstrado distinguir tópicos mais realistas do que o LDA, os valores iniciais para os pesos tópico-termo e tópico-documento têm grande influência nos resultados finais durante a otimização que têm demonstrou persistir através de execuções iterativas do modelo [41]. Como esses valores são atribuídos aleatoriamente, isso resulta em altos níveis de imprecisão e falta de reprodutibilidade dos fatores finais. Uma melhoria nesta abordagem foi a "Decomposição de Valores Singulares Duplos Não Negativos" (NNDSVD), proposta por Boutsidis e Gallopoulos em 2008, que seleciona fatores de pré-modelagem por meio de uma estimativa da matriz do corpus e do uso de valores singulares esparsos decomposição [42]. Teoricamente, o NNDSVD poderia convergir para pares de fatores idênticos entre execuções de modelos individuais, dependendo de qual aplicação do SVD é empregada, e demonstrou eficiência significativa ao usar dados baseados em texto e outras fontes esparsas [41].

Existem vários outros métodos publicados para melhorar modelos de tópicos que são dignos de nota para aqueles que procuram realizar tal análise de dados. Uma dessas técnicas é o “Processos Hierárquicos de Dirichlet” (HDP), apresentado por Teh et al. [43] (https://github.com/blei-lab/hdp); o código fornecido é do autor e utiliza inferência de amostragem de Gibbs, na linguagem de codificação C++. Esta é uma abordagem de modelagem bayesiana não paramétrica, projetada especificamente para lidar com problemas de agrupamento de múltiplos conjuntos de dados e para “aprendizado multitarefa” usando o modelo de mistura do processo Dirichlet (DP). Este método aprende automaticamente o número apropriado de componentes da mistura a serem usados em um conjunto de dados e pode compartilhar a força estatística entre grupos de dados [43]. Foi demonstrado que isso pode ser aplicado com um modelo LDA, bem como com outras abordagens de modelos de tópicos para facilitar o aprendizado automático de tópicos ou a capacidade de encontrar o número de tópico ideal sem seleção do usuário, [44,45] . No entanto, para utilizar esta funcionalidade, dois modelos devem ser construídos para um único corpus, o que pode complicar ainda mais o processo de modelagem de tópicos, exigindo duas etapas de cálculos do algoritmo de inferência e estimativa de parâmetros para alcançar o design do modelo ideal.
A adição de um processo anterior bayesiano não paramétrico para determinação *de s* no PAM também foi sugerida por Li et al. [9], que é desenvolvido a partir de uma variação da abordagem HDP; no entanto, tal processo encontra os mesmos problemas de eficiência e demandas de computação que ocorreu no LDA. Dos métodos de modelagem de tópicos discutidos, apenas o HDP é projetado de tal forma que o algoritmo aprende automaticamente o melhor número de tópicos e não precisa receber um valor *k* do usuário [43,45]; no entanto, este método ainda requer otimização significativa para produzir resultados desejáveis [45].

Outros modelos que não foram discutidos incluem aqueles que consideram a ordem das palavras. Alguns exemplos deles são o modelo hierárquico de linguagem Dirichlet (HDLM) [46] e o modelo bigrama [47]. Como os relacionamentos entre documentos são frequentemente de maior interesse do que os relacionamentos intradocumentos na análise de big data, esses métodos não foram descritos em detalhes para esta revisão. Se a ordem das palavras for de interesse para um conjunto de dados específico, esses métodos deverão ser estudados.

5. Melhorias e otimização da modelagem de tópicos

5.1. Métodos de inferência e aproximação

Está bem estabelecido que muitos destes modelos, particularmente LDA, requerem ajuste e otimização para produzir

Machine Translated by Google

resultados de um conjunto de dados. Por esta razão, inferência e aproximação de variáveis ocultas são altamente recomendadas em vez de configurações padrão que podem ser incluídas em software de modelagem de tópicos [5].
A distribuição posterior é incomputável em todos os métodos mencionados anteriormente e, portanto, a inferência exata não é possível; entretanto, essas distribuições são necessárias para usar esses processos. Há uma variedade de algoritmos de aproximação que funcionarão para muitos desses métodos de modelagem de tópicos, embora vários métodos possam ser mais adequados para tipos específicos de algoritmos do que outros. Descreveremos esses algoritmos aqui e discutiremos quais métodos eles seriam mais adequados em determinadas circunstâncias. Encorajamos a revisão da literatura original para quaisquer métodos de modelagem de tópicos de interesse para os métodos de aproximação sugeridos, pois eles são frequentemente ajustados para melhor desempenho com o modelo.

5.1.1. Amostragem de Monte Carlo e Gibbs em cadeia de Markov

Um conjunto comum de algoritmos de aproximação e inferência para modelagem de tópicos vem de uma família de métodos chamada Cadeia de Markov Monte Carlo (MCMC). Essas abordagens recebem esse nome porque utilizam integração de Monte Carlo, um método desenvolvido por físicos que usa números gerados aleatoriamente para calcular integrais, para formar uma "cadeia de Markov"—. Por "cadeia de Markov", entendemos uma série de variáveis arbitrárias cujas probabilidades de transição entre valores distintos no espaço de estados dependem exclusivamente do estado existente da variável aleatória. Assim, este processo utiliza o valor da amostra anterior para produzir aleatoriamente o valor da amostra subsequente; o objetivo desta abordagem é simular o desenho direto de uma distribuição de probabilidade complicada. Os métodos MCMC surgem dos conceitos do "algoritmo Metropolis-Hastings", que é capaz de gerar uma cadeia de Markov a partir de distribuições de probabilidade complexas que de outra forma seriam difíceis de amostrar, como distribuições de alta dimensionalidade [48] .

A abordagem mais popular na inferência Bayesiana é o método de amostragem de Gibbs. Isto também é derivado da estrutura de algoritmos MCMC, considerada um caso especial de Metropolis-Hastings com uma razão de Hastings sempre igual a 1 [48]. A amostragem de Gibbs busca gerar uma cadeia de Markov com a distribuição posterior desejada como sua distribuição estacionária, o que significa que após várias iterações a retirada de amostras da estacionária deve se aproximar da distribuição posterior de escolha. Especificamente, a amostragem de Gibbs funciona por amostragem a partir de distribuições condicionais das variáveis posteriores. Dada uma distribuição conjunta **p(x)** = *p(x1, ..., xm)* sem solução de forma fechada para **p(x) ,** mas fornecida com uma representação para distribuições condicionais, a amostragem de Gibbs primeiro inicializa aleatoriamente cada *xi* .

Então, para cada iteração *t* seguimos o seguinte processo [48]:

$$x_1^{t+1} \sim p(x_1 \mid x_2^{(t)}, x_3^{(t)}, \ldots, x_m^{(t)}) \tag{7}$$

$$x_2^{t+1} \sim p(x_2 \mid x_1^{(t+1)}, x_3^{(t)}, \ldots, x_m^{(t)}) \tag{8}$$

$$x_m^{t+1} \sim p(x_m \mid x_1^{(t+1)}, x_2^{(t+1)}, \ldots, x_{m-1}^{(t+1)}) \tag{9}$$

Isso é repetido até que as amostras comecem a convergir para uma amostra que seria retirada da verdadeira distribuição posterior. Na prática, esta técnica tem um bom desempenho e é teoricamente garantida a convergência; entretanto, não é possível saber quantas iterações são necessárias para abordar adequadamente a distribuição estacionária. A convergência é normalmente estimada calculando a probabilidade logarítmica e, em alguns casos, observando visualmente os pontos de dados plotados para julgar se o modelo atingiu um estado semelhante ao equilíbrio ou 'estacionariedade'. Uma vez que a amostragem atingiu esta estacionaridade, qualquer flutuação entre os pontos de dados é considerada erro padrão [48]. Muitas vezes as amostras do início da cadeia podem não representar com precisão a distribuição desejada e são descartadas antes de começar a coletar dados; esse intervalo de dados é geralmente chamado de período de "burn-in" ou "warm-up"; além disso, quaisquer pontos de dados descartados são geralmente chamados de valores "burn-in" [48,49].
Embora este processo tenha sido recomendado por muitos no terreno, não é necessário alcançar a convergência; no máximo, reduz a quantidade de dados que precisam ser coletados para avaliar a convergência em cenários onde o algoritmo fez uma amostragem de um extremo da distribuição de probabilidade [49]. A prática geral na área é usar um período de burn-in não superior a 1 ou 2% inicial do número total de execuções, ou calcular uma estatística chamada autocovariâncias e usar o tempo aproximado que leva para esse valor decair para níveis insignificantes [49]. Ao considerar distribuições alvo multimodais, existe a possibilidade do que é chamado de mistura pobre, que é uma cadeia que parece estar confinada a uma pequena região do espaço de parâmetros [49]. Isso pode ser combatido utilizando múltiplos valores iniciais que estão bem dispersos para iniciar muitas cadeias simultâneas [49], ou realizando recozimento simulado em cadeia única [48]. O recozimento simulado imita essencialmente o padrão de uma estrutura cristalina de resfriamento para permitir mais variação no movimento no início do período de "resfriamento" e, em seguida, reduzir gradualmente a probabilidade de movimentos descendentes ao longo do tempo. Este processo é descrito em detalhes por Walsh [48] e deve ser revisado se a observação visual do processo de amostragem parecer uma mistura pobre, se os valores de autocovariância permanecerem significativos ou se a distribuição alvo for conhecida por ser multimodal [48,49] . Cadeias de mistura de poços são cadeias que demonstram um alto grau de exploração do espaço de parâmetros antes de convergir para o equilíbrio.

O método básico de amostragem de Gibbs é diretamente recomendado e utilizado para aproximar inferências posteriores nas publicações para diversas abordagens de modelos de tópicos, incluindo PAM, BTM e HDP [7,9,43]; no SATM, recomenda-se o processo duplo ao longo do método para anexar textos curtos como estados especiais, a fim de melhor modelá-los [36]. Em um modelo como o LDA, os usuários estão interessados nas variáveis latentes ocultas – as distribuições de tópico de documento *ÿd,* as distribuições de tópico-palavra ÿ (z) e as atribuições de índice de tópico de cada palavra *zi* . Embora a amostragem tradicional de Gibbs possa ser usada para LDA derivando as distribuições condicionais dessas variáveis latentes, existe um método mais fácil. Como **z** pode ser usado como uma medida estatística apropriada para *ÿd* e ÿ *(z)* e, portanto, pode ser estimado usando *zi ,* os parâmetros multinomiais podem ser integrados e a amostragem pode ser realizada apenas em *zi* .

Isso é chamado de técnica de amostrador de Gibbs colapsado e pode ser usado em LDA e seus métodos de derivada direta [25] e também é sugerido para PTM [36]. Uma abordagem semelhante também é adotada ao usar a amostragem de Gibbs no TOT, exceto que a amostragem é feita a partir da distribuição beta ÿz em vez da atribuição do índice de tópico [34]. Aplicações para amostragem de Gibbs também foram propostas recentemente para aproximar a parte posterior no DTM usando uma abordagem em blocos; a proposta, de Bhadury et al. sugere um algoritmo de inferência paralelizável que combina amostragem de Gibbs com Stochastic Gra-dient Langevin Dynamics (GC-SGLD) [50]. Esta abordagem revela-se muito mais rápida que os algoritmos de aproximação recomendados por Blei et al. que utiliza filtragem variacional de Kalman e regressão wavelet [8]. Como este novo algoritmo é muito mais escalável do que os métodos anteriores, ele permite que dinâmicas de tópicos maiores sejam capturadas usando DTM, o que abre esta abordagem de modelo de tópico para uso mais industrializado. Para qualquer pesquisador que considere o uso de DTM para análise de Big Data, é altamente recomendável que esta publicação seja revisada como um possível método para melhorar a velocidade e também o desempenho da modelagem de tópicos.

Os algoritmos MCMC e a amostragem de Gibbs são geralmente muito versáteis e podem ser facilmente adaptados a muitas aplicações diferentes. Estas abordagens oferecem uma aproximação calculada para a distribuição posterior exata usando uma coleção de amostras, e muitas vezes

Machine Translated by Google

tem um bom desempenho para amostragem de probabilidades difíceis. No entanto, este método não permite que o tempo de convergência seja facilmente avaliado e pode sofrer mistura lenta; nestes casos, métodos como múltiplos pontos de partida ou recozimento simulado precisam ser considerados para alterar o curso para a convergência. A geração de muitas pequenas cadeias tem sido especulada como um método para quem tem acesso ao processamento paralelo; no entanto, não é ideal, pois é improvável que a convergência seja alcançada para muitas das execuções [49]. Em vez disso, recomenda-se executar várias execuções curtas para determinar a duração das iterações necessárias para aproximar-se da convergência e, em seguida, executar uma ou mais execuções mais longas para convergir com precisão para a distribuição desejada. Também é recomendado que, ao realizar múltiplas execuções, inicie cada nova execução a partir do ponto final da execução anterior; isso é recomendado sob a suposição de que a amostra da execução anterior foi distribuída aleatoriamente, mas estava em processo de convergência para a distribuição alvo [49]. Uma regra semelhante é recomendada para semear geradores de números aleatórios, que afirma que tentativas de reiniciar o processo com uma semente "aleatória" destruirão a aleatoriedade desse gerador e somente quando usado como um fluxo contínuo o gerador retém as propriedades que fez é desejável que do utilizador.

5.1.2. Aproximação variacional

A preocupação com a inferência MCMC é que, para conjuntos de dados de alta dimensionalidade ou modelos não congruentes, esse método não é computacionalmente viável e leva um tempo significativo para ser executado [51]. Os métodos de aproximação Bayesiana Variacional (VB) são, portanto, recomendados em vez do MCMC para grandes conjuntos de dados e modelos de mistura [51–53]. Os métodos VB diferem dos métodos de amostragem MCMC ao realizar inferência estatística de uma maneira importante; enquanto os métodos MCMC tentam aproximar uma solução numérica da distribuição posterior exata usando um conjunto de amostras, as abordagens VB tentam fornecer uma solução analítica exata na forma de uma fórmula discreta para uma aproximação da posterior. Isso pode ser descrito como a aplicação de um grupo de densidades sobre as variáveis desconhecidas que são parametrizadas por "parâmetros variacionais livres", e a otimização destas usando uma métrica específica chamada divergência de Kulback-Liebler (KL) para descobrir qual delas os parâmetros são mais semelhantes à densidade condicional de interesse. Minimizar esta métrica equivale a maximizar a evidência, ou a densidade marginal das observações [51]. Esses métodos são frequentemente mais gerenciáveis computacionalmente do que o MCMC, mas custam as garantias teóricas dos métodos de simulação; no entanto, existem vários critérios para avaliar a convergência desses algoritmos. Existem muitas abordagens diferentes que se enquadram nesta classe de algoritmos de inferência. Em Blei et al. o algoritmo bayesiano variacional recomendado é uma mistura de uma estrutura tradicional de maximização de expectativa variacional (EM) e uma abordagem de máxima verossimilhança variacional (ML) [11].
O CTM é recomendado com métodos de aproximação de campo médio [6], e o DTM é recomendado para a abordagem variacional de filtragem de Kalman, bem como a abordagem de regressão Wavelet sob a mesma distribuição variacional de variáveis latentes em nível de documento que LDA [8] . Também houve uma proposta de Teh et al. descrevendo o processo de uso de um algoritmo de inferência bayesiana variacional colapsado, que combina elementos de métodos bayesianos variacionais e amostragem de Gibbs colapsada, para LDA [52].
Começaremos discutindo abordagens semelhantes que são frequentemente mencionadas durante essas aproximações.

As abordagens VB podem ser consideradas como uma expansão do algoritmo "Expectation-Maximization" (EM) [51]. Este algoritmo alterna entre uma etapa "E", na qual a distribuição das variáveis latentes é inferida assumindo o presente parâmetro estimado que descreve as dependências estocásticas entre variáveis, e um passo "M", que maximiza a verossimilhança encontrada no passo E ao reestimar este parâmetro [51,53]. Este processo é atualizado continuamente e a cada iteração o passo E maximiza o limite inferior em referência à distribuição distinta para o ponto de dados atual, e o passo M maximiza as dependências das variáveis [53]. O uso de EM para modelagem de tópicos é frequentemente limitado à otimização restrita ou aproximada, pois as distribuições posteriores para esses métodos são intratáveis [53]. Nesta abordagem, as distribuições posteriores são obrigadas a ter uma forma tratável, como fatoradas sobre uma variável, e a maximização durante a etapa E serve também para minimizar a divergência KL entre a distribuição variacional e a variável oculta exata [53] . Consulte Beal para uma explicação detalhada do processo algorítmico e várias otimizações relevantes para trabalhar dentro de um cenário de modelagem de tópicos, como EM bayesiano variacional, otimização de hiperparâmetros e sua aplicação em vários tipos de modelos probabilísticos [53] . Esta é uma abordagem iterativa e, portanto, pode consumir muito tempo ao trabalhar com grandes conjuntos de dados; tem havido pesquisas significativas sobre possíveis métodos de aceleração de algoritmos EM, como o emprego de uma etapa E parcial em uma parte do conjunto de dados total para permitir a execução de etapas M mais frequentes, atualizando assim os parâmetros com mais frequência [54] . Embora esse método possa potencialmente acelerar a convergência com pouca sobrecarga, é difícil executá-lo em paralelo devido à necessidade de atualização global dos recursos de cluster. Isto requer sincronização de trabalhadores dentro de um ambiente distribuído, o que pode resultar em sobrecarga significativa; no entanto, Yin et al. discuta como o controle da frequência de atualizações de parâmetros pode melhorar o desempenho de algoritmos EM paralelos [54]. Esta nova abordagem pode ser usada de duas maneiras - "concorrente parcial" ou "concorrente de subfaixa". No primeiro método, cada etapa E estima a distribuição da variável oculta dentro de um bloco do conjunto total e o tamanho do bloco determinará a frequência de atualização dos parâmetros. O método do subintervalo funciona de maneira semelhante, exceto que cada etapa E é responsável por processar a distribuição de variáveis ocultas dentro de um subintervalo e o tamanho do subintervalo determina a frequência de atualização. Foi demonstrado que ambas as abordagens mantêm as propriedades de convergência do algoritmo EM, no entanto, a abordagem concorrente parcial teve melhor desempenho em comparação com a abordagem concorrente tradicional, bem como a abordagem simultânea de subfaixa para LDA [54] .

Outro método dentro desta classe de aproximações é o método de aproximação de campo médio. Este método é mais adequado para modelos que são conhecidos por terem uma distribuição densa [55]. Ele assume que há muitas influências de cada nó de um modelo gráfico a partir dos nós adjacentes, a tal ponto que cada efeito individual é pequeno e a influência geral pode ser considerada apropriadamente aditiva. Assim, cada nó pode ser representado aproximadamente pelo seu valor médio, principalmente nos casos em que a “lei dos grandes números” pode ser utilizada [55]. Cada variável latente sob esta suposição é considerada independentemente de outras variáveis latentes e cada uma é fatorada distintamente na densidade variacional [51].
Um fator variacional pode assumir uma forma paramétrica que seja adequada à sua variável aleatória correspondente – como um fator contínuo para uma variável contínua ou um fator categórico para uma variável categórica. Nos métodos variacionais de campo médio, o objetivo é formar uma distribuição fatorada dessas variáveis que são parametrizadas por parâmetros variacionais livres [55]. Tal como acontece com EM, os parâmetros são ajustados aos dados de forma que o valor da divergência KL seja minimizado; no entanto, requer alguma otimização para fazê-lo de forma eficaz. A inferência variacional de campo médio pode ser adaptada para diversas situações, como aplicada a misturas de densidades variacionais e consideração de dependências entre variáveis; estes apresentam maior dificuldade computacional ao realizar a otimização. Embora este método seja útil porque pode expressar qualquer densidade marginal de variáveis ocultas, é

Machine Translated by Google

não é capaz de considerar as correlações entre variáveis latentes [51]. Isto pode resultar em certas limitações, especialmente quando se consideram distribuições altamente correlacionadas. Um exemplo é quando se considera esta aproximação para uma distribuição gaussiana de duas dimensões, conforme descrito por Blei et al. [51]. A distribuição alvo é altamente alongada devido à correlação entre as Gaussianas; no entanto, a aproximação ideal do campo médio é centralizada apenas em torno da média das duas distribuições e, portanto, representa abaixo da densidade alvo [51].

Existem muitas outras abordagens VB que foram empregadas na modelagem de tópicos, no entanto, optamos por focar naquelas que foram generalizadas para uma variedade de métodos ou foram especificamente mencionadas na publicação revisada. Tanto [51] quanto [53] oferecem informações significativas sobre o projeto e a otimização desses processos, juntamente com recomendações sobre quais métodos utilizar.

5.2. Métodos de seleção K

Conforme discutido anteriormente, muitos métodos de modelagem de tópicos compartilham a mesma falha de assumir que a contagem ideal de tópicos é um determinado valor, criando assim a necessidade de que o número ideal de tópicos seja determinado externamente ou por meio de processos iterativos para obter resultados significativos. Tem havido várias abordagens para superar este obstáculo através da avaliação de modelos; esses métodos assumem que o número ideal de tópicos produzirá o melhor ajuste aos dados, aplicando modelagem de tópicos a um subconjunto de dados de treinamento e iterando sobre diferentes valores *de k* .

5.2.1. Perplexidade

Um trabalho recente de Zhai et al. propõe uma abordagem baseada em perplexidade para avaliar modelos de tópicos onde a "taxa de mudança de perplexidade" (RPC) é calculada ao longo de iterações, e o ponto de viragem deste valor é usado para selecionar o número de tópicos mais adequado [27]. Para a aplicação deste método em relação à abordagem anterior baseada em perplexidade, os dados foram divididos aleatoriamente em *m* subconjuntos (S1, S2, ..., *Sm)* e os modelos foram construídos utilizando validação cruzada m-fold para um intervalo de tópicos *t* = 1 para *t* = r. As perplexidades médias de *m* conjuntos de testes para cada valor de tópico *t* são representadas como P1, P2 ,. . . *Pr* . Portanto, o RPC para uma contagem de tópicos *ti* , dado que *i* é maior ou igual a 1 e menor que *r* pode ser calculado por:

$$RPC\ (i) = \frac{\sqrt{Pi \cdot Pi-1}}{ti - ti-1} \qquad (10)$$

Zhao et al. descobriram que, ao aplicar ambas as abordagens a um conjunto de dados de 119 cepas *de Salmonella* , a abordagem baseada em RPC demonstrou mais exatidão ao selecionar o mesmo número de tópico ideal em 80% de seus modelos replicados, em comparação com a maioria de 46% selecionada apenas por perplexidade [27] . Além disso, ao calcular a entropia média dos dois métodos, a abordagem RPC obteve pontuação significativamente inferior à perplexidade, 1,0 a 1,853, respectivamente. Quando o agrupamento K-means foi usado para determinar a precisão dos modelos de tópicos, descobriu-se que ambos os métodos selecionaram tópicos que resultaram na maior pureza, 0,96; no entanto, o RPC escolheu o número de tópico mais baixo, o que resultaria em tempos de execução mais rápidos e, portanto, foi considerado mais eficiente [27]. Embora a perplexidade por si só tenha sido geralmente o método padrão para determinar iterativamente os números dos tópicos e comparar modelos, o método baseado em RPC demonstrou um potencial considerável como ferramenta avaliativa.

O método de perplexidade é propenso à instabilidade e pode variar muito entre as iterações, mesmo no mesmo subconjunto de dados, portanto, não é a abordagem ideal para determinar *k* para um conjunto de dados; entretanto, em muitos casos é o melhor método disponível aos pesquisadores e ainda é frequentemente empregado. Embora o método RPC descrito por Zhao et al. demonstrou melhoria significativa em relação à abordagem anterior, ainda requer geração de modelo de tópico iterativo para determinar valores *k* ideais [27].

5.2.2. Processo hierárquico de Dirichlet

Como afirmado anteriormente, o modelo HDP é um método viável para determinar automaticamente o número de tópicos [43]. É comumente usado em combinação com LDA ou modelos de mistura, mas também tem sido aplicado a muitos outros métodos [53,55]. Para uma discussão mais aprofundada do HDP, consulte o segundo parágrafo da Seção 4.5.

6. conclusões

A Alocação Latente de Dirichlet (LDA) é o método mais utilizado para modelagem de tópicos, porém está longe de ser o único. Embora o LDA possa ser adequado para tarefas gerais de modelagem de tópicos usando uma variedade de dados, ele não é capaz de modelar relacionamentos de dados mais avançados e tem um desempenho fraco quando os documentos não têm comprimento suficiente. Esta é uma limitação para muitas aplicações de pesquisa porque relações complexas com o tempo e entre tópicos estão presentes em todos os tipos de dados. Ignorar a existência dessas métricas faz com que o valor real desta análise seja limitado. Há uma variedade de outras abordagens que muitas vezes são ignoradas por aqueles que procuram realizar modelagem de tópicos em um conjunto de dados; em muitos casos, a aplicação de um método mais adequado pode melhorar significativamente os resultados e é a diferença entre tópicos obscuros e irrelevantes e uma análise de dados significativa. No entanto, apesar da riqueza de abordagens disponíveis, não temos conhecimento de quaisquer revisões abrangentes dos métodos atuais de modelagem de tópicos.
Portanto, há uma grande necessidade de tal documento, a fim de promover de forma mais eficaz a profundidade do trabalho que tem sido feito no campo.

Apresentamos neste artigo uma revisão aprofundada dos métodos de modelagem de tópicos, desde os testados ao longo do tempo e desenvolvidos habilmente até as técnicas novas e inovadoras. Esta revisão começa com uma discussão dos algoritmos e abordagens sobre os quais os métodos modernos de modelagem foram construídos. Em seguida, estabelecemos os termos e símbolos que são usados ao longo do artigo para descrever os diferentes métodos de modelagem de tópicos. A revisão dos métodos foi separada em seções que permitem fácil identificação do uso de cada método e suas características especiais.
Também discutiremos brevemente as técnicas de otimização desses algoritmos para melhor refletir o conjunto de dados, o que é extremamente importante para produzir resultados significativos ao usar abordagens de modelagem probabilística. Através desta revisão, encorajamos abordagens mais diversificadas ao implementar modelagem de tópicos para fins de pesquisa. A classificação dos métodos em nossa revisão é flexível e permite acréscimos e atualizações à medida que novos métodos são desenvolvidos.
Acreditamos que este artigo de revisão seja um recurso para um engenheiro ou cientista que busca realizar tais estudos que possam direcioná-los para um método de modelagem apropriado e atuar como uma referência generalizada para aqueles que buscam criticar estudos que utilizam modelagem de tópicos.

Para melhor direcionar os leitores para os métodos que melhor atendem às suas necessidades individuais, produzimos uma árvore de decisão utilizando informações sobre as características e desempenho de cada modelo quando comparado com outros modelos (ver Fig. 8) . Isso permitirá que um método seja selecionado com base nos objetivos da pesquisa que se deseja realizar e nas características dos dados disponíveis. Eles devem então revisar a seção sobre o método selecionado para confirmar se ele será adequado para o que desejam alcançar. Este não é um guia detalhado, e considerações como o grau de complexidade do relacionamento do tópico e a quantidade de otimização necessária são descritas com mais detalhes ao longo do artigo e nas publicações do método original.

Machine Translated by Google

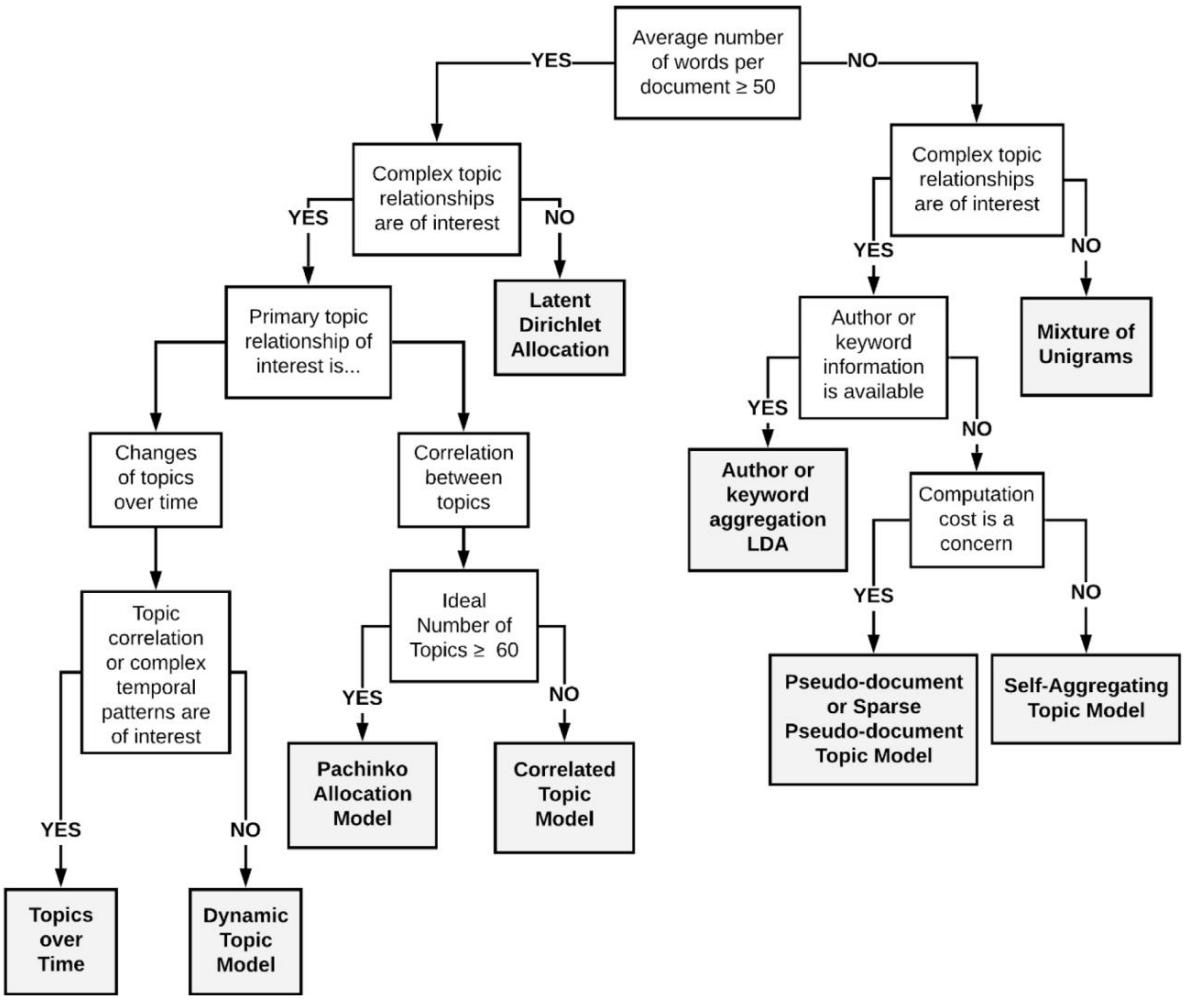

Figura 8. Árvore de decisão para seleção de um método de modelagem de tópicos.

Declaração de interesse concorrente

Os autores declaram que não têm interesses financeiros concorrentes ou relações pessoais conhecidas que possam ter influenciado o trabalho relatado neste artigo.

Referências

[1] DM Blei, Modelos de tópicos probabilísticos, Commun. ACM 55 (4) (2012) 77.

[2] L. Liu, L. Tang, W. Dong, S. Yao, W. Zhou, Uma visão geral da modelagem de tópicos e suas aplicações atuais em bioinformática, Springerplus 5 (1) (2016).

[3] L. Hong, BD Davison, Estudo empírico de modelagem de tópicos no Twitter, em: Proceedings of the First Workshop on Social Media Analytics, SOMA '10, Washington DC District of Columbia, 2010, pp.

[4] Y. Girdhar, P. Giguère, G. Dudek, Exploração subaquática adaptativa autônoma usando modelagem de tópicos online, em: JP Desai, G. Dudek, O. Khatib, V. Kumar (Eds.), Robótica Experimental: O 13º Simpósio Internacional de Robótica Experimental, Springer International Publishing, Heidelberg, 2013, pp.

[5] A. Agrawal, W. Fu, T. Menzies, O que há de errado com a modelagem de tópicos? E como consertar isso usando engenharia de software baseada em pesquisa, Inf. Suave. Tecnologia. 98 (2018) 74–88.

[6] JD Lafferty, DM Blei, Modelos de tópicos correlacionados, em: Y. Weiss, B. Schölkopf, JC Platt (Eds.), Advances in Neural Information Processing Systems, Vol. 18, MIT Press, 2006, pp.

[7] X. Yan, J. Guo, Y. Lan, X. Cheng, Um modelo de tópico biterm para textos curtos, em: Anais da 22ª Conferência Internacional sobre World Wide Web, Rio de Janeiro, Brasil, 2013, pp. 1445–1455.

[8] DM Blei, JD Lafferty, Modelos de tópicos dinâmicos, em: Proceedings of the 23rd International Conference on Machine Learning, Pittsburgh, PA, EUA, 2006, pp.

[9] W. Li, A. McCallum, alocação de Pachinko: modelos de mistura estruturados em DAG de correlações de tópicos, em: Proceedings of the 23rd International Conference on Machine Learning, Pittsburgh, PA, EUA, 2006, pp.

[10] M. Steyvers, T. Griffiths, Modelos de tópicos probabilísticos, em: TK Landauer (Ed.), Handbook of Latent Semantic Analysis, primeira ed., Routledge, Nova York, NY, EUA, 2011, pp. .

[11] Blei DM, Ng AY, Jordan MI, alocação latente de Dirichlet, J. Mach. Aprender. Res. 3 (2003) (2003) 993–1022.

[12] G. Salton, Alguns problemas de pesquisa em recuperação automática de informação, em: Proceedings of the 6th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval, Nova York, NY, EUA, 1983, 252263.

[13] S. Deerwester, ST Dumais, GW Furnas, TK Landauer, R. Harshman, Indexação por análise semântica latente, J. Am. Soc. Inf. Ciência. 41 (6) (1990) 391–407.

[14] T. Hofmann, Indexação semântica latente probabilística, ACM SIGIR Forum 51 (2) (2017) 8.

[15] Z. Zhou, J. Zhou, L. Zhang, Recuperação de imagens de roupas adaptativas à demanda usando modelo de tópico híbrido, em: Proceedings of the 2016 ACM on Multimedia Conference, MM '16, Amsterdã, Holanda, 2016, pp. 496–500.

[16] T. Hospedales, S. Gong, T. Xiang, Mineração de comportamento de vídeo usando um modelo de tópico dinâmico, Int. J. Computação. Vis. 98 (3) (2012) 303–323.

[17] Y. Ju, B. Adams, K. Janowicz, Y. Hu, B. Yan, G. McKenzie, Things and strings: Melhorando a desambiguação de nomes de lugares em textos curtos, combinando a co-ocorrência de entidade com modelagem de tópicos, em: E. Blomqvist, P. Ciancarini, F. Poggi, F. Vitali (Eds.), Engenharia do Conhecimento e Gestão do Conhecimento, Vol. 10024, Springer International Publishing, Cham, 2016, pp.

[18] Eason, Kumar, Avaliação de técnicas de mineração de texto usando dados do Twitter para resiliência a desastres de furacões, AGU Fall Meeting Abstracts (2019).

[19] Dahal, Kumar, Li, Modelagem de tópicos e análise de sentimento do clima global alterar tweets, Análise de Redes Sociais e Mineração 9 (1) (2019).

[20] Vayansky, Kumar, Li, Uma avaliação de dados georreferenciados do Twitter durante o furacão irma usando análise de sentimento e modelagem de tópicos para desastres

Machine Translated by Google

resiliência, em: Simpósio Internacional IEEE sobre Tecnologia e Sociedade (ISTAS) 2019, 2019.
[21] Singleton, Kumar, Li, avaliação baseada em análise do Twitter: as regiões costeiras dos Estados Unidos estão preparadas para as mudanças climáticas *f* , em: 2018 IEEE International Symposium on Technology and Society (ISTAS), 2018.
[22] Singleton, Kumar, Twitter Analytics: as regiões costeiras dos EUA estão preparadas para as alterações climáticas em 2017, AGU Fall Meeting Abstracts (2017).
[23] Harvey, Kumar, Bao, Modelos baseados em aprendizado de máquina para avaliar impactos antes, durante e depois do furacão Florença, em: 2019 IEEE Symposium Series on Computational Intelligence (SSCI), 2019.
[24] TL Griffiths, M. Steyvers, Encontrando tópicos científicos, Proc. Nacional. Acad. Ciência. 101 (Suplemento 1) (2004) 5228–5235.
[25] I. Porteous, D. Newman, A. Ihler, A. Asuncion, P. Smyth, M. Welling, Amostragem rápida de gibbs colapsados para alocação de dirichlet latente, em: Procedimento da 14ª Conferência Internacional ACM SIGKDD sobre Descoberta de Conhecimento e Mineração de dados, KDD 08, Las Vegas, Nevada, EUA, 2008, p. 569.
[26] K. Vorontsov, A. Potapenko, Tutorial sobre modelagem probabilística de tópicos: Regularização aditiva para fatoração de matriz estocástica, em: DI Ignatov, MY Khachay, A. Panchenko, N. Konstantinova, RE Yavorsky (Eds.), Análise de Imagens, Redes Sociais e Textos, Vol. 436, Springer International Publishing, Cham, 2014, pp.
[27] W. Zhao, et al., Uma abordagem heurística para determinar um número apropriado de tópicos na modelagem de tópicos, BMC Bioinformatics 16 (Suppl. 13) (2015) S8.
[28] J.-T. Chien, C.ÿH. Lee, Z.-H. Tan, modelo de mistura latente de Dirichlet, Neurocomputing 278 (2018) 12–22.
[29] D. Agarwal, B.-C. Chen, fLDA: fatoração de matriz por meio de alocação de dirichlet latente, em: Proceedings of the Third ACM International Conference on Web Search and Data Mining, Nova York, NY, EUA, 2010, pp.
[30] DM Blei, TL Griffiths, MI Jordan, O processo de restaurante chinês aninhado e inferência não paramétrica bayesiana de hierarquias de tópicos, J. ACM 57 (2) (2010) 1–30.
[31] J. Cao, T. Xia, J. Li, Y. Zhang, S. Tang, Um método baseado em densidade para seleção adaptativa de modelo LDA, Neurocomputing 72 (7–9) (2009) 1775–1781.
[32] DM Blei, JD Lafferty, Capítulo 4: Modelos de tópicos, em: A. Sricastava, M. Sahami (Eds.), Text Mining: Classification, Clustering, and Applications, CRC Press, Boca Raton, FL, EUA, 2009 , pp.
[33] U. Nodelman, CR Shelton, D. Koller, Redes bayesianas de tempo contínuo, em: Proceedings of the Eighteenth Conference on Uncertainty in Artificial Intelligence, Alberta, Canadá, 2002, pp.
[34] X. Wang, A. McCallum, Tópicos ao longo do tempo: um modelo de tempo contínuo não-Markov de tendências tópicas, em: Anais da 12ª Conferência Internacional ACM SIGKDD sobre Descoberta de Conhecimento e Mineração de Dados, Filadélfia, PA, EUA, 2006, pp.
[35] K. Nigam, A. Mccallum, S. Thrun, T. Mitchell, Classificação de texto de documentos rotulados e não rotulados usando EM, Mach. Aprender. 39 (2/3) (2000) 103–134.
[36] X. Quan, C. Kit, Y. Ge, SJ Pan, Modelagem de tópicos de texto curto e esparso via autoagregação, em: IJCAI, 2015.
[37] Y. Zuo, et al., Modelagem de tópicos de textos curtos: uma visão de pseudo-documento, em: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, KDD '16, San Francisco, Califórnia, EUA , 2016, pp.
[38] T. Lin, W. Tian, Q. Mei, H. Cheng, O modelo de tópico duplo esparso: mineração de tópicos focados e termos focados em texto curto, em: Anais da 23ª Conferência Internacional sobre World Wide Web, WWW '14, Seul, Coreia, 2014, pp.
[39] DD Lee, HS Seung, Aprendendo as partes de objetos por matriz não negativa fatoração, Nature 401 (6755) (1999) 788–791.
[40] D. Kuang, J. Choo, H. Park, Fatoração de matriz não negativa para modelagem de tópicos interativos e agrupamento de documentos, em: ME Celebi (Ed.), Partitional Clustering Algorithms, Springer International Publishing, Cham, 2015, pp . –243.
[41] M. Belford, B. Mac Namee, D. Greene, Estabilidade de modelagem de tópicos via fatoração de matriz, Expert Syst. Apl. 91 (2018) 159–169.
[42] C. Boutsidis, E. Gallopoulos, Inicialização baseada em SVD: Um avanço para fatoração de matriz não negativa, Pattern Recognit. 41 (4) (2008) 1350–1362.
[43] YW Teh, MI Jordan, MJ Beal, DM Blei, Compartilhando clusters entre grupos relacionados: processos hierárquicos de Dirichlet, em: LK Saul, Y. Weiss, L. Bottou (Eds.), Advances in Neural Information Processing Systems, Vol. . 17, MIT Press, 2005, pp.
[44] CP George, DZ Wang, JN Wilson, LM Epstein, P. Garland, A. Suh, Uma exploração e categorização de tópicos baseada em aprendizado de máquina em pesquisas, em: 2012 11ª Conferência Internacional sobre Aprendizado de Máquina e Aplicações, Boca Raton , FL, EUA, 2012, pp.
[45] YW Teh, K. Kurihara, M. Welling, Collapsed variational inference for HDP, em: Advances in Neural Information Processing Systems, 2008, pp .
[46] DJC MacKay, LCB Peto, Um modelo hierárquico de linguagem Dirichlet, Nat. Lang. Eng. 1 (03) (1995).
[47] HM Wallach, Modelagem de tópicos: além do saco de palavras, em: Proceedings of the 23rd International Conference on Machine Learning, Pittsburgh, PA, EUA, 2006, pp.
[48] B. Walsh, Notas de aula para EEB 581: Cadeia de Markov Monte Carlo e Gibbs Amostragem, Universidade do Arizona, 2004.
[49] CJ Geyer, cadeia prática de Markov Monte Carlo, Statist. Ciência. 7 (4) (1992) 473–483.
[50] A. Bhadury, J. Chen, J. Zhu, S. Liu, Ampliando modelos de tópicos dinâmicos, em: Proceedings of the 25th International Conference on World Wide Web, Montreal, Quebec, Canadá, 2016, pp. 390.
[51] DM Blei, A. Kucukelbir, JD McAuliffe, Inferência variacional: uma revisão para estatísticos, J. Amer. Estatista. Assoc. 112 (518) (2017) 859–877.
[52] YW Teh, D. Newman, M. Welling, Um algoritmo de inferência bayesiana variacional colapsado para alocação latente de Dirichlet, em: B. Schölkopf, JC Platt, T. Hoffman (Eds.), Avanços em Sistemas de Processamento de Informação Neural, Vol. 19, MIT Press, 2007, pp.
[53] MJ Beal, Algoritmos Variacionais para Inferência Bayesiana Aproximada (tese de doutorado), Universidade de Londres, Londres, Inglaterra, 2003.
[54] J. Yin, Y. Zhang, L. Gao, Acelerando algoritmos de expectativa-maximização distribuídos com atualizações frequentes, J. Parallel Distrib. Computação. 111 (2018) 65–75.
[55] TS Jaakkola, MI Jordan, Melhorando a aproximação do campo médio através do uso de distribuições de mistura, em: MI Jordan (Ed.), Learning in Graphical Models, Springer Holanda, Dordrecht, 1998, pp.